

分类号:

安徽师范大学

硕士学位论文

题目: 基于分层注意力网络的分布式光纤振动传感系统开集事件识别方法研究

Title: **Research on Open-Set Event Recognition Method for Distributed Optical Fiber Vibration Sensing Systems Based on Hierarchical Attention Network**

学科、专业: 光电信息科学与工程

研究方向: 光纤传感

作者姓名: 谢天长

导师及职称: 周正仙 副教授

论文提交日期: 2025 年 5 月

授予学位日期: 2025 年 6 月

安徽师范大学学位评定委员会办公室

基于分层注意力网络的分布式光纤振动传感 系统开集事件识别方法研究

谢天长

安徽师范大学硕士学位论文
(二〇二五年五月)

基于分层注意力网络的分布式光纤振动传感系统开集事件识别方法研究

摘要

分布式光纤振动传感技术已广泛应用于智能电网、安全监测等领域。目前在光纤振动传感信号识别的研究主要集中在提高已知事件的识别精度、降低误报率上。然而在实际应用中传感光纤的周围环境复杂，信号的随机性很大，当未知事件出现时会极大影响信号识别准确性。为了克服这一问题，本文提出一种基于 Hierarchical Attention Network with Openmax (HANO) 的光纤振动传感信号开集事件识别方法，解决了在开放环境下不能识别未知信号的问题。主要完成工作如下：

(1) 首先介绍了分布式光纤振动传感技术的基本概念与重要性，并回顾了近年来该领域的研究进展，特别是基于机器学习和深度学习的方法，提出了利用这些新兴技术显著改善信号识别性能的可能性。研究了光时域反射仪 (OTDR) 的基本原理和工作机制，深入分析了 Φ -OTDR 系统在振动检测中的应用。使用基于时域方差的定位算法和信号特征提取方法对信号进行定位与处理。最后阐述了闭集事件识别和开集事件识别的原理，为后续的事件识别奠定了重要基础。

(2) 设计了分布式光纤振动传感开集事件识别系统，基于 HANO 模型进行信号识别。构建了光纤振动传感信号识别模型，通过整合 Hierarchical Attention Network 和 Openmax 算法，提升了系统对开放集事件的识别能力。设计了分布式光纤振动传感系统，并描述了系统的参数指标设置。为了提高模型的鲁棒性和准确性，我们对振动信号的定位与预处理进行了详细探讨，并描述了 HANO 模型的设计过程，从分层注意力网络的构建到 Openmax 算法的实现，针对模型训练模式及其他网络模型的研究也做了详细分析。

(3) 搭建了分布式光纤振动传感的实验装置并进行了性能测试与对比验证，采集了脚踢、锯网、摇晃、攀爬四种事件作为闭集，树枝触碰、手摸、风雨三种事件作为开集。针对采集到的信号，通过时频分析预处理后，进行了一系列的性能测试与对比，包括 Swin transformer、HANO、YOLOv5、1-D ResNet 闭集网络分类测试和开集分类测试。使用 Sigmoid 激活函数的 HANO 模型识别效果最好，总体识别率达到 95.71%。

本文提出的 HANO 模型开集识别算法，可以有效提升复杂环境中光纤振动传感信号识别的准确性，在安全监控、入侵检测和环境监测等领域具有重要意义。

关键词： Φ -OTDR；光纤振动传感；信号识别；开集识别；深度学习

Research on Open-Set Event Recognition Method for Distributed Optical Fiber Vibration Sensing Systems Based on Hierarchical Attention Network

Abstract

Distributed optical fiber vibration sensing technology finds extensive applications in areas including smart grids and security monitoring. Currently, research on optical fiber vibration sensing signal recognition mainly focuses on improving the recognition accuracy of known events and reducing false alarm rates. However, in practical applications, the surrounding environment of the sensing fibers is complex, and the randomness of the signals is significant. When unknown events occur, they can greatly affect the accuracy of signal recognition. To address this issue, this paper proposes a novel open-set event recognition method for optical fiber vibration sensing signals based on a Hierarchical Attention Network with Openmax, aimed at overcoming the challenge of recognizing unknown signals in open environments. The main contributions of this work are as follows:

(1) We introduced the fundamental concepts and significance of distributed fiber optic vibration sensing technology, along with a review of recent advancements in this field, particularly methods based on machine learning and deep learning. We highlighted the potential of leveraging these emerging technologies to significantly improve signal recognition performance. The fundamental principles and operational mechanisms of Optical Time-Domain Reflectometry (OTDR) were thoroughly investigated, with a comprehensive analysis conducted on the application of phase-sensitive OTDR (ϕ -OTDR) systems in vibration sensing. We employed a time-domain variance localization algorithm and a signal feature extraction method for signal localization and processing. Finally, we established a vital foundation for subsequent event recognition by elucidating the principles of closed-set and open-set event identification.

(2) We designed an open-set event recognition system for distributed fiber optic vibration sensing, utilizing a Hierarchical Attention Network with Openmax (HANO) model for signal recognition. We constructed a model for recognizing fiber optic vibration sensing signals by integrating the Hierarchical Attention Network and the Openmax algorithm to enhance the system's capability to identify open-set events. We detailed the setup of the distributed fiber optic vibration sensing system and described its parameter specifications.

To improve the model's robustness and accuracy, we provided a thorough exploration of the localization and preprocessing of vibration signals and detailed the design process of the HANO model, covering the construction of the hierarchical attention network and the implementation of the Openmax algorithm, as well as an extensive analysis of training modes and other network models.

(3) A distributed optical fiber vibration sensing experimental setup was established, and its performance was tested and compared for validation. Four types of events, including kicking, sawing the mesh, shaking, and climbing, were collected as the closed set, while three types of events, including branch, finger, and storm, were collected as the open set. After preprocessing the acquired signals via time-frequency analysis, we performed a series of performance tests and comparisons, including closed-set and open-set network classification tests for Swin Transformer, HANO, YOLOv5, and 1-D ResNet. The HANO model employing the Sigmoid activation function achieved the best recognition performance, with an overall accuracy of 95.71%.

The open-set recognition algorithm proposed in this study for the HANO model significantly enhances the accuracy of optical fiber vibration signal recognition in complex environments, offering substantial value for applications in security monitoring, intrusion detection, and environmental sensing.

Keywords: ϕ -OTDR; Fiber optic vibration sensing; Signal recognition; Open set identification; Deep Learning

目 录

第一章 绪论.....	1
1.1 引言.....	1
1.2 分布式光纤振动传感信号识别研究进展	2
1.2.1 基于机器学习的分布式光纤振动信号识别	3
1.2.2 基于深度学习的分布式光纤振动信号识别	5
1.3 本文研究内容.....	7
第二章 分布式光纤振动传感技术及信号识别理论研究	9
2.1 ϕ -OTDR 系统基本原理	9
2.1.1 瑞利后向散射原理.....	9
2.1.2 光时域反射仪.....	10
2.1.3 ϕ -OTDR 原理	12
2.2 信号定位与处理方法.....	14
2.2.1 时域方差定位算法.....	14
2.2.2 信号的特征提取方法.....	17
2.3 分布式光纤振动传感事件识别方法	18
2.3.1 分布式光纤振动传感封闭集事件识别方法	18
2.3.2 分布式光纤振动传感开集事件识别方法	19
2.4 本章小结.....	20
第三章 分布式光纤振动传感开集事件识别系统设计	21
3.1 基于 Hierarchical Attention Network with Openmax 的光纤振动 传感信号识别系统	21
3.2 分布式光纤振动传感系统的搭建与参数指标	22
3.3 振动信号的定位与预处理	24
3.4 HANO 开集算法模型.....	26
3.4.1 分层注意网络模型.....	26
3.4.2 Openmax 算法	30
3.4.3 HANO 模型训练模式	31
3.4.4 其他网络模型.....	32
3.5 本章小结.....	36
第四章 振动信号采集与模型性能测试	37
4.1 实验装置搭建.....	37
4.2 区域振动信号定位与采集	37
4.3 信号预处理与数据集分配	39
4.4 模型性能测试与对比.....	41

4.4.1 闭集网络分类测试.....	41
4.4.2 开集分类测试.....	46
4.4.3 不同网络下开集识别对比.....	52
4.5 本章小结.....	53
第五章 总结和展望	54
5.1 主要完成工作.....	54
5.2 本文的创新点.....	55
5.3 展望.....	55
参考文献.....	56

第一章 绪论

1.1 引言

在现代科技快速发展的背景下,传感器技术在诸多领域(如土木工程、环境监测、智能建筑、医疗健康及能源管理)发挥着至关重要的作用。然而,传统的点式传感器存在空间覆盖范围有限以及易受局部干扰等固有缺陷,限制了其在更大范围监测中的应用。分布式光纤传感技术凭借其独特的优势,逐渐成为当下最具潜力的传感技术之一^[1-3]。该技术利用单根光纤即可对数公里范围内多种物理量(例如温度、应变、压力和位移)进行连续监测,显著提升了监测的空间分辨率和覆盖范围^[4]。与传统的点式传感器相比,分布式光纤传感器能够实时、连续地提供数据,并在局部事件发生时迅速响应,及时发出预警信息。其工作原理基于多种光学效应,包括光纤光栅、拉曼散射、瑞利散射和布里渊散射等。这些不同的光学效应赋予了该技术根据测量需求选择不同精度、灵敏度和空间分辨率的能力。例如,基于瑞利散射的分布式光纤传感器因其高空间分辨率,广泛应用于工程结构健康监测^[5-7];而基于拉曼散射的传感器则更适用于长距离、高灵敏度的温度测量^[8-9]。这些优势使其在各个领域展现出巨大的应用潜力。

在基础设施监测方面,分布式光纤传感技术能够实现对桥梁、隧道、建筑物等结构的实时健康监测^[10-12]。随着城市化进程的加快,基础设施的安全性和可靠性显得尤为重要。传统的监测方法多依赖于定期检查和人工评估,难以动态获取结构健康状态信息。而分布式光纤传感器通过在光纤上分布测量点,能够实时获取结构受力、变形、温度等数据,提供连续、精确的监测信息,帮助工程师及时发现潜在风险,推动预防性维护的发展^[13]。

在环境监测领域,分布式光纤传感技术同样展现出广泛的应用价值^[14]。例如,对土壤湿度^[15]、水面液位^[16]等方面的监测。利用光纤传感器,可以在大范围内实现对环境参数的实时监测,为及时应对环境问题提供数据支持。此外,分布式光纤传感器还可以集成到智能城市和智慧农业中,发挥其在数据采集与分析中的作用,促进可持续发展^[17]。

在工业过程控制方面，分布式光纤传感技术可以监测温度、应变、振动等参数^[18-19]，以优化生产过程和设备维护。在高温、高压等极端环境中，传统传感器往往难以正常工作，而光纤传感器由于其无电源、抗电磁干扰的特点，在此类环境中显示出显著的优势。同时，分布式光纤传感器的可扩展性多点式分布式测量使其能够满足现代工业对数据采集和分析的高需求^[20]。

随着技术的进步，分布式光纤传感器的种类和应用场景日益丰富。光学传感原理的不断创新，包括相干光学^[21]、光子晶体光纤^[22]以及频域分辨^[23]等新技术，为分布式光纤传感器的高性能和多功能性赋予了更多可能性^[24]。与此同时，数据处理和分析技术的进步，使得从大规模光纤传感网络中获取有意义的信息成为可能。尽管分布式光纤传感技术的前景广阔，但在实现信号的有效识别方面仍面临诸多挑战^[25]。首先，光纤传感器采集到的信号往往受到环境噪声、温度变化等因素的影响，导致信号识别的准确性降低，高效提取和识别这些信号是当前研究中的一个关键挑战。其次，如何快速处理和分析采集到的海量数据，以便快速获得有用信息，也是当前研究的热点之一。此外，算法的设计和优化、数据融合技术的应用等，都是提升信号识别能力的重要方向。针对分布式光纤传感信号的识别，研究重点在于利用先进的信号处理和模式识别技术，提升对光纤传感数据的理解和应用。当前研究主要集中在时域、频域和时频域等方法上，以期通过信号处理和分析，提取更有意义的信息。例如，运用小波变换、傅里叶变换等技术^[26]，可以对复杂的信号进行有效分解和分析，从而支持后续是非判别和事件识别。

综上所述，分布式光纤传感信号识别技术的研究不仅具有理论上的重要意义，更在实践中展现出巨大的应用潜力。随着技术的不断进步，分布式光纤传感信号的识别能力将不断提升，有助于推动相关领域的持续发展。在接下来的章节中，我们将深入探讨分布式光纤传感信号的基本原理、识别技术的发展历程、当前存在的挑战以及未来的发展方向，为相关研究提供全面而深入的参考

1.2 分布式光纤振动传感信号识别研究进展

近年来，国内对光纤振动识别技术的发展给予了高度重视，众多大型企业纷纷投入研发，致力于分布式光纤振动的预警和识别设备。其中， Φ -OTDR（光纤光学时域

反射)系统的原理主要分为两类:一类是基于干涉效应造成的散射信号强度的变化,另一类则是通过解调散射信号的相位变化^[27]。前者虽然结构简单且成本低廉,但光纤所检测到的振动强度与信号强度之间缺乏线性关系,限制了其应用于定量测量。相比之下,基于相位变化解调的系统具有更高的灵敏度和性能,其相位差与振动之间存在线性关系,这使得定量检测成为可能。这一类系统又可根据解调方法的不同,细分为基于 3×3 耦合器的相位解调、正交相位解调、希尔伯特变换相位解调以及载波相位生成解调等多种方式。本文选用的系统为直接探测的 Φ -OTDR系统。

目前,光纤振动识别技术的研究方向主要集中在两个方面:一是基于机器学习的振动识别方法^[28],二是近几年兴起的卷积神经网络(CNN)相关技术^[29-30]。这两个方向的研究持续推进,推动了这一领域的快速发展。以下将分别对这两种方法的研究现状进行详细探讨。

1.2.1 基于机器学习的分布式光纤振动信号识别

早期对于振动事件的识别方法主要依赖于建立特征值数据库、加权平均型综合评判函数等一些人为设定的判别规则。这些规则在振动信号识别中的应用虽然在一定程度上降低了复杂性,但也带来了许多实际问题。由于这些判别规则通常是基于静态的特征值设定的,故在面对复杂和多变的环境条件时,系统的适应性显得相当不足,导致频繁出现误报和漏报的现象。例如,当环境噪声、振动源特性或信号干扰等外部因素发生变化时,原有的判别规则往往无法准确捕捉到新的特征,从而引发识别准确性的大幅下降。

在早期的振动信号识别的研究中,使用的算法主要有支持向量机(SVM)、相关向量机(RVM)、以及人工神经网络(ANN)等。这些方法虽然在当时提供了一种较为有效的识别手段,但依然面临着模型训练时间长、特征选择困难等问题。比如,支持向量机(SVM)通过构造高维特征空间来实现分类,虽然在一些应用场景中表现出色,但对于海量数据的处理却显得举步维艰。此外,相关向量机(RVM)虽然能通过少量的训练样本达到较高的分类准确率,但模型的设计与后续的调整仍然需要大量的人工经验。而人工神经网络(ANN)则通过模拟人脑的神经网络结构,从而实现较为非线性的振动信

号处理，然而其训练过程的复杂性以及对参数的敏感性仍然为实际应用带来了诸多挑战。




图 1.1 早期机器学习方法振动事件识别流程

2015 年，Sun. Q 等提出一种用于相敏光学时域反射计（ Φ -OTDR）传感系统的入侵事件识别特征提取方法^[31]。该方法通过使用时域信号的形态特征来提取特征向量，克服了传统方法在特征提取中耗时且易受噪声干扰的问题。计算散点矩阵用于特征选择，实验结果表明，该方法显著提高了识别精度，并将计算时间缩短至 1 秒以内，识别准确率达到 97.8%，非常适合用于 Φ -OTDR 系统的在线振动监测。

2017 年，Wu HJ 等人通过对比研究了三种典型现场测试信号的小波分解（WD）和小波包分解（WPD）特征提取方法，并构建了人工神经网络（ANN）进行事件识别^[32]。对比结果表明，在输油管道安全监测中，WPD 对 DOVS 信号的分析 and 识别效果略优于 WD。基于小波包能量分布特征的识别网络可将识别率提高到 94.4%，将妨害报警率有效控制在 5.6% 以下。构建了人工神经网络 (ANN) 进行事件识别，将报警率有效控制在 5.6% 以下。

为了改善模式识别的性能，2019 年 Wang Y 等人提出一种基于相敏时域反射计的分布式光纤振动传感系统中的入侵模式识别方法^[33]。通过小波能谱分析从原始振动信号中提取特征向量，并使用相关向量机进行分类，以提高分类精度和概率输出。设定了小波能谱分析的最优分解层为 6 层，并在不同地面材料和天气条件下进行了多种振动模式的实验。通过 10 倍交叉验证得到多分类混淆矩阵，并分析了准确率、召回率、f-measure 等性能指标，最终实现了 88.60% 的分类宏观准确率。

2021 年，Fouda BMT 应用 SVM 算法和时频域特征 (TFDC) 特征提取方法对三次海底电缆撞击事件进行了检测和识别^[34]。实验结果表明，对电缆撞击事件的平均识别率为 96.78%，平均识别时间为 2.47 s，能够有效地识别和确定海缆事件。在人工提取特征的基础上，可以进一步提高神经网络的性能。

在早期的机器学习方法中，事件识别已经取得了一定的效果，但是这些方法大多依赖于人为提取信号的特征，并且这些特征提取的方法通常基于领域专家的经验设计，这种方式可能导致部分信号基础信息的丧失。

1.2.2 基于深度学习的分布式光纤振动信号识别

与传统的机器学习方法相比，深度学习算法通过自动化的方式进行特征提取，一过程极大地简化了研究人员在特征提取阶段的需求，使其能够以更少的领域知识和人工干预来获得有效的判别特征^[35]。深度学习相较于传统的机器学习方法具有以下几个显著优势：

（1）特征自动提取

深度学习模型能够自动提取数据中的复杂特征，减少了人工特征工程的依赖。这一优势在处理复杂的光纤传感数据时尤为突出，因为这些数据通常包含非线性和高维度的特征。

（2）处理大规模数据

随着光纤传感技术的应用范围增大，面对不同的复杂环境下，产生的数据量急剧增加。深度学习擅长从大规模数据集中提取有用信息，因此在处理高维度和大规模数据时，更加高效和准确。

（3）适应性强

深度学习模型具有较强的适应能力，能够根据不同的应用场景和数据分布进行自我优化，由于传感光纤周围环境复杂，使其在不同类型的光纤传感应用中表现出色。

（4）多模态数据融合

深度学习可以将来自不同传感器和多种类型数据进行融合，增强数据分析的深度与准确性。深度学习的引入为光纤传感领域的各项应用带来了更高的准确性和效率，使得系统的智能化、自动化水平显著提升。目前深度学习中的卷积神经网络(CNN)具有强大的表征学习能力，研究人员开始采用 CNN 来识别光纤振动信号中的事件。

2021 年 Wu H 等从两个方面提出了一种扩大 CNN 有用数据集的方法^[36]。第一个方面是提出了一种强度和相位叠加 CNN （IP-CNN）来利用具有相干检测的 DAS 的强度

和相位信息。第二个方面是提出使用数据增强来进一步增加训练数据集的大小。深入研究了不同的数据增强方法对所提出的 CNN 架构性能的影响。实验结果表明,在传感长度为 1km 的 DAS 数据集上,基于数据增强的 IP-CNN 分类准确率达到 88.2%。

为了克服在某些场景下,入侵信号难以采集导致训练样本不足的问题,2022 年,Shi Y 等针对 Φ -OTDR 系统,提出了一种基于时间序列转移和周期生成对抗网络(CycleGAN)数据增强的少镜头学习分类方法^[37]。通过基于时间序列转移和 CycleGAN 的稀有样本扩展,最终使数据集中的样本数量满足网络训练的要求。实验结果表明,即使训练集有两个小类,只有两个样本,5 个分类任务的验证集的平均准确率仍然可以达到 90.84%,小类的分类准确率可以达到 79.28%。

为了保持网络规模,又能避免计算量的增加,2022 年 Shi Y 等又提出了一种基于多信号表示的注意机制特征融合方法,用于埋地光纤 Φ -OTDR 事件分类。每个信号表示经过特征提取后进行融合,得到更丰富、更好的特征^[38]。利用一种基于注意机制的层剪枝方法。实验结果表明,该方法具有 3 种信号表示,识别准确率达到 97.93%,比单一表示方法提高了 3.52%。在输入阶段,该方法比传统的多信号表示融合方法具有更高的识别精度。当融合四种表示时,识别准确率可进一步提高到 99.11%。

目前卷积神经网络在对光纤传感封闭集事件的识别上方法众多,平均识别率也很高。然而,在实际应用中,传感光纤周围的环境非常复杂,信号的种类比我们在模型训练中所使用的要多,并且具有一定的随机性和不确定性。因此,当封闭集识别模型应用于开放集环境时,会错误地将未知事件分类为已知事件,导致错误的判断结果。为了解决这个问题,需要开发新的算法来准确分类和识别未知事件,以提高模型在开放集环境下的精确性和泛化能力。目前用于图像识别的开集算法有 Openmax^[39]、开放集识别的生成对抗网络(OpenGAN)^[40]、对抗性互惠点学习(ARPL)^[41]、类激活映射(CAMV)^[42]等。目前在 Φ -OTDR 系统上开放集识别的研究较少。2023 年,有研究者提出了一种新的基于 1-D 残差学习卷积神经网络(1-D RL-CNN)和 Openmax 算法的开放集事件识别模型^[43],实验结果表明,使用 Openmax 的 1-D RL-CNN 总体开集分类准确率为 91.19%。然而在实际应用中还存在识别事件少、准确率低等问题。

1.3 本文研究内容

为进一步提高开放环境中事件识别精度,本文针对分布式光纤振动传感系统在开放环境下识别已知事件和未知事件做了深入的理论研究和实验。本文提出了一种基于改进的分层注意力网络(Hierarchical Attention Network)与 Openmax 分类模型的分布式光纤振动感知开放事件分类模型(Hierarchical Attention Network with Openmax Model, HANO)。该模型在开放环境中表现出高准确性和泛化能力,有效解决了传统封闭集识别模型在类似环境下的局限性。在实验中,我们选取了摇晃、锯切、攀爬和踢打作为已知事件,选取了指尖触碰、树枝摆动和暴风雨作为未知事件。与 Swin Transformer 模型^[44]、YOLOv5 模型^[45]、1-D ResNet 模型、Softmax 层以及原始的 Openmax 层相比,改进后的 HANO 模型在事件识别方面表现出优越的性能,达到了 95.71% 的整体开放集分类准确率。论文的各章节结构内容如下:

第一章主要探讨分布式光纤振动传感技术的发展前景及其实际应用,强调了该技术在现代工程和安全监测中的重要性,指出了本研究的意义和价值。针对当前分布式振动传感技术的研究现状,重点介绍了两种主要的技术路径:一种是基于机器学习的算法,另一种是基于深度学习的卷积神经网络模型,并分析了这两者的差异及其演进过程。最后概述了本文的结构安排和研究内容。

第二章着重于分布式光纤振动传感在开放环境下的事件识别理论研究。首先介绍了 ϕ -OTDR 系统的基本原理,包括瑞利后向散射原理、光时域反射仪的工作机制和 ϕ -OTDR 的具体原理,这为理解光纤振动传感技术奠定了基础。然后介绍信号定位与处理方法,重点阐述时域方差定位算法及其在信号分析中的应用,以及信号特征提取的相关技术。最后章节将分别探讨分布式光纤振动传感的封闭集和开放集事件识别方法,详细分析各自的实现过程,为实际应用中的事件识别提供理论指导和技术参考。本章为分布式光纤振动传感技术在复杂环境中的有效应用提供深入的理论支持。

第三章将详细探讨分布式光纤振动传感开放集事件识别系统的设计。设计了基于 Hierarchical Attention Network with Openmax 的光纤振动传感信号识别模型,以克服在开放环境下不能识别未知信号的问题。阐述了分布式光纤振动传感系统的搭建过程及其关键参数指标,以确保系统稳定性和可靠性。接着详细讨论了振动信号的定位与预处理步骤。章节将深入分析分层注意网络(HAN)模型的构建并详细介绍了

Openmax 算法，探讨其在开放集识别中的作用与有效性。本章在为分布式光纤振动传感技术的系统设计提供全面的理论基础和实践指导。

第四章将围绕分布式光纤振动传感的实验与数据处理展开，重点介绍实验的实施过程及数据分析方法。首先详细描述了实验装置的搭建，确保系统能够有效采集和处理振动信号。然后阐述了振动信号的定位与采集的具体过程。在数据集处理方面，本章将介绍信号预处理的步骤，以及如何合理地分配数据集以便于模型训练。章节还将深入讨论不同模型的训练和测试具体步骤及参数指标，确保获得高性能的识别模型。最后对模型的性能进行测试与对比，包括闭集与开集分类测试，分析不同网络在开放集识别中的表现。通过这一系列实验与数据处理的介绍，为分布式光纤振动传感技术的实用性提供充分的实验结果数据支持。

第二章 分布式光纤振动传感技术及信号识别理论研究

2.1 ϕ -OTDR 系统基本原理

2.1.1 瑞利后向散射原理

1. 光纤中的后向散射

光纤作为一种高效传输光信号的介质，其内部传播机制受到材料均匀性和微观结构的显著影响。在光纤的生产过程中，因材料结构的微小不均匀性和杂质的存在，光线在其传播途中会产生多种形式的后向散射现象^[46]。当光波以特定入射角度进入光纤时，部分光波由于与介质的微结构碰撞而被散射回入射方向。后向散射大致可分为三类：瑞利后向散射、布里渊后向散射和拉曼后向散射。瑞利后向散射为弹性散射，散射光的频率与入射光一致，这一现象主要源于光波与微粒的碰撞所产生的瞬时极化效应^[47]。相对而言，布里渊后向散射和拉曼后向散射则为非弹性散射，其中布里渊散射依赖于声波与光波的耦合，而拉曼散射则涉及光波在与分子振动模式相互作用后频率发生变化的现象。这些后向散射效应在光纤通信、传感器以及光纤成像等领域中具有重要的应用价值，对于改善信号质量及增强系统性能具有重要意义。本文将从瑞利散射的基础原理入手，逐步过渡到其在光纤传感系统中的应用。

2. 瑞利散射基础原理

光纤通常由芯层和包层组成，芯层的折射率高于包层，从而可以引导光波在光纤中传输。光纤中的杂质、微小的气泡或纤维的微小变化都会在传播过程中引起瑞利散射。如图 2.1 所示，后向散射光将沿着与入射光相反的方向返回，并被探测器接收。散射光的强度信息携带着光纤内部的物理及化学状态的变更信息。根据光的波动性，

散射的强度与光波长成反比，遵循 $I \propto \frac{1}{\lambda^4}$ 的关系。这意味着波长越短，散射强度越大。




图 2.1 瑞利后向散射在光纤中的发生

在光纤中瑞利散射光强度可表示为：

$$I(\theta) = I_0 \pi d \lambda^{-4} R^{-2} V^2 (1 + \cos^2 \theta) (n-1)^2 \quad (2.1)$$

其中 I_0 为入射光的光强， θ 为入射光和散射光的夹角， d 为测得点的光纤长度， λ 为入射波长， R 为纤芯半径， V 为幅度， n 为纤芯折射率。 $I(\theta)$ 为沿该角度上光强的大小。当 θ 角为 180° 的时候， $I(\theta)$ 最大，所以采用角度为 180° 时的后向散射光。

瑞利散射的功率和脉冲光的脉宽有如下关系：

$$P_R = P S_{\alpha_s} W \frac{v}{2} \quad (2.2)$$

其中 P 为脉冲光的峰值功率大小， S_{α_s} 为后向散射捕获因子， α_s 为散射系数， W 为脉冲光脉宽， v 为光在真空中的传播速度。其中 S_{α_s} 可以表示为：

$$S = \frac{1}{4} \left(\frac{\lambda}{\pi n R} \right) \quad (2.3)$$

瑞利散射作为一种弹性散射现象，其后向散射光的频率与入射光脉冲完全一致。相较于光纤内其他类型的散射光，瑞利后向散射光因其较高的光强度而对外部环境变化表现出更高的敏感性。这种特性使其广泛应用于探测振动、语音等信号，以及进行光纤线路的功率衰减和损耗评估。

2.1.2 光时域反射仪

光时域反射仪（Optical Time Domain Reflectometer, OTDR）是一种利用光学技术进行光纤通信系统检测、故障定位和损耗分析的重要工具^[48]。它通过分析光纤中光信号的散射与反射特性来确定光纤的状态和位置。




图 2.2 OTDR 基本结构图

如图 2.2 所示为 OTDR 基本结构图，OTDR 的工作原理基于瑞利散射和反射现象。当激光脉冲发射到光纤中时，一部分光会被光纤内的瑕疵、接头及其他不均匀性反射或散射回仪器。OTDR 接收散射或反射的光信号，并通过分析这些信号的特性（如强度、回波时间、波形等）来评估光纤的状况。

光脉冲发射：OTDR 发射短时宽脉冲光信号，脉冲功率可用如下公式表示：

$$P(t) = P_0 \cdot \delta(t) \quad (2.4)$$

其中 P_0 是脉冲的最大功率， $\delta(t)$ 是单位脉冲函数。

当光脉冲在光纤中传播时，会遇到光纤内的散射中心（如分子、微小颗粒等），这些中心会导致光的瑞利散射。散射光的强度 I 通常与距离、光波的波长 λ 及光纤折射率有关，可用如下公式表示：

$$I \propto \frac{1}{\lambda^4} \quad (2.5)$$

散射光返回的时间与光纤长度 L 相关，光在光纤中的传播速度 v 受光纤材料的折射率 n 影响，可用如下公式表示：

$$v = \frac{c}{n} \quad (2.6)$$

其中 c 是真空中光速。因此，往返时间 T 可以表示为：

$$T = \frac{2L}{v} = \frac{2Ln}{c} \quad (2.7)$$

OTDR 接收到的信号是时间函数，可以绘制为反射强度与时间的关系曲线（反射图），从而识别不同距离上散射或反射的信号^[49,50]。信号处理一般包括以下步骤：

1. 数据获取：OTDR 对接收到的信号进行数字化处理，通过快速采样将返回信号转化为时间域波形。
2. 反射强度分析：通过分析反射波形，确定光纤中不同位置的反射强度。通常使用分贝（dB）表示相对功率：

$$P(dB) = 10 \log_{10} \left(\frac{P}{P_0} \right) \quad (2.8)$$

其中 P_0 是参考功率， P 是测量功率。

3. 故障定位：如图 2.3 所示根据回波信号的强度及其反射位置，可以判定光纤中可能存在的故障位置、损耗程度及其他光学特性。




图 2.3 OTDR 曲线中故障点示意图

2.1.3 ϕ -OTDR 原理

ϕ -OTDR (Phase-sensitive Optical Time Domain Reflectometry) 是一种结合了相位测量技术的光时域反射仪，能够提供高精度的光纤状态监测，特别是在温度和应变监测等应用中^[51,52]。与传统的 OTDR 相比， ϕ -OTDR 具有更高的灵敏度和分辨率，能够实现分布式传感。

在无扰动的情况下，窄线宽脉冲光在时刻 $t=0$ 入射到传感光纤时产生的后向瑞利散射光波函数可以用以下表达式表示：

$$y(t) = \sum_{k=1}^N \exp[jw_s(t - \tau_k)] a(\tau_k) \exp(-\alpha \frac{c\tau_k}{n}) \text{rect}(\frac{t - \tau_k}{W}) \quad (2.9)$$

$$\text{rect}(\frac{t - \tau_k}{W}) = \begin{cases} 1, & \text{while } 0 \leq \frac{t - \tau_k}{W} \leq 1 \\ 0, & \text{otherwise} \end{cases} \quad (2.10)$$

$\exp[jw_s(t - \tau_k)]$ 为输入光的波函数，式中 N 为传感光纤中散射体数量； τ_k 为第 k 个散射体的时间延迟； $a(\tau_k)$ 为对应的辐射因子； w_s 为光源的角频率； c 为真空中光的传播速度； n 为传感光纤纤芯的折射率； α 为传感光纤的衰减系数。

当外界干扰信号作用于传感光纤时，光纤折射率的变化导致光波相位在干扰点和光纤末端之间往返调制。干涉效应使瑞利后向散射光的强度发生变化，其光波函数可表示为：

$$y(t) = y_1(t) + y_2(t) \quad (2.11)$$

$$y_1(t) = \sum_{k=1}^M \exp[jw_s(t - \tau_k)] a(\tau_k) \exp(-\alpha \frac{c\tau_k}{n}) \text{rect}(\frac{t - \tau_k}{W}) \quad (2.12)$$

$$y_2(t) = \sum_{k=M+1}^N \exp[jw_s(t - \tau_k)] a(\tau_k) \exp(-\alpha \frac{c\tau_k}{n}) \text{rect}(\frac{t - \tau_k}{W}) \quad (2.13)$$

$$\exp\{j[f(t - \frac{2nk_z}{c} + \frac{nz_d}{c}) + f(t - \frac{nz_d}{c})]\} \quad (2.14)$$

在时刻 t 前后，扰动信号作用于传感光纤某点，产生的瑞利后向散射光波函数分别为 $y_1(t)$ 和 $y_2(t)$ 。其中 M 表示扰动点之前的散射体数量， z_d 为扰动点的位置。当振动信号作用在该位置时，光纤会产生形变，导致折射率变化，从而实现相位调制。同时， $f(t)$ 是与扰动信号相关的函数。

在没有任何扰动时，光纤中的散射点分布保持不变，瑞利散射光的波形也显得稳定。相反，当有扰动信号引入时，受影响的光纤段内散射点的相位会发生改变，导致瑞利散射干涉光的变化，最终引起对应位置的光强波动。在扰动信号作用区域内，信号幅值显著变化，而在无扰动区域，信号幅值保持稳定。通过对比有无扰动信号后的后向散射曲线幅值，可以有效鉴别传感光纤上是否存在振动事件及其大致位置。




图 2.4 基于瑞利后向散射的反射镜模型

为了更好的理解 ϕ -OTDR 的工作原理，如图 2.4 所示为基于瑞利后向散射的反射镜模型^[53,54]。单个脉冲光 W 对应传感光纤的长度为 L ，分成 N 段，每段长度为 ΔL ，每段内有 M 个反射镜。幅度和相位服从随机分布。那么第 k 段后向散射体总数 r 为：

$$r = r_k e^{j\phi_k} = \sum_{i=1}^M r_i e^{j\phi_i} \quad (2.15)$$

式中 r_k 为光纤中第 k 段的散射体幅值， ϕ_k 为相位， r_i 和 ϕ_i 分别为第 i 个散射点对应的幅值和相位。在距离光源 $m\Delta L$ 的瑞利后向散射光为：

$$E_{back}(m\Delta L) = E_0 \sum_{k=m}^{m+n-1} P_k R_k \exp j(\phi_k + \Delta\phi_k) \exp(-\alpha k\Delta L) \quad (2.16)$$

式中 E_0 为入射光的初始光强度， P_k 为第 k 个散射体的偏振系数， r_k 为对应的瑞利后向散射系数， ϕ_k 为对应的初始相位， $\Delta\phi_k$ 为光纤中扰动导致的相位变化。

2.2 信号定位与处理方法

2.2.1 时域方差定位算法

基于相干光时域反射技术的分布式光纤传感系统中，振动定位的核心原理可以这样理解：探测器捕获的后向瑞利散射信号呈现周期性特征。当光纤上某处发生振动时，该位置前后时刻的散射曲线会产生差异。具体而言，在无扰动和有扰动两种状态下，曲线上对应点的瑞利散射光强度会发生变化。基于这一现象，我们可以采用时序

对比法进行振动定位^[55]。如图 2.5 所示，具体步骤如下：首先获取相邻两个时间点的后向散射曲线，然后将这两条曲线进行差分运算。通过分析所得的差值曲线，我们可以大致确定振动发生的位置。这种基于时域差分的定位方法利用了光信号在光纤中传播的时间与距离关系，能够有效地识别和定位光纤上的振动事件。该方法简单直观，适用于实时监测和快速定位分析，并且有效的降低了系统的成本和设计的复杂程度，提高了系统的定位技术性能，其实验步骤如下：




图 2.5 信号定位原理

首先对信号预处理，从探测器输出的模拟信号通过采集卡转变成数字信号。接着为使系统的波动噪声降低，将最初的振动信号沿着曲线的长度方向做滑动平均处理。滑动平均公式如下：

$$A_j = \frac{1}{L} \sum_{l=i}^{i+L-1} t_{l,j} \quad (2.17)$$

式中， L 为移动平均线的步长， l 为每一步长的长度， $l \in (i, i + L - 1)$ 。接着对信号做定位算法处理，将原始的振动信号做纵向的累加后再平均处理，会得到一条曲线，该曲线为处理后的局部振动信号。其公式如下：

$$B = \frac{1}{N} \sum_{j=1}^N t_{i,j} \quad (2.18)$$

接着对每条曲线减掉累加平均后的曲线会获得一条新的曲线，该曲线为局部振动信号插值曲线。用下式表示：

$$\Delta t = t - B \quad (2.19)$$

通过上式可以得出 N 个差值曲线：

$$\Delta t = \{\Delta t_{i,1}, \Delta t_{i,2}, \dots, \Delta t_{i,j}, \dots, E_{i,N}\} \quad (2.20)$$

再将原始的局部振动信号依照固定的步长计算其步长以内的平均值曲线。运算完成后将每一条原始振动信号的差值曲线同一个步长内先后和其对应的平均值相减平方，累加平均计算后会得到一条差值均方曲线。用以下公式表示：

$$E_{i,j} = \left\{ \frac{1}{n} \cdot \sum_{w=n \cdot k - n + 1}^{n \cdot k} (\Delta t_{i,w} - P_{i,ave})^2 \right\} \quad (2.21)$$

其中

$$P_{i,ave} = \frac{1}{n} \cdot \sum_{w=n \cdot k - n + 1}^{n \cdot k} t_{i,w} \quad (2.22)$$

再将运算出的的各条差值均方曲线做累加平均最后会获得一条曲线如图 2.6 所示。该曲线会存在峰值，其峰值位置对应振动位置。检测该曲线上的峰值，可以定位局部振动事件的位置，从图中可以观察到振动事件的发生位置在 120 米到 125 米之间。




图 2.6 累加平均后的差值均方曲线

最后对信号进行提取。对上一步横向滑动平均处理过后的信号曲线进行数据提取，即可得到该位置的原始信号的振动时域序列，如图 2.7 所示，从图中可以得到有不同振动频率和幅度的振动时域序列。




图 2.7 原始信号的振动时域序列

2.2.2 信号的特征提取方法

1. 快速傅里叶变换频域分析法

光纤振动信号最初以时间序列的形式出现，随着时间的推移，信号的振幅和相位随着外界振动的影响而变化。这些变化通常反映了系统所受到的动态负荷或外界干扰。通过离散傅里叶变换（Discrete Fourier Transform, DFT），我们可以将这些时间变化的数据转换为频率空间，以揭示信号中的周期性特征，DFT 的表达式可以写为：

$$X(k) = \sum_{n=0}^{N-1} x(n) e^{-j \frac{2\pi}{N} kn}, \quad k = 0, 1, 2, \dots, N-1 \quad (2.23)$$

其中 N 是采样点的数量， $x(n)$ 是时间序列信号， $X(k)$ 是在频域中对应的频率成分。

DFT 的计算虽然直观，但通常计算量较大，计算复杂度为 $O(N^2)$ ，当数据量增加时，计算效率显得不足。快速傅里叶变换（FFT）是一种优化的 DFT 算法，通过减少冗余计算来缩短计算时间，从而将计算复杂度降低到 $O(N \log N)$ [56]。在使用 FFT 之后，频率域信号可通过如下公式获得：

$$X(k) = FFT(x(n)) \quad (2.24)$$

FFT 不仅能够保持 DFT 计算的精度，结果与 DFT 一致，因此在实际应用中得到广泛使用。在 Φ -OTDR（相干光纤传感技术）系统中，FFT 方法用于将采集到的离散时间信号翻转至频域，使得特定频率成分的分析变得可能。如图 2.6 所示为脚踢事件的频域波形图，在频域中我们可以观察到信号的频谱分布，分析其中包含的特定频率成分和振动模式，主要集中在低频部分，但是我们不能观察到信号的频率随时间的变化情况。为了更好地观察到信号特征分布，我们将做进一步的时频分析研究。




图 2.8 振动事件频谱图

2. 短时傅里叶变换时频分析法

由于傅里叶变换无法提供频率规律随时间变化的详细信息，在光纤传感应用中，信号通常是复杂的，并可能包含多种频率成分，所以需要进一步提高信号的特征。短时傅里叶变换（Short-Time Fourier Transform, STFT）是一种时频分析工具，它能够揭示信号在时间和频率上的变化特性，短时傅里叶变换的公式为：

$$STFT\{x(t)\} = X(t, f) = \int_{-\infty}^{+\infty} x(\tau)w(\tau-t)e^{-j2\pi f\tau} d\tau \quad (2.25)$$

其中 $w(t)$ 是窗函数，用于控制分析信号的时间范围。STFT 通过对信号进行窗口处理，使得在每个短时间段内可以获得该段信号的频率信息^[57]。具体步骤如下：如图 2.7 所示，首先选取一个合适的窗函数，对信号进行加窗处理。窗函数的选择（如矩形窗、汉宁窗等）会影响后续分析的结果文中选择的窗函数为矩形窗。然后对每个窗口内的信号执行傅里叶变换，得到该时间窗内的频谱信息，FFT 窗大小直接影响频率分辨率。窗口较大时，可以获得更高的频率分辨率，但时间分辨率下降；窗口较小时，情况相反，文中采用的窗口大小为 256。最后是窗口沿时间轴移动（称为帧移），对每个重叠的时间窗重复以上操作文中设定帧移为 1。




图 2.9 脚踢信号的时频分布图

2.3 分布式光纤振动传感事件识别方法

2.3.1 分布式光纤振动传感封闭集事件识别方法




图 2.8 分布式光纤振动传感封闭集事件识别方法原理图

如图 2.8 所示，展示了光纤振动传感器用于识别封闭集事件的方法^[58,59]。首先，我们将采集到的事件划分为训练数据集和测试数据集，并为每一类训练数据集分配相应的标签。接下来，经过预处理后的训练数据集被输入到深度学习模型中进行训练，以使模型能够学习到不同事件类型的特征与规律。训练完成后，我们将未参与训练的测试数据集输入到经过训练的模型中，模型将根据其学习到的知识为每个测试数据分配正确的标签，从而准确识别事件的类型。然而，当未知数据集被输入到已训练的模型时，由于该未知数据集中缺乏与已知类别相同的事件类型，因而没有对应的标签可供模型参考。这将导致模型输出的标签值极有可能是错误的，从而影响事件的准确识别和分类。因此，为了提高模型在此类未知情况下的适应性，接下来的研究将会探讨如何利用开集事件算法的方法，增强模型对未知数据集的识别能力，从而提高整体的系统鲁棒性和准确性。

2.3.2 分布式光纤振动传感开集事件识别方法




图 2.9 分布式光纤振动传感开集事件识别方法原理图

如图 2.9 所示, 本研究展示了光纤振动传感器在识别开放集事件中的应用方法 [60,61]。通过在训练完成的模型后增加一个开集检测算法层, 该算法层能够将模型原本输出的 N 个标签进一步转换为一个新的标签, 此新标签专门用于表示未知数据集的类别。当未知事件被输入到已经训练好的模型时, 该模型会输出一个未在训练集中出现的未知集标签。同样地, 当已知事件被输入到训练完成的模型时, 经过开集算法层处理后, 模型可以输出正确的闭集事件标签。这一设计使得模型不仅能够准确识别已知事件, 还能有效检测和分类未知事件, 从而提高了系统的鲁棒性和适应性。图中所示的具体流程如下: 首先, 训练数据集被用于训练初始模型, 生成其内部特征表示。然后, 通过引入开集算法层, 系统能够生成一个额外的标签, 用于指示输入数据是否属于训练数据集的已知类别。当新的未知事件输入时, 模型将输出一个未训练到的标签, 从而实现对未知事件的识别。对于已知事件, 开集算法层确保模型能够准确地输出相应的标签, 维持系统的准确性和可靠性。这种设计不仅提高了模型的泛化能力, 还增强了其在实际应用中的实用性。

2.4 本章小结

基于 ϕ -OTDR 系统的基本原理 (瑞利散射、OTDR 机制), 本章重点探讨分布式光纤振动传感信号的定位、处理和识别方法。时域方差定位算法和信号特征提取技术的阐述为事件识别提供了基础。深入分析了分布式光纤振动传感的封闭集和开放集事件识别方法, 提供了理论指导和技术参考, 为在开放环境下识别信号奠定基础。

第三章 分布式光纤振动传感开集事件识别系统设计

3.1 基于 Hierarchical Attention Network with Openmax 的光纤振动传感信号识别系统

本文提出了一种基于 Hierarchical Attention Network with Openmax (HANO) 分类识别模型,用于光纤振动传感系统开放集环境下的事件分类。如图 3.1 所示,该模型主要包括分布式光纤振动传感系统信号采集、HAN 分类模型训练、Weibull 模型和 MAVs 获取、Openmax 评分计算、事件分类等几个部分。第一步是数据收集。通过分布式光纤振动传感系统 (DVS) 采集不同类别的振动信号数据,将数据集分为训练集和测试集加开放集。接下来是 HAN 分类模型训练,将训练集数据输入到 HAN 模型中进行训练^[62]。通过不断的反向传播和更新权值,得到训练良好的模型后,对训练好的已知数据集进行分类。然后将分类后的样本数据输入到训练好的模型中,计算最后一个完全连接层输出的激活向量 AV_i 。将不同类别的特征平均为 n 维向量,得到平均激活向量 MAV ^[63]。同时,将测试样本输入到训练好的模型中,得到其激活向量 $AV(x)$ 。最后,计算 AV_i 与 MAV 之间的欧氏距离,并对最大距离进行威布尔拟合,得到威布尔模型,用于标定概率 w_i 。之后进行 Openmax 评分计算和事件分类。首先将 $AV(x)$ 与 MAV 之间的欧氏距离输入威布尔模型,计算第 i 类的校准概率 w_i 。然后通过计算 w_i ,得到第 i 类的校准分数 $v_i(x)$ 。此过程用于修改所有类别的 $AV(x)$ 分数。最后将每个类别的得分与 w_i 的乘积相加,得到未知类别得分,并将标定后的 $AV(x)$ 结合,形成 $N+1$ 维的最终向量。最后,通过计算最终向量得到分类概率。




图 3.1 基于 Hierarchical Attention Network with Openmax 的光纤振动传感信号识别系统

3.2 分布式光纤振动传感系统的搭建与参数指标

基于 ϕ -OTDR 原理的用于振动信号检测的光纤振动传感系统(DVS)由各种组件组成,包括窄线宽激光源、隔离器、函数发生器、驱动器、声光调制器(AOM)、两个掺铒光纤放大器(EDFA1 和 EDFA2)、滤波器、环行器、单模传感光纤、衰减器、PIN 光电探测器(PD)、数据采集卡(DAQ)和计算机(PC)。基于 ϕ -OTDR 的光纤振动传感系统结构图如图 3.2 所示^[64]。




图 3.2 基于 ϕ -OTDR 的光纤振动传感系统结构图

窄线宽激光源(NLL)发出波长为 1550.12 nm、功率为 20mW 的连续光，经声光调制器(AOM)经过隔离器调制成脉宽为 50ns 的脉冲光信号。函数发生器为 AOM 提供电压，为 DAQ 提供同步信号。脉冲光进入掺铒光纤放大器 1 (EDFA1)进行放大，提高脉冲光的峰值功率，满足光纤中长距离传输的要求。光经滤波器 1 (Filter1)过滤后，从环行器输出口进入传感光纤。瑞利背向散射光在传感光纤中产生并返回到环行器，其中在背向散射光的一个脉冲宽度内发生自干涉。当振动信号作用于传感光纤时，后向散射光的相位发生变化，导致自干扰信号发生变化。在距离传感光纤的位置 L_i 处，瑞利散射光的干涉强度是给定区域内散射中心的振幅和相位的矢量和，表示为下式：

$$\vec{E}_b(L_i) = E_0 e^{-\alpha(i-1)\Delta L} \sum_{k=1}^M \alpha_k^i e^{j\varphi_k^i} \quad (3.1)$$

式中 E_0 为入射光的电场强度， α 为传感光纤的衰减系数， ΔL 为 L_i 的长度， α_k^i 和 φ_k^i 分别为第 i 个散射区和第 k 个散射中心的振幅和相位，当振动信号作用于传感光纤时，瑞利后向散射光的强度发生变化，自干涉信号光返回环行器后注入掺铒光纤放大器 2 (EDFA2)进行二次放大。经过滤波器 2(Filter2)滤波和衰减器衰减后，信号光由 PIN 光电探测器(PD)检测。PD 将检测到的光信号转换成电信号，然后由 DAQ 采集并由计算机进行处理和分析。当脚踢、攀爬等事件发生在围栏上时，围栏随之晃动，导致围栏上多点出现振动信号，此时我们可以利用搭建好的系统对振动信号进行采集。系统关键器件参数如下：

(1) 激光器：这款激光器由丹麦的 NKT Photonics 公司制造，型号为 E15 系列，具备窄线宽特性。其工作温度范围为 15℃ 至 50℃，中心波长为 1550.12 纳米，最大

输出光功率为 40 毫瓦，线宽小于 100 赫兹，频率稳定性优于 10 兆赫，信噪比超过 50 分贝。

(2) 声光调制器：选用的声光调制器由英国的 Gooch&Housego 公司生产，型号为 T-M200-0.1C2J-3-F2S。该产品适用于 1550 纳米波长的光信号，最大耐受输入光功率为 1 瓦，具有 50 分贝的消光比，插入损耗小于 0.8 分贝，回波损耗达到 40 分贝，上升沿与下降沿时间均为 10 纳秒。其射频工作频率上限为 200 兆赫，射频功率限制在 3 瓦以内，标准输入阻抗为 50 欧姆。

(3) 掺铒光纤放大器：此设备为上海拜安公司的 M8139-20 型号，工作波长范围为 1550 纳米，输入功率可在 -3dB/mW 至 10dB/mW 之间调整，输出功率稳定性控制在 ± 0.05 分贝，最大增益为 30 分贝，最大回波损耗为 -45 分贝，工作温度范围为 0℃ 至 50℃。

(4) 光电探测器：光电探测器选用 Thorlabs 公司的 PDB410C 系列产品，采用 InGaAs/PIN 材料制造。该探测器的工作波长区间为 800 至 1700 纳米，最大响应率可达 1.0 安培/瓦，射频输出带宽为直流至 100 兆赫。在 1550 纳米波长下，连续波状态下的饱和功率为 72 微瓦，综合噪声水平为 65 纳瓦，总输出电压噪声为 2.2 毫瓦。

3.3 振动信号的定位与预处理

在本研究中，我们收集了 M 条瑞利后向散射信号，以构建如图 3.3 所示的振动信号在全空域的叠加图。红色框选区域内的信号波动幅度显著较大，这一现象表明该空间位置存在明显的信号扰动，结合瑞利散射信号对外界环境变化的敏感性，这一信号波动的增强可被推断为振动事件的发生位置。原始后向散射信号的叠加会使振动事件的空间定位模糊，因此，本章采用了在前一章中提出的时域方差定位方法来精确识别和定位原始数据中的振动信号。首先，通过对所有采集的瑞利后向散射信号进行累加平均，构建了一条平均后向散射曲线，利用该平均曲线与每一条原始散射曲线相减，生成差值后向散射曲线序列，如图 3.4 所示。我们以特定步长对这些差值曲线进行累加平均，得到差值平均曲线，通过对差值平均曲线计算方差，产生差值方差曲线。最终，对此方差曲线再次进行累加平均处理，得到如图 3.5 所示的最终方差曲线，用以精确定位振动信号的发生位置。




图 3.3 N 条瑞利后向散射曲线




图 3.4 差值后向散射曲线




图 3.5 振动信号后向散射方差曲线定位图

在完成对振动信号的定位之后，提取出该振动位置的时域信号，如图 3.6 所示，该信号为用于识别的振动事件时域信号，该信号描述了幅值随时间的变化。该信号表现出 20 秒振动事件从发生到结束的特征，经过短时傅里叶变换 (STFT) 处理，生成了一个时频分布图，该表示以频谱图的形式显示了频率成分随时间的变化。颜色刻度

表示每个时间瞬时频率分量的幅度。最后将数据转换生成了最终的时频分布图，该时频分布图使用 jet 色彩图，其颜色映射范围为[60,80]，图形分辨率为 680×540 使其在滤除背景噪声的情况下保留了振动曲线的特征。这种最终表示有助于识别原始振动信号中随时间变化的频率分量，揭示时域波形中不容易发现的信息。




图 3.6 时域信号预处理步骤

3.4 HANO 开集算法模型

3.4.1 分层注意网络模型




图 3.7 HAN 网络结构

如图 3.7 所示，分层注意网络（Hierarchical Attention Network, HAN）结构包含

四个关键模块：自注意主干模块（Swin transformer），用于提取空间注意特征序列；空间特征自组织模块（Spatial Feature Self-Organization, SFSO），旨在促进模型训练；基于长短期记忆网络（LSTM）的分层聚合模块（Hierarchical Aggregation, HA）^[65]，通过对分层重组特征间的时间关系进行建模，以学习细粒度特征表示；以及基于 LSTM 的上下文感知模块（Context-Aware, CA），用于在上下文信息的基础上，通过保存和遗忘长期记忆来增进每个分层特征映射的表征能力。HAN 的训练过程通过最小化两个损失项的加权和来实现，其中一个是基于学习空间注意机制下系列特征的空间特征分类损失项 (L_s)，另一个是基于学习细粒度分层聚合特征表示的分层注意特征分类损失项 (L_{HA})，最后将基于空间注意机制下系列特征得出的激活向量 (AV_s) 与基于学习细粒度分层聚合特征的激活向量 (AV_{HA}) 进行加权求和得到最终的激活向量。




图 3.8 空间特征自组织模块 (SFSO)

如图 3.8 所示为空间特征自组织（SFSO）模块架构旨在对分层特征进行重构，首先在 Swin transformer^[66]层将输入图像分割成多个小块，通过线性嵌入层获得潜在特征，然后通过空间自注意操作，将这些特征通过四个集成块传递。这四个块然后将这些特征映射通过最大池化层进行降维处理。随后将具有交叉关注的具有层次空间特征传递给卷积层以获得统一尺寸的特征映射。然后将这些特征映射通过最大池化层进行降维处理。再将具有交叉关注的高层块特征与低层块特征进行聚合，以进一步增强特征表示能力。为了确保 SFSO 模块中所有重新组织的特征具有相同的尺寸，使

用四个卷积块，每个块都设计有不同的卷积层（Conv）和批归一化层（BN）的排列，以方便特征映射的处理^[67]。这些块按顺序工作，应用卷积操作，然后进行批归一化，确保有效提取和增强分层特征。卷积块的相应配置如图 3.8 中所示。

在经过卷积层后得到的特征分别经过最大池化层传递。为了提高特征的可辨识度，将来自较高块和较低块的特征池进行聚合，并进行多重交叉关注。每个交叉关注在两个不同的特征上实现，用于特征融合。具体而言，在交叉注意机制中，从两个不同的特征中计算出 Q（查询）、K（键）和 V（值）向量，分别表示为 $\{Q_1, K_1, V_1\}$ 和 $\{Q_2, K_2, V_2\}$ ，以确保一般性，与之相关的交叉注意力可用以下公式表示：

$$\frac{\text{Softmax}(\frac{Q_2 K_1^T}{\sqrt{256}})V_1 + \text{Softmax}(\frac{Q_1 K_2^T}{\sqrt{256}})V_2}{2} \quad (3.2)$$

其中 $\text{Softmax}()$ 是归一化指数函数^[68]，它将向量归一化为 $(0, 1)$ 。




图 3.9 分层聚合模块(HA)结构

如图 3.9 所示，分层聚合模块（HA）旨在从分层重组的特征中提取细粒度特征，主要由一个 4 阶矩的单层 LSTM 组成^[69]。它利用 LSTM 对这些重组特征之间的层次关系进行建模，将低层次的重组特征与高层次的重组特征聚合在一起。聚合后的特征作为最终的分层特征表示。该模块的架构如图 3.10 所示。




图 3.10 LSTM 模块和上下文感知（CA）模块的体系结构

如上图所示，Context-aware (CA) 模块作为 LSTM 的遗忘块实现，用于有选择地保存/遗忘来自内存单元的信息。在本模块中，采用另一个 LSTM 对 SFSO 模块中间过程中得到的每个尺寸统一的层次特征映射进行上下文关系建模^[70,71]。CA 模块包含三个输入：前一个 HA 模块的 Hidden，以及通过在像素级拆分当前特征图获得的特征切片（contextual feature slices），输出一个 soft mask，其元素范围限制为 (0, 1)，以及用于屏蔽 HA 模块的 Cell 状态，该模块的架构如图所示。从图中可以观察到，该模型采用单层 LSTM 结构，接收经过重组的特征作为输入。通过展开的 LSTM 单元包括一个(长期)记忆单元（用于在 4 个 Cell 状态下保留全局记忆），以及 3 个块（输入/输出/遗忘块），用于确定添加/导出/删除内存中哪些信息。前一刻的输出被视为隐藏状态，而最后时刻的输出则被用作进行分类任务时的精细特征表示。此外，初始 Cell 块和 Hidden 块是实例自适应向量，在最后时刻从输入特征中映射得到，以加速模型训练。在遗忘模块中使用另一个具有 n 个矩阵（ n 为特征图中的像素数）的单层 LSTM 将三个输入转换为最终生成 soft mask。该 LSTM 单元采用标准形式结构，并且其初始 Cell 和 Hidden 状态是随机化的^[72,73]。LSTM 当前时刻接收到一个特征序列作为输入，在此序列中每个分裂特征与 HA 模块之前计算得到隐藏状态相连接，并且该 LSTM 输出与 HA 模块输入特征相连接。通过一个 FC 全连接层和一个 sigmoid 层，将连接的特征转换成最终的 soft mask。最后我们将得到的 soft mask 与 Swin Transformer 层输出的 soft mask 进行加权相乘得到我们最终的激活向量。

3.4.2 Openmax 算法

在本节中,我们将介绍用于处理开集分类任务的 Openmax 方法^[74],该方法将 HAN Model 相结合。假设模型有 N 个类别输出,通过 HAN 模型的最后一个全连接网络层的样本输出的 N 维向量称为激活向量(AV)。首先,使用不包含未知类别样本的训练数据集对模型进行训练,得到预训练的 HAN 模型。然后,使用训练好的模型对训练数据集中的第 i 类样本进行识别,得到 m 个正确分类的样本AV,长度为 N ,可由下式表示:

$$AV_i = \{av_1, av_2 \dots av_m\} \quad (3.3)$$

然后对AV求平均,得到MAV;

$$MAV_i = \text{mean}(av_1, av_2, \dots av_m) \quad (3.4)$$

为了衡量其向量间的差异来区分不同类型的事件,这里用欧氏距离来反映不同事件之间的差异,在第 i 类中,MAV和av的欧氏距离可以表示为:

$$dist_j = \text{Euclidean}(MAV_i, av_j) \quad (3.5)$$

在Dist中 n 个极值样本,作为拟合威布尔模型的数据集,可用如下公式表示:

$$\overrightarrow{Dists_i} = \text{sort}(Dist_i)_\eta \quad (3.6)$$

其中 $\text{sort}()_\eta$ 表示从最大到最小排序并选择 η 个最大元素, η 表示 tailsize。使用Dists对 i 类进行Weibull Model的拟合后得到如下公式:

$$\text{Weibull Model}_i(\tau_i, k_i, \lambda_i) = \text{Fithigh}(\overrightarrow{Dists_i}, \eta) = 1 - e^{-\left(\frac{\|x - \tau_i\|}{\lambda_i}\right)^{k_i}} \quad (3.7)$$

之后计算 Openmax 分数,首先将测试样本 x 输入训练好的模型,计算其激活向量AV(x):

$$AV(x) = \{v_1(x), \dots v_i(x) \dots, v_N(x)\} \quad (3.8)$$

计算欧氏距离(x),介于AV(x)和MAV之间,然后将距离 $dist(x)$ 输入到威布尔模型中,为得到修正后的第 i 类概率,

$$w_i = 1 - \frac{\alpha - i}{\alpha} e^{-\left(\frac{\|dist_i(x) - \tau_i\|}{\lambda_i}\right)^{k_i}} \quad (3.9)$$

计算所有类别的AV(x)与MAV之间的距离,并将其输入到相应的威布尔模型中,得到标定概率 $W(x)$;

$$W(x) = \{w_1, w_2, \dots, w_N\} \quad (3.10)$$

使用 $(1 - w_i)$ 作为校准参数，对分数 $v_i(x)$ 进行修正，得到第 i 类的 Openmax 分数，

$$v_i(x) = v_i(x) * (1 - w_i) \quad (3.11)$$

通过对 $AV(x)$ 和 $W(x)$ 进行点乘，计算未知类别的 Openmax 分数，然后将这一分数与修正后的 $AV(x)$ 拼接，形成一个长度为 $N + 1$ 的最终向量：

$$\hat{v}_{N+1}(x) = AV(x) * W(x) \quad (3.12)$$

$$AV(x)_{final} = \{\hat{v}_1(x), \dots, \hat{v}_N(x), \hat{v}_{N+1}(x)\} \quad (3.13)$$

3.4.3 HANO 模型训练模式

在本节中，我们将介绍 HANO Model 的训练模式。HANO 方法采用联合分类损失函数进行训练，并采用基于阈值的策略进行推理。使用的联合分类损失函数包含两个损失项，分别是 Swin Transformer 分类损失项 L_s 和 HAN Model 分类损失项 L_{HA} 。 L_s 用于衡量 Swin transformer 在预测与基础事实之间的差异。该损失项通过传统的交叉熵损失来鼓励主干模块在空间自注意机制下学习一系列特征，可用如下公式表示：

$$L_s = -\frac{1}{N} \sum_{i=1}^N \log p_i \quad (3.14)$$

上式中 N 为批大小， p_i 为 Swin transformer 输出的分类分数通过实现 SoftMax 层得到的分类概率。

HAN 分类损失项（ L_{HA} ）用于评估 HAN Model 在预测与基础事实之间的差异。该损失项旨在促进 HA 模块学习更细粒度的分层聚合特征表示。在此， L_{HA} 同样采用交叉熵损失函数可以表示为：

$$L_{HA} = -\frac{1}{N} \sum_{i=1}^N \log q_j \quad (3.15)$$

上式中， q_j 是根据 HAN Model 输出的分类分数计算出的相应分类概率。

总联合分类损失函数 L 为 L_s 与 L_{HA} 的加权和：

$$L = L_s + \lambda L_{HA} \quad (3.16)$$

将 (3.13) 式得到的最终向量输入 sigmoid 函数，得到每个事件的分类概率

$$F(x) = \left\{ \frac{1}{1+e^{-v_1(x)}}, \frac{1}{1+e^{-v_2(x)}}, \dots, \frac{1}{1+e^{-\hat{v}_{N+1}(x)}} \right\} \quad (3.17)$$

如果未知样本的分类概率低于阈值，则归类为未知类别，否则归类为已知类别之一，预测值可由下式表示：

$$prediction = \begin{cases} \operatorname{argmax}_{k \in \{1, 2, \dots, k\}} F_k & \text{if } \max\{F_k\} > threshold \\ unknown \text{ classes} & \text{if } \max\{F_k\} < threshold \end{cases} \quad (3.18)$$

3.4.4 其他网络模型

为了进一步对 HANO 模型性能的验证，本课题选了多组模型进行开集识别对比，包括 Swin transformer、YOLOv5、一维残差卷积网络 1D-ResNet CNN。下面主要介绍这两种模型的结构框架。

(1) Swin transformer




图 3.11 Swin transformer 结构

Swin Transformer 通过层次化的特征提取和自注意力机制，能够有效地捕捉图像中的空间特征，进而提升模型在视觉任务中的表现。如图 3.11 展示了 Swin Transformer 的整体架构 [75]，该模型在图像分类、目标检测和语义分割等领域展现出了优异的

性能。以下是对该图主要组成部分的详细分析：在输入阶段，图像首先被划分为固定大小的小块（例如 224x224 或 256x256 像素），这一步骤称为“Patch Partition”。这种处理方式使得输入图像可以被视作一个序列，从而符合 Transformer 网络的输入需求。每个小块通过映射形成一个向量表示，便于后续的特征学习。图 3.11 中的 Block 部分包括多个 Transformer 块（Block 1 至 Block 4），这些模块是 Swin Transformer 的核心组成部分。Swin Transformer 是通过将 Transformer 块中的标准多头自关注(MSA)模块替换为基于移位窗口的模块而构建的，其他层保持不变。

如图 3.11 所示，Swin Transformer 模块由一个基于移位窗口的 MSA 模块组成，其次是一个 2 层 MLP，中间是 GELU 非线性。在每个 MSA 模块和每个 MLP 模块之前应用一个 LN(LayerNorm)层，在每个模块之后应用一个残余连接。每个 Transformer 块都实现了空间自注意力机制，这使得模型在计算自注意力时，仅关注相邻的小块，大幅度降低了计算复杂度，同时保持了特征间的局部相关性。在特征提取完成后，最后一层将特征向量输入到一个线性分类器 Linner。该分类器的目的是将提取到的高层特征映射到类别空间，以完成最终的分类任务。

（2）YOLOv5 模型

YOLOv5 是一种最先进的目标检测模型，在对象检测不是主要目标的某些场景中，可以通过利用其内部组件来重新利用 YOLOv5 进行分类^[76]。YOLOv5 分类模型在输入端使用 Albumentations 数据增强。首先将图像调整到指定的大小，然后进行随机裁剪、水平翻转、颜色抖动和像素归一化操作。随后将处理后的图像输入到分类模型中进行训练。如图 3.12 所示，YOLOv5 分类模块的主要结构包括 Conv 模块和 C3 模块。




图 3.12 YOLOv5 网络结构

Conv 模块用于特征提取和特征映射组织，相应配置如上图中所示（k 表示 kernel size，s 表示 stride，p 表示 padding，c 表示 channel）。自动计算 Conv2d 层的填充，通过修改步长确定特征图的降采样因子。在主干中，所有 Conv 模块的步长为 2，内核大小为 3。因此，每个 Conv 模块将特征图的宽度和高度减半，在提取目标特征的同时对特征图进行降采样。BatchNorm2d 是一个批处理规范化层，用于规范化每个批处理的数据。SiLU 是一个将非线性引入数据的激活函数。Conv 模块可以提取特征并组织特征映射。它完成了特征图上的降采样、降维、归一化和非线性等任务。

C3 模块由三个 Conv 模块和一个瓶颈模块组成。feature map 进入 C3 模块后，会被分成两条路径。左边的路径经过 Conv 模块和瓶颈模块，而右边的路径只经过 Conv 模块。最后，将两个路径的输出连接起来，并通过另一个 Conv 模块传递。C3 中的 3 个 Conv 模块均为 1x1 卷积，在降维或扩维方面有一定作用，但在特征提取方面意义不大。在骨干网络中，瓶颈模块使用了一个剩余连接。瓶颈模块由两个 Conv 模块组成。第一个 Conv 模块是一个 1x1 卷积，将通道数量减少了一半，而第二个 Conv 模

块是一个 3x3 卷积，将通道数量增加了一倍。最后，利用残差结构将输入输出加在一起，避免了梯度消失的问题。

YOLOv5 模型输出端包含 Conv、AdaptiveAvgPool2d、Dropout 和 Linear 等层，它们将输出分为 4 类。Conv 层接收输入特征映射，并使用 1x1 卷积核将其压缩为 1280 维特征向量。该层使用 BatchNorm2d 进行批处理归一化，使用 SiLU 激活函数进行非线性变换。AdaptiveAvgPool2d 层可自适应将输入特征映射的大小缩放为 1x1，用于全局平均池化。在全局平均池化后，Dropout 层将 50% 的特征向量丢弃，以防止过拟合。最后，将特征向量映射到 3 个输出类别。

(3) 1-D ResNet 模型




图 3.13 1-D ResNet 网络结构

如图 3.13 所示为基于残差学习的深度卷积神经网络 (ResNet) 结构，该模型可以解决深层网络中的梯度消失问题并提高模型的性能。ResNet 的网络结构可以分为以

下几个主要部分：首先是输入层与初始处理，网络的输入为经过预处理的原始数据，首先通过一个卷积层（Conv），使用 1×3 的卷积核进行特征提取，步长为 1。此后，数据经过批量归一化（BatchNorm1d），以加速训练过程和提高模型的稳定性。网络包含多个残差块，每个块由两个连续的卷积层组成，卷积块的相应配置如图中所示（ k 表示 kernel size， s 表示 stride， p 表示 padding， c 表示 channel）。每个卷积层后接有一个批量归一化层和一个 ReLU 激活函数。每个块的输出与输入之间添加残差连接（ResidualBlock），残差块的结构如图所示，以确保信息的有效传递和梯度的顺畅流动。每个残差块后接一个最大池化层（MaxPool1d），池化核大小为 2，步长为 2，用于降维和减少计算复杂度。在卷积完成后使用了平均池化层（AvgPool1d），在网络的深层部分进一步压缩数据。在网络的末端，我们引入丢弃层（Dropout1d）来防止过拟合，通过随机丢弃一部分神经元来提高模型的泛化能力。最后，数据通过多个全连接层（Linear）进行处理，逐步减少特征维度，并最终映射到分类任务的输出空间。网络的最后一层是一个线性层，输出节点数等于类别数，结合 softmax 函数用于多类别分类。该 ResNet 结构通过残差连接的引入，显著减少了训练深层网络时梯度消失的问题，同时保持了模型的学习能力。整个网络采用了 RELU 作为激活函数，有效地引入非线性，增强了模型的表达能力。通过在网络中加入批量归一化和丢弃层，进一步提高了模型的训练效率和泛化性能。

3.5 本章小结

本章设计了基于 Hierarchical Attention Network with Openmax 的光纤振动传感信号识别模型。阐述分布式光纤振动传感系统的搭建过程及其关键参数指标，以确保系统稳定性和可靠性。随后，讨论振动信号的定位与预处理步骤，详细描述了分层注意网络（HAN）模型的构建和 Openmax 算法原理，并引入 YOLOv5 和 ResNet 模型作为参考对比，为分布式光纤振动传感技术的系统设计提供全面的理论基础和实践指导。

第四章 振动信号采集与模型性能测试

4.1 实验装置搭建

在本实验中，我们使用了一个窄线宽激光源，工作波长为 1550.12nm，光功率为 20mW。为了产生脉冲光信号，我们采用声光调制器组产生频率为 4000Hz，脉冲宽度为 50ns。然后这些信号被注入到传感光纤中。在我们的设置中使用的传感光纤总长度为 1860 m。在距离传感光纤 100m 的地方安装了一个高 3 米、宽 2 米的围栏。在栅栏上，以 S 形模式布置了一段 24 米长的传感光纤，垂直间距为 25 厘米。传感光纤的终端端放置在防水隔离箱内，以消除任何外部信号干扰。实验装置如图 4.1 所示。




图 4.1 实验装置图

4.2 区域振动信号定位与采集

对于围栏区域数据采集，我们采用采样率为 500 MHz 的采集卡。每组信号的采样时间为 20 秒，总共收集了 80,000 个数据点。首先我们对围栏区域的信号进行定位，当振动事件发生在围栏上时，收集 80000 条原始后向瑞利散射曲线叠加曲线如图 4.2 所示：




图 4.2 80000 条原始后向瑞利散射曲线叠加曲线

在采集过程中，围栏上的事件发生时，整个围栏会随之产生晃动。图 4.2 展示了光纤传感系统采集到的瑞利后向散射信号曲线。在距离光纤入口 90m 至 115m 的范围内，信号的稠密程度明显高于其他位置。这种由于外部振动所引起的扰动与原始瑞利散射信号叠加，使得振动事件的精确定位变得复杂。为提高定位精度，本研究采用了时域方差算法来处理包含振动信息的瑞利散射信号。图 4.3 和图 4.4 分别展示了该算法处理后所得到的振动信号定位曲线。




图 4.3 围栏区域振动信号定位曲线




图 4.4 围栏区域振动信号定位曲线放大图

如图 4.4 显示，在距离光纤前端 $103\text{m} \pm 13\text{m}$ 范围内，检测到的振动信号幅值显著高于背景噪声水平（即无扰动区域的信号强度）。鉴于系统光脉冲脉宽为 50ns ，对应空间分辨率约为 5m ，观察到的振动信号并非局限于单一点，而是呈现出约 25m 的分布范围。此现象与围栏与路基连接不牢固的实际情况相符。当围栏受到拍打或脚踢等外力作用时，其结构整体发生晃动，导致沿围栏分布的多个传感点同时产生振动响应，从而形成空间上扩展的振动信号分布。

4.3 信号预处理与数据集分配

在实验过程中，我们收集了七种类型的信号：摇晃(shaking)、锯网(sawing)、攀爬(climbing)、树枝触碰(branch)、手摸(finger)、脚踢(kicking)、风雨(storm)。如表 4.1 所示，对摇晃、锯网、攀爬、风雨这信号各记录了 1000 组，对手摸、树枝触碰、脚踢信号各记录 1000 组，共计 7000 组信号。在实际应用环境中，光纤传感系统在周界安防、管道监测等实际应用场景中，往往面临显著的环境温度波动（日温差可达 $20\text{--}30^\circ\text{C}$ ）及其他环境干扰。实验数据本身包含了丰富的环境变化因素：数据采集跨越不同时段（早/中/晚）包含了日均温度变化的影响，以及不同天气伴随的温度、湿度等气象参数的自然波动。通过附加温度传感器记录发现，室外部署的光缆在昼夜交替过程中经历了约 15°C 的温度变化范围。在本研究中，未对实验环境中的温度等外部因素施加严格控制。在数据采集阶段，我们系统性地涵盖了多种自然环境条件（包括晴/阴天、昼/夜时段、有/无微风等气象组合），以此获取具有环境多样性的振动信号数据集。这种基于真实环境下的训练策略能够有效增强模型在实际应用中应对复杂环境扰动的泛化能力，从而显著降低因实验室条件过度标准化而导致的“实验室-现

场偏差”风险。本实验选取摇晃、锯网、攀爬、脚踢信号作为已知事件，其中随机选取 80%的数据作为训练集，剩余 20%的数据作为测试集。选取手摸、树枝触碰、风雨这些事件作为未知事件，其中随机选取 20%作为测试集，未知事件不参与模型训练如表 4.1 所示。其七种不同的振动原始信号如图 4.5 所示。

表 4.1 七种不同的振动信号数据分配

事件类型	事件	训练数据集	测试数据集
已知事件	摇晃	800	200
	锯网	800	200
	攀爬	800	200
	脚踢	800	200
未知事件	手摸	0	200
	树枝触碰	0	200
	风雨	0	200




图 4.5 七种信号原始波形图(a) 脚踢;(b) 摇晃;(c) 攀爬;(d) 锯网;(e) 手摸;(f) 树枝触碰;(g) 风雨

然后对每类信号进行时频处理，获得时频分布图，如下图所示。




图 4.6 七种信号的时频分布图(a)脚踢;(b) 摇晃;(c)攀爬;(d)锯网;(e) 手摸;(f)树枝触碰;(g)风雨

4.4 模型性能测试与对比

4.4.1 闭集网络分类测试

我们首先选取 Swin transformer、HAN、YOLOv5、1-D ResNet 模型进行闭集训练以及测试，总共收集了四种类型的数据用于模型的训练和验证，每种类型的数据各 1000 条，训练样本和测试样本按照 8: 2 的比例随机抽取。




图 4.7 模型训练准确率(a)Swin transformer; (b)HAN; (c)YOLOv5; (d)1-D ResNet




图 4.8 模型训练损失值(a)Swin transformer; (b)HAN; (c)YOLOv5; (d)1-D ResNet

如图 4.7 所示，Swin Transformer 的准确性在训练初期快速提升，并在第 10 轮左右达到了约 90% 的高水平。在第 20 轮后，准确性趋于平稳，表明模型已经部分收敛。这种较快的收敛速度表明 Swin Transformer 在特征提取和信息融合方面的表现较为优秀，能够迅速捕捉到数据中的有效信息。HAN 的准确率在前 10 轮中迅速上升，随后在 20 轮内也接近 90% 的水平，表现略逊于 Swin Transformer，但仍显示出良好的学习能力。HAN 的准确性在训练的后期阶段趋于平稳，表明其有效地学习了样本特征，并具备一定的泛化能力。YOLOv5 的准确率在前期训练中变化较大，不如 Swin Transformer 和 HAN 增长迅速。虽然 YOLOv5 在训练后期有所提升，但整体波动较

大,说明在训练过程中对任务适应性较差。1-D ResNet 的准确率波动幅度较小,仅在后期总体准确率偏低在 96%左右。如图 4.8 所示,在损失值方面,Swi n Transformer 的损失值随着训练轮次的增加而持续减小并趋于平稳,表明模型在减少训练误差方面表现出色。HAN 的损失值同样随着训练的进行而下降,与 Swi n Transformer 相比损失值下降的速度略慢,但仍显示出较为稳定的优化趋势,表明其能有效捕捉特征。YOLOv5 的损失值在训练初期呈现出较大的波动,显现出模型在训练过程中的不稳定性,虽然在训练的后期损失值有所降低,但仍限制了其在实际应用中的效果。1-D ResNet 的损失值下降波动明显,初期损失较高,且后期降幅不明显,损失值虽然在训练后期逐步减少,但整体的下降趋势不如其他模型显著,可能影响了其预测性能。总的来说,当 Swi n transformer、HAN 两种模型的训练轮数达到 25 以上时,准确率接近 100%并且损失值别的性能上都非常优秀,闭集准确率变化相差不大,损失值的下降趋势也相差不大。YOLOv5 模型的准确率和损失值随训练步骤的增加不平稳但最高值在 99%以上,1-D ResNet 模型的准确率和损失值趋于平稳但整体准确率偏低。初步结果表明,Swi n transformer 和 HAN 模型在闭集识别效果上优于其他两个模型。




图 4.9 四个已知事件的激活向量散点图: (a)Swi n transformer; (b)HAN model; (c)YOLOv5; (d) 1-D ResNet

如图 4.9 所示，我们展示了四个不同模型的激活向量散点图分布，分别为 Swin Transformer(a)、HAN model(b)、YOLOv5(c)和 1-D ResNet(d)。在该散点图中，X 轴、Y 轴、Z 轴分别表示模型输出最后一层激活向量中每种事件在三个不同维度上的特征值大小。每个点代表一个事件实例，其空间位置由对应事件在这三个特征维度上的值确定。通过三维空间的分布，可以直观地观察不同事件类别在特征空间中的分布模式及其相互之间的关系。若不同类别的事件在空间中表现为明显分离的聚类，则表明模型能够有效区分这些类别，若类别间的分布存在分散或重叠，则可能反映出模型对该类别区分的不足。Swin Transformer 的散点图显示了四种事件的分布情况。可以观察到，每种事件的激活向量点较为集中地分布在各自的空间区域内，表明 Swin Transformer 在这些事件上的分类效果较为显著。HAN model 的散点图与 Swin Transformer 的分布相似。四种事件的激活向量点也较为集中地分布在各自的空间区域内，进一步验证了 HAN model 在事件识别和分类上的高效性。YOLOv5 的散点图揭示了四种事件的分布虽然也各自占据了特定的空间区域，但每个事件的点分布较为分散。这表明 YOLOv5 在事件分类上可能存在较大的不确定性和较低的区分度。1-D ResNet 的散点图显示了四种事件的激活向量点在各自的空间区域内分布较为集中，但整体上缺乏足够的分散性，导致不同事件之间的界限不够清晰。综上所述，Swin Transformer 和 HAN model 在四个事件上的闭集分类性能表现优异，激活向量点分布集中且具有较好的区分度。相比之下，YOLOv5 的分类效果受限于激活向量的分散性，而 1-D ResNet 尽管在每个事件上的点分布集中，但整体分类效果因缺乏空间扩散性而受到一定影响。通过这些散点图的分析，我们可以得出结论：Swin Transformer 和 HAN model 在事件识别和分类任务上具有更强的性能表现。




图 4.10 四种模型闭集事件分类最好结果的混淆矩阵: (a)Swin transformer; (b)HAN model; (c)YOLOv5; (d)1-D ResNet

在图 4.10 中，展示了四种不同模型在分类任务中的混淆矩阵，包括 Swin Transformer (a)、HAN 模型 (b)、YOLOv5 (c) 和 1-D ResNet (d)。每个子图的横轴和纵轴分别表示预测类别和实际类别，矩阵中的每个元素表示对应类别的样本数量。(a)图中 Swin transformer 在所有类别上均表现出较高的分类准确率，锯网、攀爬、脚踢事件存在极少量的混淆，总的准确率在 99.63%，表现出了较高的分类性能。(b)图和(c)图中，HAN 模型和 YOLOv5 的分类性能同样优秀，HAN 模型对锯网和攀爬事件存在少量的混淆，总体分类准确率在 99.63，YOLOv5 模型只有摇晃事件存在少量混淆，总体分类准确率在 99.75%。(d)图中 1-D ResNet 的分类性能相对较差，尤其是对攀爬和摇晃事件出现了一定的混淆，说明在特征提取方面可能存在不足。综上所述，通过对比四个模型的混淆矩阵，可以看出 Swin Transformer 和 HAN 模型在大多数类别上表现较好，错误分类样本较少。YOLOv5 模型同样表现出色，但在散点分布图上的表现不够优越。1-D ResNet 模型在“攀爬”和“摇晃”类别上表现较差，错误分类样本较多。

4.4.2 开集分类测试

在机器学习与统计学的领域，评估分类模型的性能是至关重要的。常用的评价指标之一是 AUROC（Area Under the Receiver Operating Characteristic Curve），以及相应的 OSCR（Optimized Score Classification Rate）。

ROC 曲线是评估分类模型性能的重要工具，而其下方的面积（AUROC）则为衡量模型区分正负样本能力的标量指标。AUROC 的计算涉及以下几个步骤：首先，针对二分类模型，需确定其在不同阈值下的真正率（True Positive Rate, TPR）和假正率（False Positive Rate, FPR）。TPR 可以通过以下公式计算：

$$TPR = \frac{TP}{TP + FN} \quad (4.1)$$

其中， TP 表示真正例（True Positives）， FN 表示假负例（False Negatives）。假正率的计算公式为：

$$FPR = \frac{FP}{FP + TN} \quad (4.2)$$

其中， FP 表示假正例（False Positives）， TN 表示真负例（True Negatives）。在多组不同的阈值下，绘制 TPR 与 FPR 的关系图，从而形成 ROC 曲线。AUROC 的计算可通过数值积分的方法进行，如梯形法则，具体公式为：

$$AUROC = \int_0^1 TPR(FPR) dFPR \quad (4.3)$$

或者在离散型数据情况下，可以通过以下形式近似计算：

$$AUROC = \sum_{i=1}^{n-1} (FPR_{i+1} - FPR_i) \cdot \frac{TPR_i + TPR_{i+1}}{2} \quad (4.4)$$

其中， n 为不同阈值的数量。AUROC 值范围在 0 到 1 之间，值越靠近 1 表示模型的分类性能越好，而值为 0.5 则表示模型性能相当于随机猜测。

OSCR 强调在特定操作条件下模型的表现，计算时注重 Precision（精确率）与 Recall（召回率）之间的平衡。Precision（精确率）与 Recall（召回率）的计算公式如下：

$$Precision = \frac{TP}{TP + FP} \quad (4.5)$$

$$Recall=TPR \quad (4.6)$$

OSCR 的定义和 AUROC 相似，其计算侧重于特定决策阈值下的表现。OSCR 的面积计算为：

$$OSCR_AUC = \int_0^1 Precision(Recall)dRecall \quad (4.7)$$

对于离散情况，OSCR 的计算可表示为：

$$OSCR_AUC = \sum_{i=1}^m (Recall_{i+1} - Recall_i) \times Precision \quad (4.8)$$

在分类模型中，Accuracy（准确率）也是一个常用的性能指标，用于衡量模型的总体预测能力。准确率的计算公式为：

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (4.9)$$




图 4.11 四个已知事件和未知事件的激活向量散点图: (a)Swin transformer; (b)HAN model; (c)YOLOv5; (d) 1-D ResNet

如图 4.11 所示，展示了四种不同模型的已知事件与未知事件的激活向量散点分布图，包括 Swin Transformer（图(a)）、HAN 模型（图(b)）、YOLOv5（图(c)）和一

维 ResNet（图(d)），X、Y、Z 轴分别表示事件激活向量的三个维度。从图中可以清晰地观察到，各种已知事件的激活向量均聚集在其各自的特定空间中。蓝色点、红色点、黄色点、绿色点和灰色点分别表示锯网、摇晃、脚踢、攀爬及未知事件。在图(a)中，Swin Transformer 模型的四种已知事件的激活向量明显聚集于各自的空间域内，且与未知事件的重合度较低，表明其具备良好的分类性能。图(b)所示的 HAN 模型同样展现出卓越的分类性能，已知事件与未知事件均有效聚集在各自的空间域中，进一步验证了其在分类任务中的有效性。与此形成对比的是，图(c)中 YOLOv5 模型的激活向量显示出较为分散的特征，且与未知事件的重合度较高，提示该模型分类性能较为欠缺。图(d)中一维 ResNet 的各个事件激活向量虽有一定聚集性，但相互之间的重合度较高，这同样表明该模型在分类任务上的性能不足。综上所述，HAN 模型与 Swin Transformer 模型在分类性能上表现最佳且最为接近。为了对这两个性能更优的模型进行更为深入的比较，我们引入了 AUROC 作为评估标准。




图 4.12 Swin transformer 和 HAN 模型训练结果 AUROC 随训练轮数分布图

如图 4.12 所示横轴表示训练的轮次（Epoch），纵轴表示模型的 AUROC，以百分比形式呈现。该图展示了两种模型的性能变化：Swin Transformer 模型和 HAN 模型。随着训练轮次的增加，两个模型的 AUROC 值均趋于稳定，表明在经过一定的训练轮次后，模型的性能不再显著提高。HAN 模型的 AUROC 值在大部分训练过程中高于 Swin transformer 模型，尤其是在前 50 个轮次内，其性能提升幅度较为明显。这表明 HAN 在该任务中的表现优于 Swin Transformer 模型。在训练的后期阶段，两者的 AUROC 值均保持在接近 97% 的高水平，显示出良好的模型稳定性。总的来说，HAN 模型分类性能更加优越。

表 4.2 不同模型的开集识别结果比较

模型	AUROC%
HAN	97.56
Swin transformer	97.08
YOLOv5	84.60
1-D ResNet	68.60

如表 4.2 所示为四种不同模型的开集识别结果, HAN 模型表现优异, 其 AUROC% 为 97.56, 该模型在区分正负样本方面具有极高的能力。Swin Transformer 模型的性能同样优秀, AUROC% 为 97.08。YOLOv5 的 AUROC% 为 84.60, 尽管未能达到前两者的水平, 但仍展示了其相对较好的分类性能。1-D ResNet 的开集分类精度较低, 其 AUROC 为 68.60%, 远低于其他三种模型。因此, 初步结果表明, HAN 模型在开集测试中的性能更为出色。接下来将对 HAN 模型做具体分析。

本文通过对 HAN 模型与 Openmax 算法结合以提高开集分类精度, 为了对 HANO 模型进行进一步的评估, 我们继续做了不同模型参数下 AUROC 和 Accuracy 大小的实验分析。Tailsize 和 threshold 是 Openmax model 的两个关键参数, 它们直接影响 HAN-Openmax 模型的分类精度。Tailsize 会直接影响 Weibull model 的拟合效果, threshold 会影响模型分类的效果。




图 4.13 HANO 模型不同 tailsize 下 AUROC 随训练轮数的变化图

如图 4.13 所示为 AUROC 在不同的 tailsize 的情况下随着随训练轮数变化的曲线。从图中我们可以看出, 当 tailsize 一定时, AUROC 随着训练轮数的增加而增加, 最高值在 98.5% 以上, 在训练轮数达到 60 时 AUROC 的值趋于平稳状态。在 AUROC 的值趋于平稳时, 此时模型的训练已经达到的很好的效果, 从图中我们可以看出, 不同 tailsize 的情况下 AUROC 值也会有所不同, AUROC 值会随着 tailsize 的值升高而增加, 其中 tailsize 为 5 时 AUROC 值最高, tailsize 为 30 时 AUROC 值最低。




图 4.14 HANO 模型不同 tailsize 上准确度随阈值(threshold)的变化

如图 4.14 所示为所有事件的分类准确率在不同的 tailsize 下随着阈值(Threshold)变化的曲线。从图中我们可以看出,准确率随着 threshold 的上升而上升,其中 threshold 在 0.99 到 1 的时候准确率上升最为明显,此时 tailsize 的值越小准确率上升最高, tailsize 为 5 时, threshold 为 0.999 时准确率最高,为 95.71%,此时模型对开集事件的识别效果最好。




图 4.15 HANO 模型不同 tailsize 下的混淆矩阵图

为了进一步分析开集分类情况,我们绘制了最优 threshold 下的不同 tailsize 的混淆矩阵,如图 4.15 所示。从图中我们可以观察到,随着 tailsize 值的增加,未知事件的正确识别个数在增加,但是已知事件的误判率会增加,总的误判率依然在增加。通过对混淆矩阵的分析,可以观察到所有四个已知事件均部分误分类为未知事件类别。其中攀爬事件的误分类率最高,这是由于在数据收集过程中攀爬活动的分布不均,导

致特征分布更为分散。此外，未知事件的误分类主要集中在攀爬和踢腿事件类别。这一现象的产生是因为手部接触和踢腿事件在未知事件中具有相似的低频分布，而树枝和攀爬事件则在高频成分上表现出类似的特征。为了进一步分析不同 `tailsize` 下的识别精度，我们绘制了以下表格如表 4.3 所示。

表 4.3 HANO 模型不同 `tailsize` 下开集识别结果对比

Tailsize	AUROC/%	OSCR/%	Accuracy/%
3	98.75	98.06	95.21
5	98.84	98.09	95.71
10	98.69	97.86	95.14
15	98.55	97.79	94.71
20	98.33	97.27	94.42
30	98.23	97.14	94.35

该表格显示了不同 `tailsize` 对模型性能的影响，评估指标包括 AUROC、OSCR、以及准确率（Accuracy）。从表中结果可以看出，随着 `tailsize` 的增加，AUROC 值呈现轻微下降趋势。从 3 到 30 的 `tailsize`，AUROC 值从 98.75 逐渐减少到 98.23。在 `tailsize` 为 30 时，AUROC 值下降最为明显，减少了 0.52 个百分点。尽管如此，各 `tailsize` 下的 AUROC 值均保持在较高的水平，表明模型在区分不同类别方面具有良好的能力。OSCR 值的变化趋势与 AUROC 类似，显示出了一个较明显的下降趋势。从 98.06（`tailsize` 为 3）到 97.14（`tailsize` 为 30），OSCR 值总共下降了 0.92 个百分点。准确率的变化趋势与 AUROC 和 OSCR 类似，但下降趋势更为显著。从 95.21（`tailsize` 为 3）到 94.35（`tailsize` 为 30），准确率下降了 0.86 个百分点。准确率的下降表明随着 `tailsize` 的增加，模型在预测正确分类方面的表现有所下降。这表明在当前阈值下随着 `tailsize` 的增加，模型在优化子组分类方面的性能略有下降。综上所述，尽管 `tailsize` 的增加导致 AUROC、OSCR 和准确率的轻微下降，但各 `tailsize` 下的模型性能仍然保持在较高水平。为了进一步验证 HANO 的性能，我们进一步做了不同模型算法在最优训练权重下 Accuracy 变化的对比实验：




图 4.16 不同模型最优训练权重下不同算法的识别准确率随阈值的变化

图 4.16 中呈现了五种不同的模型，包括 Swin Transformer with Openmax、Swin Transformer with Softmax、HAN with Softmax、以及 HANO(两种方法分别利用 softmax 和 sigmoid)。各模型的表现通过准确率（Accuracy）与不同阈值（Threshold）关系的曲线展示。随着阈值的增大，所有模型的准确率均显示出相对稳定的趋势，尤其在阈值接近 0.99 时，准确率趋近于 95% 以上。这表明，在高阈值设置下，模型的分类性能较为可靠。其中 HANO with sigmoid 的准确率最高，HANO with softmax 也表现良好。在低阈值时，各模型的准确率差异明显，而阈值增大至 0.99 及以上时，模型之间的性能差异逐渐减小，说明在高阈值地区，模型的分类能力趋于一致。

4.4.3 不同网络下开集识别对比

如表 4.4 所示，表中给出了 Swin transformer、HAN、HANO、YOLOv5 和 1-D ResNet 模型在 AUROC、OSCR 和准确率方面的比较结果。可以看出，HANO 模型在所有三个指标上都表现最佳，AUROC 为 98.84%，OSCR 为 98.09%，准确率为 95.71%。Swin transformer 模型在 AUROC 和 OSCR 上的表现也很好，但在准确率上略逊于 HANO 模型。HAN 模型在 AUROC 和 OSCR 上的表现与 Swin transformer 模型相似，但在准确率上略高。YOLOv5 模型和 1-D ResNet 模型在所有三个指标上的表现都较差。总的来说，HANO 模型在这项任务上的表现最好，其次是 Swin transformer 模型和 HAN 模型。YOLOv5 模型和 1-D ResNet 模型的性能相对较差。

表 4.4 不同模型算法的开集识别效果对比

Method	AUROC/%	OSCR/%	Accuracy/%
Swin transformer with Openmax	96.92	96.62	87.86
Swin transformer with Softmax	95.65	95.40	81.64
HAN with Softmax	97.27	97.11	91.14
HANO with Softmax	97.75	97.22	94.57
HANO with Sigmoid	98.84	98.09	95.71
YOLOv5	84.60	82.10	80.87
1-D ResNet	68.60	65.90	60.28

4.5 本章小结

本章搭建了实验装置并在围栏上铺设传感光纤，开展了入侵事件实验。选择了摇晃、锯网、攀爬、脚踢四种信号各 1000 条作为已知事件，其中 80%用作训练集，20%用作测试集。模型训练后，闭集事件的最高识别准确率达到 99.63%。在开集事件识别方面，选取了手指触碰、树枝、暴风雨这三种事件作为未知事件。通过优化 `tailsize` 与 `threshold` 参数，得到 `tailsize` 等于 5，`threshold` 范围在 0.99 到 1 时总体平均准确率最佳。最高识别准确率达到 95.71%。比较了 Swin Transformer、YOLOv5、1-D ResNet 和 HANO 模型。结果表明，无论搭配 Softmax 还是 Openmax，HANO 模型均表现优于其他模型。改进后的 HANO with Sigmoid 相比于 HAN with Softmax 准确率提高了 4.57%，相比于原始 HANO with Softmax 层提高了 1.14%。

第五章 总结和展望

5.1 主要完成工作

本文基于瑞利后向散射原理搭建了分布式光纤振动传感系统。提出了基于 HANO 模型开集分类算法，并提出了时频分析法对信号作预处理和特征提取。研究了多组算法并做了对比验证，包括 Swin transformer、YOLOv5 模型、1-D ResNet 模型。具体工作如下：

（1）理论研究：首先通过文献阅读学习了分布式光纤传感技术的研究进展和应用。探讨了分布式光纤传感在信号识别领域的研究现状，同时分析了光纤传感技术目前阶段在信号识别领域的不足。引出在开放环境下光纤振动信号识别并阐述了目前主流的开集识别算法，提出了基于 HANO 模型开集分类算法。详细介绍了 Φ -OTDR 系统的基本原理和时域方差定位算法，以及信号时频分析方法的特征提取方法。

（2）实验系统的设计和数据的预处理：设计了 Φ -OTDR 分布式光纤振动传感系统并给出了系统关键器件的参数。通过时域方差定位算法定位到光纤振动点并采集到振动事件的时域信号，对采集到的信号进行了时频分析预处理。详细介绍了 HAN 网络模型以及 Openmax 算法原理。此外详细阐述了 YOLOv5 网络模型结构和 1-D ResNet 模型结构作为 HAN 模型的对比实验。通过实验装置的搭建和数据采集，成功实现了在分布式光纤振动传感系统对闭集事件的高精度识别，同时验证了在开集事件识别中优化参数对模型性能提升的显著作用。

（3）实验装置的搭建和实验数据的分析：通过搭建实验装置，在围栏上铺设传感光纤进行入侵事件实验，选取摇晃、锯网、攀爬、脚踢这四种信号各 1000 条作为已知事件，其中 80% 用作训练集，20% 用作测试集。经过模型训练，闭集事件的最高准确率在 99.63%。在开集事件的识别上，选取了手指触碰、树枝、暴风雨这三种事件作为未知事件。通过优化 tailsize 与 threshold 参数值，最终得到 tailsize 等于 5，threshold 的范围在 0.99 到 1 时总体平均准确率最好，最高的准确率在 95.71%。通过比较 Swin transformer、YOLOv5、1-D ResNet 模型，HAN 无论是配合 Softmax 还是 Openmax，均表现优于其他模型。改进后的 HANO with sigmoid 相较于 HAN with Softmax 准确率提高了 4.57%，相较于原 HANO with Softmax 层提高了 1.14%。综合

实验结果表明，改进后的 HANO 模型在闭集与开集事件的分类性能上均优于其他模型，展现了其在分布式光纤振动信号识别中的优势与潜力。

5.2 本文的创新点

(1) 本研究提出了一种基于 HANO 的光纤振动传感信号开集事件识别方法，克服了传统方法在复杂开放环境中无法识别未知信号的局限性。通过整合 Hierarchical Attention Network 和 Openmax 算法，增强了系统对开放集事件的识别能力，为分布式光纤振动传感技术在实用应用中的有效性提供了重要支持。

(2) 本文设计并搭建了一个分布式光纤振动传感开集事件识别系统，详细探讨了振动信号的定位与预处理过程，并通过实验验证了所提出模型的有效性。在对比多种网络模型的性能测试中，HANO with sigmoid 模型表现出色，总体识别率达到 95.71%，展现了该方法在实际应用中的潜力和优势。

5.3 展望

本研究的实验验证主要针对围栏上的入侵事件，这在一定程度上限制了模型的泛化能力。在实际应用中，光纤传感系统部署的环境往往更加复杂多变，可能存在各种类型的干扰和噪声。因此，需要开展更多样化的实验，收集更全面的数据集，以提高模型对不同类型未知事件的识别鲁棒性。

此外，本研究将未知事件作为一个整体类别进行识别。然而，在实际场景中，未知事件可能具有不同的特征和模式。为了进一步提高系统的实用性，需要开展后续研究，将未知事件进一步细分为不同的子类别，从而实现更加精细化的识别和分类。

未来研究方向：收集更全面的光纤振动信号数据集，涵盖各种环境条件和未知事件类型，以增强模型的泛化能力；探索机器学习和深度学习技术，将未知事件进一步细分为不同的子类别，实现更加精细化的识别和分类；开发自适应学习算法，使模型能够随着时间的推移不断学习和更新，以适应未知事件模式的变化；研究多模态传感融合技术，将光纤传感与其他传感技术相结合，实现协同识别，提高未知事件识别的准确性和鲁棒性。

参考文献

- [1] 许海燕. 分布式光纤振动传感器及其定位技术研究[D].复旦大学(上海), 2011.4
- [2] 安阳. 双光束 Φ -OTDR 分布式光纤传感技术与应用[D].天津大学精密仪器与光电子工程学院(天津), 2013.10.
- [3] 张旭, 张益昕, 王亮, 等. 分布式光纤传感技术研究和应用的现状及未来 [J].光学学报, 2024, 44(1):0106001.
- [4] 沙雨杉. 分布式光纤位移温度双参量传感技术研究[D].安徽师范大学(芜湖), 2021.5
- [5] Huang L J, Fan X Y, He H J, et al. Single-end hybrid Rayleigh Brillouin and Raman distributed fibre-optic sensing system[J]. Light: Advanced Manufacturing, 2023, 4(2): 16.
- [6] 纪国宜 振动测试和分析技术综述《机械制造与自动化》[J].2012,39(10):51-55
- [7] 谢孔利 基于 Φ -OTDR 分布式光纤传感系统 [D].电子科技大学(成都),2008.4
- [8] Li J, Zhou X X, Xu Y, et al. Slope-assisted Raman distributed optical fiber sensing[J]. Photonics Research, 2022, 10(1):205-213.
- [9] 张树霖 拉曼光谱学与低维纳米半导体[M]. 拉曼光谱学与低维纳米半导体, 2008.
- [10] Zhao Z, Wu H, Hu J, et al. Interference fading suppression in ϕ -OTDR using space-division multiplexed probes[J]. Optics Express 2021,29(10):15452
- [11] 贾俊. 基于 Sagnac 干涉仪光纤传感器干扰检测定位技术研究[D].北京大学(北京), 2008.5.
- [12] 吴俊. 长途油气管道破坏预警的干涉型分布式光纤传感系统定位技术研究[D].重庆大学(重庆),2007.4.
- [13] Ravet F, Briffod F, Goy A, et al. Mitigation of geohazard risk along transportation infrastructures with optical fiber distributed sensing[J]. Journal of Civil Structural Health Monitoring, 2021, 11(4):967-988.
- [14] Wu H, Qian Y, Zhang W, et al. Feature Extraction and Identification in Distributed Optical-Fiber Vibration Sensing System for Oil Pipeline Safety Monitoring[J]. Photonic Sensors, 2018, 7(4):305-310.

- [15]李凯彦, 赵兴群, 孙小菡, 等. 一种用于光纤链路振动信号模式识别的规整化复合特征提取方法[J]. 物理学报, 2015,64(5):251-257.
- [16]伯成地. 基于拉曼后向散射原理的分布式光纤土壤水分传感技术研究[D].安徽师范大学(芜湖), 2022.
- [17]Shi J, XU Z, Li X, et al. High-Resolution Liquid-Level Sensor Based on FabryPerot Interferometer With Fiber Laser Intracavity Sensing[J]. IEEE Sensors Journal, 2023, 23(15):16938-16943.
- [18]Zhou Z, Sha Y, Zhang D, et al. Optical fiber displacement sensor based on Stokes Raman backscattering light bending loss[J]. Optical Fiber Technology, 2021, 66:102667.
- [19]Zhou Z, Tian L, Han Y, et al. Distributed vibration and temperature simultaneous sensing using one optical fiber[J]. Optics Communications, 2021, 487:126801.
- [20]Arshry I, Mao Y, Wang B, et al. A Review of Distributed Fiber–Optic Sensing in the Oil and Gas Industry[J]. Journal of Lightwave Technology, 2022, 40(5):1407-1431.
- [21]Zuo W, Zhou H, Qiao Y, et al. Investigation of Co-Cable Identification Based on Ultrasonic Sensing in Coherent Systems[J]. IEEE Photonics Technology Letters, 2023, 35(21):1155-1158.
- [22]Pinto A M R, Lopez-Amo M. All-fiber lasers through photonic crystal fibers[J]. Nanophotonics, 2014,2(5-6):355-368.
- [23]Sun Z S, Liu K, Jiang J F, et al. Distributed vibration sensing with high frequency response by using WDM based integrated scheme[J]. Journal of Physics D-Applied Physics, 2020, 53(15):155106.
- [24]Sun Z S, Liu K, Jiang J F, et al. Interferometer-Based Distributed Optical Fiber Sensors in Long-Distance Vibration Detection: A Review[J]. Journal of Physics D-Applied Physics, 2020, 53(15):155106.
- [25]Li J C, Wang Y, Wang PF, et al. Pattern Recognition for Distributed Optical Fiber Vibration Sensing: A Review[J]. 2021, 21(10):11983-11998.
- [26]刘浩 分布式光纤振动传感系统振动信号的模式识别[D]. 安徽师范大学(芜湖), 2022.

- [27] Wang C, Shang Y, Zhao W A, et al. Investigation and Comparison of ϕ -OTDR and OTDR-Interferometry via Phase Demodulation[J]. IEEE Sensors Journal, 2018, 18(4):1501-1505.
- [28] Kandamali D F, Cao X M, Tian M L, et al. Machine learning methods for identification and classification of events in ϕ -OTDR systems: a review[J]. 2022, 61(11):2975-2997.
- [29] Tanimura T, Hoshida T, Kato T, et al. Convolutional Neural Network-Based Optical Performance Monitoring for Optical Transport Networks[J]. Journal of Optical Communication and Networking, 2019, 11(1):A52-A59.
- [30] Lin W H, Liu Y B, Yu F H, et al. Temperature Fiber Sensor Based on 1-D CNN Incorporated Time-Stretch Method for Accurate Detection[J]. 2023, 23 (6):5773-5779.
- [31] Sun Q, Feng H, Yan X Y. Recognition of a Phase-Sensitivity OTDR Sensing System Based on Morphologic Feature Extraction[J]. Sensors, 2015 15(7):15179-15197.
- [32] Wu H J, Qian Y, Zhang W, et al. Feature Extraction and Identification in Distributed Optical-Fiber Vibration Sensing System for Oil Pipeline Safety Monitoring[J]. Photonic Sensors, 2018, 7(4):305-310.
- [33] Wang Y, Wang P F, Ding K, et al. Pattern Recognition Using Relevant Vector Machine in Optical Fiber Vibration Sensing System[J]. IEEE Access, 2019, 7:5886-5895.
- [34] Fouda B M T, Yang B, Han D Z. Pattern Recognition of Optical Fiber Vibration Signal of the Submarine Cable for Its Safety[J]. IEEE Sensors Journal, 2021, 21(5):6510-6519.
- [35] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. 2015, 521(7553):436-444.
- [36] Wu H, Zhou B, Zhu K, et al. Pattern recognition in distributed fiber-optic acoustic sensor using an intensity and phase stacked convolutional neural network with data augmentation[J]. Optics Express, 2021, 29(3):3269-3283.
- [37] Shi Y, Dai S W, Liu X Y, et al. Event recognition method based on dual-augmentation for a Φ -OTDR system with a few training samples[J]. Optics Express, 2022, 30(17):31232-31243.
- [38] Shi Y, Chen J W, Dai S W, et al. Multi-signal feature fusion method with an attention mechanism for the Φ -OTDR event recognition system[J]. Optics Express, 2023, 30(23):42086-42096.

- [39]Giusti E, Ghio S, Oveis A H, et al. Proportional Similarity-Based Openmax Classifier for Open Set Recognition in SAR Images[J]. Remote Sensing, 2022, 14(18):4665.
- [40]Kong S, Ramanan D. Opengan: Open-set recognition via open data generation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 812-822.
- [41]Chen G Y, Peng P X, Wang X P, et al. Adversarial reciprocal points learning for open set recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(11):8065-8081.
- [42]Dai W, Diao W H, Sun X, et al. CAMV: Class Activation Mapping Value Towards Open Set Fine-Grained Recognition[J]. IEEE Access, 2021, 9:8167-8177.
- [43]Zhou Z X, Jiao W Y, Hu X, et al. Open-Set Event Recognition Model Using 1-D RL-CNN With OpenMax Algorithm for Distributed Optical Fiber Vibration Sensing System[J]. IEEE Sensors Journal, 2023, 23(12):12817-12827.
- [44]Liu Z, Lin Y, Cao Y, et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows[J]. in Proc. IEEE Int. Conf. Comput. Vis., 2021, 10012-10022.
- [45]Joseph R, Santosh D, Ross G, et al. You Only Look Once: Unified, Real-Time Object Detection[J]. 2016 IEEE Conference on Computer Vision and Pattern Recognition, 2016, 779-788.
- [46]A T. Young. Rayleigh scattering[J]. Applied optics, 1981, 20(04): 533-535
- [47]张旭苹, 丁哲文, 洪瑞, 等. 相位敏感光时域反射分布式光纤传感技术[J]. 光学学报, 2021, 41(1): 0106004.
- [48]Barnoski M K, Jensen S M. Fiber Waveguides: A Novel Technique for Investigating Attenuation Characteristics[J]. Applied Optics, 1976, 15(9): 2112-2115.
- [49]于淼. 基于双重同源外差相干检测的 Φ -OTDR 系统的研究及应用[D]. 吉林大学(长春), 2017.
- [50]Juarez J C, Maier E W, Choi K N, et al. Distributed fiber-optic intrusion sensor system[J]. Journal of Lightwave Technology, 2005, 23(6): 2081-2087.
- [51]Park J, Taylor H F. Fiber Optic Intrusion Sensor using Coherent Optical Time Domain Reflectometer[J]. Japanese Journal of Applied Physics Part 1-Regular Papers Short Notes & Review Papers, 2003, 42(6A):3481-3482.

- [52] Taylor H F, Lee C E. Apparatus and method for fiber optic intrusion sensing: US, US5194847 A[P]. 1993.
- [53] Marie T F B, Bin Y, Han D Z, et al. Principle and Application State of Fully Distributed Fiber Optic Vibration Detection Technology Based on ϕ -OTDR: A Review[J]. IEEE Sensors Journal, 2021, 21(15):16428-16442.
- [54] Xu S H, Qin Z J, Zhang W T. A Novel Method of Recognizing Disturbance Events in Φ -OTDR Based on Affinity Propagation Clustering and Perturbation Signal Selection[J]. IEEE Sensors Journal, 2021, 21(12):13272-13282.
- [55] 李华. 用于输配电线路安全监控的光纤分布式拉曼温度传感系统解调算法研究 [D]. 华中科技大学(武汉), 2018
- [56] 徐健, 李晓慧. 一种基于 FFT 的高分辨率音频频率测量方法[J]. 电子质量, 2020, (02): 11-14
- [57] C. Xu, J. Guan, M. Bao, J. Lu, et al. Pattern recognition based on time-frequency analysis and convolutional neural networks for vibrational events in ϕ -OTDR[J]. Optical Engineering, 2018, 57(01): 016103
- [58] 宋培培, 万遂人. 分布式光纤传感信号特征提取方法研究 [J]. 世界科技研究与发展, 2009, 31(5):820-823
- [59] Wang P, Li Z, Hou Y, et al. Action Recognition Based on Joint Trajectory Maps Using Convolutional Neural Networks[J]. Knowledge Based Systems, 2016, 102-106
- [60] Scheirer W J, Jain L P, Boulton T E, et al. "Probability Models for Open Set Recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2014, 36(11):2317-2324.
- [61] Chen G, Peng P, Wang X, et al. Adversarial Reciprocal Points Learning for Open Set Recognition[J]., IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(11):8065-8081.
- [62] Sun J Y, Wang H, Dong Q L, et al. Hierarchical Attention Network for Open-Set Fine-Grained Image Recognition[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2024, 34(5):3891-3904.

- [63]Ben Ali J, Chebel- Morello B, Saidi L, et al. Accurate bearing remaining useful life prediction based on Weibull distribution and artificial neural network[J]. Mechanical Systems and Signal Processing, 2015, 56-57:150-172.
- [64]Zhou Z X, Liu H, Zhang D W, et al. Distributed Partial Discharge Locating and Detecting Scheme Based on Optical Fiber Rayleigh Backscattering Light Interference, Sensors 2023, 23(4).
- [65]Wang M, Feng H, Qi D, et al. ϕ -OTDR pattern recognition based on CNN-LSTM[J]. Optik, 2023, 272:170380.
- [66]Liu Z, Lin Y, Cao Y, et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows[J]. in Proc. IEEE Int. Conf. Comput. Vis., 2021, 10012-10022.
- [67]Chen B, Polatkan G, Sapiro G, et al. Deep Learning with Hierarchical Convolutional Factor Analysis[J]. IEEE Transaction on Pattern Analysis and Machine Intelligence, 2013, 35(8):1887-1901.
- [68]Zhu D Y, Lu S Y, Wang M Q, et al. Efficient Precision-Adjustable Architecture for Softmax Function in Deep Learning[J]. IEEE Transactions on Circuits and Systems II-Express Briefs, 2020 67(12):3382-3386.
- [69]Wang Y F, Wan S P, Zhang S J, et al. Speaker recognition of fiber-optic external Fabry-Perot interferometric microphone based on Deep Learning[J]. IEEE Sensors Journal, 2022, 22(13):12906-12912.
- [70]Hu H W, Xia X, Luo Y L, et al. Development and application of an evolutionary deep learning framework of LSTM based on improved grasshopper optimization algorithm for short-term load forecasting[J]. Journal of Building Engineering, 2023, 57:104975.
- [71]Zhao J H, Zeng D L, Xiao Y J, User personality prediction based on topic preference and sentiment analysis using LSTM model[J]. Pattern Recognition Letters, 2020, 138:397-402.
- [72]Petkovic T, Petrovic L, Markovic I, et al. Human action prediction in collaborative environments based on shared-weight LSTMs with feature[J]. Applied Soft Computing, 2023, 126:109245.

- [73]Landi F, Baraldi L, Corina, et al. Working memory connections for LSTM[J]. Neural Networks, 2021, (144)334–341.
- [74]Giusti E, Ghio S, Oveis, A, et al. Proportional Similarity-Based Openmax Classifier for Open Set Recognition in SAR Images[J]. Remote Sensing, 2022, 14(18):4665.
- [75]Yao D Z, Shao Y X. A data efficient transformer based on Swin Transformer[J]. Visual Computer, 2024, 40(4):2589-2598.
- [76]Zhang L, Li J M, Zhang F Q, et al. An Efficient Forest Fire Target Detection Model Based on Improved YOLOv5[J]. Fire, 2023, 6(8):291.