

密级：_____

河北地质大学硕士学位论文

基于深度学习的分布式光纤振动传感
信号识别研究

论文作者：	程杨鑫	学生类别：	全日制
一级学科：	计算机科学与技术	学科专业：	计算机系统结构
指导教师：	郑一博	职 称：	教授

Security Classification: _____

Dissertation Submitted to
Hebei GEO University
for
The Master Degree of
Computer System Architecture

**Research on Distributed Acoustic Sensing Signal Recognition
Based on Deep Learning**

by
YangXin Cheng

Supervisor: Prof. Yibo Zheng

April, 2025

摘 要

分布式光纤振动传感（DAS）是一种近年来兴起的超密集地震观测技术，可将通信光纤转变为地震传感器台阵，以米级空间分辨率采样几十公里长光纤的振动信号，用单台机器实现数万道观测。DAS 具有密集、可持续观测、低维护成本和强大的环境适用性等优点，这些优势使得 DAS 在地震监测领域拥有巨大的应用潜力。然而 DAS 密集观测会产生海量数据，并且采集的数据含有大量噪声，传统的地震信号识别方法难以胜任。因此，本文以提高 DAS 的智能识别能力为目标，开展基于深度学习的 DAS 信号识别方法研究，主要工作如下：

（1）介绍了分布式光纤传感技术的基本原理，分析了现有 DAS 信号去噪方法存在的问题，并针对这些问题给出了本文解决思路，以及详细介绍了半监督学习的流程和相位关联算法原理。

（2）为减小 DAS 记录中的噪声对信号识别的影响，提出了一种基于孪生形态学 U-Net 神经网络的自监督学习去噪算法（SiamMorph-Unet）。首先，根据形态学滤波原理创建形态学开卷积模块和形态学闭卷积模块，替换 U-Net 网络中的普通卷积块，提高模型的降噪能力。随后，在新构建的 U-Net 模型的编码与解码之间加入多尺度卷积注意力机制，使模型更关注有用信号的特征，降低信号去噪后的误差。此外，根据 DAS 地震记录相邻通道间强相关特点，在 Noise2Self 自监督方法的损失函数上加入 J-invariant 约束项，减小模型恒等映射对去噪效果的影响。通过在合成 DAS 数据和实际 DAS 数据上进行测试，结果表明 SiamMorph-Unet 算法能有效抑制 DAS 信号中的噪声，且对有效信号损伤较轻，整体信噪比提升了 12.92dB。

（3）针对 DAS 地震数据庞大，手动标注一个大型 DAS 数据集既耗时又成本高昂，现有 DAS 地震波相位识别半监督学习算法准确率较差的问题，提出了一种基于小波有效通道注意力模型的半监督 DAS 地震波相位识别算法（WECANet-DAS）。该方法首先在半监督学习流程中添加去噪步骤，在教师模型生成伪标签之前，使用本文提出的去噪方法对 DAS 信号去噪，提高伪标签的质量。其次，提出了一种小波有效通道注意力卷积替换传统 U-Net 模型中的普通卷积，在增大模型感受野的同时，提高模型的识别精度。此外，使用小波下采样卷积作为模型的下采样模块，减少下采样时有效信息的损失。结果表明，本文提出的方法识别到的有效地震波相位信号相比于 PhaseNet-DAS 方法增加了 0.76 倍，相位识别率提高了 12.17%。

关键字：深度学习；分布式光纤振动传感；地震波；信号去噪；信号识别

ABSTRACT

Distributed Acoustic Sensing (DAS) is an emerging ultra-dense seismic observation technology that transforms communication optical fibers into seismic sensor arrays, sampling vibration signals along tens of kilometers of fiber with meter-level spatial resolution to achieve tens of thousands of observation channels on a single machine. DAS has the advantages of dense and continuous observation, low maintenance cost, and strong environmental adaptability, which endow it with tremendous application potential in seismic monitoring. However, the dense observation of DAS produces massive amounts of data, and the acquired data contain a large amount of noise, rendering traditional seismic signal recognition methods inadequate. Therefore, this paper aims to improve the intelligent recognition capability of DAS by conducting research on deep learning-based DAS signal recognition methods. The main work is as follows:

(1) The basic principles of distributed optical fiber sensing technology are introduced, the problems existing in current DAS signal denoising methods are analyzed, and a solution strategy is proposed to address these issues. In addition, the process of semi-supervised learning and the principle of the phase association algorithm are described in detail.

(2) To reduce the impact of noise in DAS records on signal recognition, a self-supervised denoising algorithm based on a Siamese Morphological U-Net neural network (SiamMorph-Unet) is proposed. First, morphological opening convolution modules and morphological closing convolution modules are created based on the principles of morphological filtering to replace the ordinary convolution blocks in the U-Net, thereby improving the model's denoising capability. Then, a multi-scale convolution attention mechanism is added between the encoder and decoder of the newly constructed U-Net model, so that the model focuses more on the features of useful signals and reduces the error after denoising. In addition, based on the strong correlation between adjacent channels in DAS seismic records, a constraint term is added to the loss function of the Noise2Self self-supervised method to reduce the effect of identity mapping on denoising performance. Tests on both synthetic DAS data and actual DAS data show that the SiamMorph-Unet algorithm can effectively suppress noise in DAS signals, with minimal damage to the valid signal, and the overall signal-to-noise ratio is improved by 12.92 dB.

(3) In view of the enormous volume of DAS seismic data, the time-consuming and high cost of manually annotating a large-scale DAS dataset, and the poor accuracy of existing semi-supervised learning algorithms for DAS seismic phase recognition, a semi-supervised DAS seismic phase recognition algorithm based on a Wavelet Effective Channel Attention model (WECANet-DAS) is proposed. This method first adds a denoising step in the semi-

supervised learning process; before the teacher model generates pseudo-labels, the proposed denoising method is used to denoise the DAS signals to improve the quality of the pseudo-labels. Secondly, a wavelet effective channel attention convolution is proposed to replace the ordinary convolution in the U-Net model, which not only enlarges the model's receptive field but also improves the recognition accuracy. In addition, wavelet downsampling convolution is used as the model's downsampling module to reduce the loss of effective information during downsampling. The results show that the proposed method detects effective seismic phase signals 0.76 times more than the PhaseNet-DAS method, and the phase recognition rate is improved by 12.17%.

KEYWORDS: Deep Learning; Distributed Acoustic Sensing; Seismic Waves; Signal Denoising; Signal Recognition

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 DAS 在地震领域的应用.....	2
1.3 DAS 信号的去噪研究现状	3
1.4 DAS 地震波识别研究现状	4
1.5 主要研究内容.....	5
1.6 论文组织结构.....	6
第二章 基于深度学习的分布式光纤振动传感信号识别分析	9
2.1 分布式光纤传感技术基本原理	9
2.1.1 瑞利散射.....	9
2.1.2 基于 Φ -OTDR 的 DAS 系统原理	10
2.2 DAS 系统的性能指标.....	11
2.3 DAS 信号去噪分析.....	12
2.3.1 有监督学习.....	12
2.3.2 弱监督学习.....	13
2.3.3 自监督学习.....	15
2.4 DAS 地震波相位识别分析	18
2.4.1 Noisy Student 半监督方法步骤.....	18
2.4.2 贝叶斯高斯混合模型关联器.....	19
2.5 本章小结.....	24
第三章 基于孪生形态学 U-Net 神经网络的 DAS 信号去噪方法 ..	25
3.1 基于形态学滤波的卷积模块构建	25
3.1.1 形态学滤波原理.....	25
3.1.2 形态学卷积模块构建.....	27
3.2 孪生形态学神经网络模型构建	30
3.3 实验数据和模型训练.....	32
3.3.1 实验数据.....	32
3.3.2 模型训练.....	36
3.3.3 评估指标.....	37
3.4 实验结果与分析.....	38
3.4.1 合成 DAS 数据去噪结果.....	38
3.4.2 实际 DAS 数据去噪结果.....	44
3.4.3 消融实验.....	48
3.5 本章小结.....	48

第四章 基于小波有效通道注意力模型的 DAS 地震波识别	49
4.1 小波有效通道注意力模型构建	49
4.1.1 网络架构	49
4.1.2 WECAConv 和 WTD 介绍	50
4.1.3 损失函数	53
4.2 实验数据和模型训练	53
4.2.1 实验数据	53
4.2.2 模型训练	54
4.2.3 评估指标	55
4.3 实验结果与分析	56
4.3.1 对比实验	56
4.3.2 消融实验	57
4.4 本章小结	59
第五章 总结与展望	61
5.1 工作总结	61
5.2 研究展望	61
参考文献	63

第一章 绪论

1.1 研究背景及意义

分布式光纤振动传感技术 (Distributed Acoustic Sensing, DAS) 是近年来一项快速发展的光纤传感技术, 可以将长达一百公里的光纤电缆转变为间隔仅几米的超密集地震传感器阵列。DAS 使用询问器单元将激光脉冲发送到光纤中, 并测量光纤内部自然缺陷的瑞利反向散射。通过测量重复脉冲之间的微小相位变化, DAS 可以推断出沿光纤电缆随时间变化的纵向应变或应变率^[1,2], 因此 DAS 可以有效的记录地震波^[3]。相比于传统的地震采集方式, DAS 在地震监测方面具有许多潜在优势。例如, 与地震台网数十公里的间距相比, DAS 提供了前所未有的米级通道间距^[4]。DAS 还可以利用未使用的电信光纤电缆进行地震监测, 降低使用成本。此外, 由于光纤材料具有抗电磁干扰、耐高温、轻便耐用等特点, DAS 适合在冰川、海洋、深井等恶劣、复杂、极端环境中部署和维护。随着高速互联网基础设施的发展, 新型 DAS 询问器单元能够以更低的成本实现更长的传感范围^[5]。因此, DAS 在地震监测领域具有广泛的前景。然而, 面对 DAS 数千个通道产生的海量数据, 传统的小波变换、自适应滤波、带通滤波等去噪算法无法有效胜任。同时, 缺乏有效的地震检测和相位到达提取算法, 将 DAS 应用于常规地震监测任务仍然具有挑战性。与地震网络相比, 光纤传感的超高空间分辨率是一个显著优势, 但也对为单分量或三分量地震仪设计的传统数据处理算法提出了挑战。例如, 常用的 STA/LTA (短期平均和长期平均) 方法^[6]对于 DAS 来说是无效的, 因为由于电缆地耦合和对人为噪声的敏感性等因素, DAS 记录相比于专用地震仪数据的包含更多的噪声。STA/LTA 只能在 DAS 单个通道波形上运行, 因此无法有效利用 DAS 提供的密集空间采样。模板匹配是另一种有效的地震检测方法, 特别是用于检测微小的地震信号^[7]。然而, 现有模板的要求和高计算要求限制了其在常规地震监测中的适用性^[8]。

随着人工智能技术的不断发展和计算机硬件性能的大幅提升, 特别是深度神经网络在各个领域的应用得到了迅猛发展, 例如图像分类、对象检测、语音识别、机器翻译、文本/图像生成和医学图像分割^[9]。深度学习还广泛应用于地震检测^[10,11]、密集地震序列^[12]和日常监测地震活动^[13,14]。与 STA/LTA 方法相比, 深度学习对小地震的微弱信号更敏感, 对导致 STA/LTA 误报的噪声尖峰更稳健。与模板匹配方法相比, 深度学习概括了基于相似性的搜索, 不需要精确的地震模板, 并且速度明显更快。神经网络模型自动学习从大型训练数据集中提取地震信号的共同特征, 并能够推广到训练样本之外的地震。例如, PhaseNet 模型是一种使用北加州地震训练的深度神经网络模型,

在应用于全球构造地震、诱发地震和火山地震时表现良好^[15,16]。DAS 在地震监测应用中,能够实现密集、长时间地连续观测和记录地震信号,同时也会产生大量数据,传统的地震数据处理方法面对大数据捉襟见肘,如果利用深度学习方法分析 DAS 地震信号,加速 DAS 数据处理,对于地震研究具有重要意义。

1.2 DAS 在地震领域的应用

近几年,随着 DAS 系统的发展,越来越多的学者将 DAS 系统应用到地震学相关应用研究中。王等^[17]将 DAS 与传统地震仪在评估地震地动响应方面的性能进行了比较,证明了 DAS 地震监测的高空间分辨率,并对比出了 DAS 与地震仪振幅和相位的差异。Lindsey 等^[18]探索了暗光纤在地震监测中的再利用,强调了 DAS 的成本效益和检测大面积地震活动的能力。Karrenbach 等^[19]应用 DAS 监测 2019 年里奇克雷斯特地震的余震,展示了 DAS 在实时地震危险评估中的潜力。Farghal 等^[20]的研究进一步验证了 DAS 在地震震中定位和预警应用方面的能力,强调了 DAS 的可扩展性和效率。李等^[21]证明了 DAS 在将光纤电缆转换为用于高频地震成像的大规模地震阵列方面的有效性。Baba 等^[22]将 DAS 应用于 Nankai 海槽慢滑事件的海上监测。Matias 等^[23]将 DAS 应用扩展到使用海底电缆的地下表征,证明了其用于海洋学研究的可行性。Biondi 等^[24]研究了 DAS 在城市地震监测和 underwater 声学探测方面的潜力,证明了其在各种环境中的多功能性。Zeng 等^[25]进行的研究强调了 DAS 通过提供快速震级估计和地面运动预报来增强地震预警的能力。Tsuji 等^[26]介绍了一种用于地质成像的便携式主动地震源系统,该系统与 DAS 结合使用时可以改善地质监测。Yin 等^[27]展示了 DAS 在海上快速地震定位中的应用,可以直接根据应变率幅度估算震级。Zhai 等^[28]则展示了 DAS 在检测以前未记录的地震事件方面的潜力,这进一步证明了 DAS 在推进地震灾害评估中的作用。Cheng 等^[29]的进一步研究探索了 DAS 在海底构造研究中的作用。邓等^[30]则展示了其在检测深海环境中远震事件的有效性,将地震监测扩展到了以前未被覆盖的区域。

DAS 的另一个关键应用是火山地震学。Nishimura 等^[30]展示了 DAS 如何追踪岩浆运动、精确定位地震起源并检测火山震动,这使其对实时灾害评估很有价值。Brenguier 等^[32]展示了其在监测断层区中的作用,利用过往火车等来源的背景噪声来研究断层动力学。Biagioli 等^[33]在意大利的斯特龙博利火山使用 DAS 技术,通过 1km 的光缆分析了爆炸和震动产生的应变信号,从而深入了解了火山活动。Nakano 等^[34]在汤加的海底电信电缆上测试了 DAS,表明它是一种经济高效的水下火山活动监测工具。Caudron 等^[35]在德国的拉赫尔湖火山使用 DAS 检测和分类水下气体排放,证明了其在实时脱气监测方面的潜力。Jousset 等^[36]在埃特纳火山附近部署了一条 1.3km 的电缆,捕获高分辨率应变数据以探测火山事件和地下过程。Currenti 等^[37]在埃特纳火

山使用 1.5km 的电缆和 26 个地震仪测试了 DAS，证实了其在监测局部应变变化方面的准确性。Currenti 等^[38]还监测了武尔卡诺岛和西西里岛之间的低频火山活动，检测到了 1488 次事件，并展示了 DAS 如何结合机器学习来增强火山灾害评估。另外，DAS 还被广泛的应用于油气勘探^[39]、基础设施监测^[40]、城市活动监测^[41]和环境监测^[42]。

1.3 DAS 信号的去噪研究现状

虽然，DAS 系统相比于传统地震检波器具有很多优势，但是由于其高灵敏性的特点，使得 DAS 系统与常规检波器采集的数据相比，通过 DAS 采集到的数据信噪比较低，并且数据中存在各种噪声，例如随机噪声、振铃噪声、低频噪声、水平噪声和棋盘格噪声等^[43-45]。严重影响后续地震相位识别，以及 DAS 地震数据的成像和解释^[4]。为了克服 DAS 数据信噪比低的问题，学者们纷纷提出了不同的去噪方法。

传统的地震信号去噪方法，例如小波变换^[46]、带通滤波^[47]、曲波变换^[48]、经验模态分解^[49]、变分模态分解^[50]等，这些方法在处理一些随机噪声或高斯噪声时是有效的，但对于 DAS 噪声都有局限性。例如，带通滤波无法分离同一频带内的有效信号和噪声。小波变换、曲波变换等稀疏表示方法依赖于阈值函数以及手动选择阈值的需要。近年来，一些去噪方法被提出来抑制特定的 DAS 数据噪声。例如，Binder 等（2020）通过中值滤波和倾角滤波来分别抑制光学异常噪声和水平噪声^[51]。Sun 等（2020）利用 F-X 反卷积降低随机噪声^[52]。Marius 等（2022）提出一种自适应频率波数滤波器降低 DAS 信号中的随机噪声。这些研究对 DAS 数据的处理做出了巨大贡献，具有重要的指导意义。但上述方法通常存在一定的局限性，这些方法仅对一类或两类噪声取得了较好的去噪效果，并且它们的应用受到噪声水平的限制，有效信号容易丢失。当多种噪声同时存在时，去噪效果往往不理想。此外，为了获得最佳效果需要调整大量参数，不能满足大数据背景下高效、智能处理的要求。

在更广泛的科学和工程领域，噪声抑制越来越多地通过深度学习方法来解决，其中图像领域的去噪方法取得了最大的进展。与线性、f-k（时间和空间频率）或统计估计滤波器不同，深度学习模型不受明确的统计假设、响应权衡（例如，滤波器系列或阶数的选择）或手动参数化（例如，选择通带或统计模型）。深度学习能够直接从样本数据中“学习”经验的、抽象的和非线性的分层数据表示，从而使它们能够执行有效的信号过滤和特征提取，而无需手动输入或对信号或噪声分布的事先假设。该领域最初的成功是由“标准”完全监督范式推动的，使用大量噪声-无噪声信号对进行模型训练；即，每个训练样本的噪声和无噪声副本均可用，并且模型经过训练直接将噪声信号映射到无噪声对应信号。这种方法有时在去噪文献中被称为“Noise2Clean”（N2C），并且之前已应用于地震信号并取得了明显的成功^[53-56]。例如，赵等（2022）利用卷积神经网络去除 DAS 信号中的耦合噪声，去噪后受耦合噪声影响的信号变得清晰连续，

有效信号几乎没有能量损失^[57]。王等^[58]（2023）提出了一种名为注意力引导的去噪卷积神经网络（ADNet）来去除 DAS 信号中的光学异常噪声、衰落噪声和水平噪声等。然而，在许多应用中，获取足够数量的无噪声或高信噪比记录信号以进行稳健的模型训练可能很困难甚至不可能，因此这种方法的“现实世界”适用性受到限制。这种情况在 DAS 记录的情况下尤其如此，其中观测到的数据受到强随机噪声过程的严重污染，并且模拟地震波传播以在长距离光纤上生成真实的无噪声信号需要大量计算且难以建模。Lapins 等^[59]（2024）提出了一种名为 DAS-N2N 的方法对 DAS 采集的自然冰川微震信号去噪，该方法通过将一根光缆内的两根光纤拼接（连接在一起）来实现，记录同一底层信号的两个噪声副本，这些副本被随机观测噪声的不同独立实现所破坏。然后使用这两个带噪声的数据副本来训练深度学习模型，极大地抑制不相干噪声并提高自然冰川微震事件的信噪比。尽管 DAS-N2N 方法在训练神经网络时不需要关注干净信号，相比于有监督的深度学习降低了模型的训练条件，但是 DAS-N2N 方法需要将光缆内的光纤熔接在一起，破坏了现有的光纤结构。因此，不适用于使用现有的电信光缆进行的地震监测。van den Ende 等^[60]（2021）提出了一种自监督的方法在去除 DAS 采集的地震信号噪声的同时提高信号的相干性，称为 jDAS。该方法尽管解决了有监督方法人工标记标签数据工作量大的问题，但是使用该方法去噪后的信号幅值大幅降低，信号失真严重。

1.4 DAS 地震波识别研究现状

地震波识别是地震监测中的一个关键问题，准确识别地震的不同波相（如初至波 P 波和后至波 S 波）对于地震早期预警、震源定位以及震中推算至关重要。传统的地震仪器往往难以同时满足高空间分辨率与实时监测的需求，且对地震定位精度较低，尤其是在大范围的地震波监测中存在局限性。近年来，随着分布式光纤传感技术的发展为地震监测提供了新的思路。相比于传统的地震传感技术，DAS 能够在长距离内提供高空间分辨率的测量数据，且光纤传感器对环境适应性较强，可以实现更广泛区域的地震监测。

传统的地震仪采集到的地震信号，通常使用 STA/LTA（长时平均和短时平均）识别地震波相位，但是由于 DAS 采集到的地震信号相比于专业的地震仪器采集到的地震信号具有较低的信噪比，微弱的 P 波信号可能淹没在噪声信号中。因此，常用的地震相位监测方法 STA/LTA 不适用于低信噪比的 DAS 地震信号检测。对于另外一种有效的地震检测方法—模板匹配方法，该方法尽管能够检测出微弱的地震信号，但是该方法需要现有地震模板和高计算量，而且 DAS 由于高分辨率和高采样频率特性采集到的地震数据庞大，因此限制了模板匹配方法在 DAS 常规地震监测方面的适用性。随着深度学习在各个领域的发展，深度学习也广泛用于地震检测中^[10]。与 STA/LTA 方

法相比,深度学习方法更擅长从复杂的信号中提取特征,尤其是对于微小的地震信号,且在噪声环境下能够有效减少误报,提升了地震监测系统的整体准确性和可靠性。与模板匹配方法相比,深度学习概括了基于相似性的搜索而无需精确的地震模板,并且具有更快的识别速度。例如,Perol 等(2018)提出了一种名为 ConvNetQuake 的高度可扩展的卷积神经网络,用于从单个波形中检测和定位地震^[61]。将该神经网络应用于美国俄克拉荷马州的诱发地震活动时,检测到的地震比俄克拉荷马州地质调查局之前记录的地震多 17 倍以上。Zhu 等(2019)使用北加州的地震数据训练了一个地震波相位拾取模型 PhaseNet,将该模型应用于其它地区的地震识别时表现良好^[62]。Mousavi 等(2020)提出了一种同时用于地震监测和相位拾取的模型 EQTransformer。该模型拾取 P 相和 S 相的精度接近人类分析师的手动拾取^[63]。在 2022 年 Zhu 等人又提出了一种深度学习与相位关联相结合的神经网络模型 EQNet,用来提高相位识别精度^[10]。深度学习在地震检测和相拾取过程中成功的一个关键因素是在过去的几十年里,地震学家和人工分析师通过对大量地震事件的波形数据进行人工标注,积累了丰富的相位到达时间数据。这些数据提供了高质量的标签,是训练深度学习模型的基础。深度学习模型通过学习这些手动标注的数据,能够有效地识别地震信号中的各种相位,进而提高相位识别的能力。例如, Ross 等人收集了约 150 万个 P 波和 S 波的标注数据,这些数据来自南加州地震网络^[64]; Zhu 和 Beroza 则使用了来自北加州地震网络的约 70 万个 P 波和 S 波的标注数据^[62]; Michelini 等人建立了一个基准数据集,包含来自意大利国家地震网络的约 120 万个地震波形^[65];赵等人则构建了一个基准数据集,包含来自中国地震网络的约 230 万个地震波形^[66]; Mousavi 等人创建了一个全球基准数据集 (STEAD),包含约 120 万个地震波形^[67];此外,还有多个其他基准数据集被开发出来,用于训练深度学习模型^[68,69]。尽管许多 DAS 数据集已经被收集^[70],并且还在继续收集,但这些数据集大多数尚未经过人工分析师的处理。手动标注一个大型 DAS 数据集既耗时又成本高昂。因此,基于 DAS 数据的深度学习应用仍然有限。大多数研究集中于使用小型数据集进行地震检测,准确识别相位到达时间仍然是 DAS 数据中未解决的挑战,这也限制了其在地震监测中的应用。

1.5 主要研究内容

本文的研究内容分为两部分,第一部分是基于自监督学习的 DAS 地震信号去噪算法研究,第二部分是基于半监督学习的 DAS 地震波相位识别的算法研究。第一部分中,针对 DAS 地震信号信噪比低,有监督学习的 DAS 地震信号去噪算法泛化性较差,现有自监督算法去噪后信号失真严重的问题,提出一种基于孪生形态学 U-Net (SiamMorph-Unet, Siamese Morphology U-net) 神经网络的自监督学习去噪算法,在对 DAS 信号去噪的同时有效降低模型对信号幅值的影响。第二部分中,针对 DAS 地

震数据庞大，人工标注一个大型 DAS 数据集既耗时又成本高昂，而现有 DAS 地震波相位识别半监督学习算法准确率较差的问题，本文提出一种基于 WECA_{Net}-DAS 神经网络的半监督 DAS 地震波相位识别算法，解决有监督学习算法对 DAS 数据标签依赖问题的同时提高识别精度。具体内容如下：

(1) 针对现有 DAS 地震信号自监督算法去噪后信号失真、误差较大的问题，提出了一种基于孪生形态学 U-Net 神经网络的自监督学习去噪算法。该方法首先根据形态学滤波原理创建形态学开卷积模块和形态学闭卷积模块，替换 U-Net 网络中的普通卷积块，在对 DAS 信号去噪的同时可以有效降低模型对信号幅值的影响；其次，在新构建的 U-Net 模型的编码与解码之间加入多尺度卷积注意力机制，使模型更关注有用信号的特征，降低信号去噪后的误差。此外，根据 DAS 地震记录相邻通道间强相关特点，在 Noise2Self 自监督方法的损失函数上加入 $J - invariant$ 约束项，减小了模型恒等映射对去噪效果的影响。

(2) 针对 DAS 地震数据庞大，人工标注一个大型 DAS 数据集既耗时又成本高昂，现有 DAS 地震波相位识别半监督学习算法准确率较差的问题，提出了一种基于 WECA_{Net}-DAS 神经网络的半监督 DAS 地震波相位识别算法。首先，在使用教师模型生成伪标签之前，使用第一部分提出的去噪方法对 DAS 信号去噪，提高伪标签的质量；然后，提出了一种小波有效通道注意力卷积替换传统 U-Net 模型中的普通卷积，在增大模型感受野的同时，提高了模型的识别精度。此外，使用小波下采样卷积作为模型的下采样模块，减少了下采样时有效信息的损失。

1.6 论文组织结构

论文总体框架如图 1.1 所示，全文共分为五章，具体内容安排如下：

第一章为绪论，首先介绍了分布式光纤振动传感（DAS）信号识别方法的研究背景及意义，然后阐述了 DAS 在地震监测领域的应用。随后，讨论了 DAS 地震信号去噪和相位识别的发展现状，列举了一些现有的针对 DAS 地震信号去噪和相位识别的方法，分析了这些方法的不足之处。最后，介绍本文的主要研究内容和各章节安排。

第二章首先介绍了分布式光纤传感技术的基本原理，详细说明了基于相位敏感的光时域反射仪的 DAS 系统原理和 DAS 系统性能指标。然后从有监督学习、弱监督学习、自监督学习三个方面分析了 DAS 信号去噪的原理和不足之处，针对这些问题给出了本文解决思路。最后介绍了本文半监督学习的流程，以及详细介绍了流程中使用的相位关联算法原理。

第三章首先介绍形态学开卷积和形态学闭卷积模块的原理和构建过程。然后介绍了使用形态学卷积模块、多尺度卷积注意力模块改进的 U-Net 网络模型 SiamMorph-UNet。最后，根据此方法进行了 DAS 地震信号去噪实验，包括数据集获取、对比实

验、消融实验以及实验结果与分析。

第四章首先介绍了 DAS 地震波相位识别模型 WECA Net-DAS 的网络结构。随后，详细介绍了小波卷积、小波有效通道注意力卷积和小波下采样的原理和构建过程。最后，本章就 WECA Net-DAS 算法进行了 DAS 地震波相位识别实验，验证该模型的有效性，以及各模块对模型性能的影响。

第五章总结了本文的主要研究内容和工作，并对工作中的不足进行了分析，思考未来的工作开展方向。

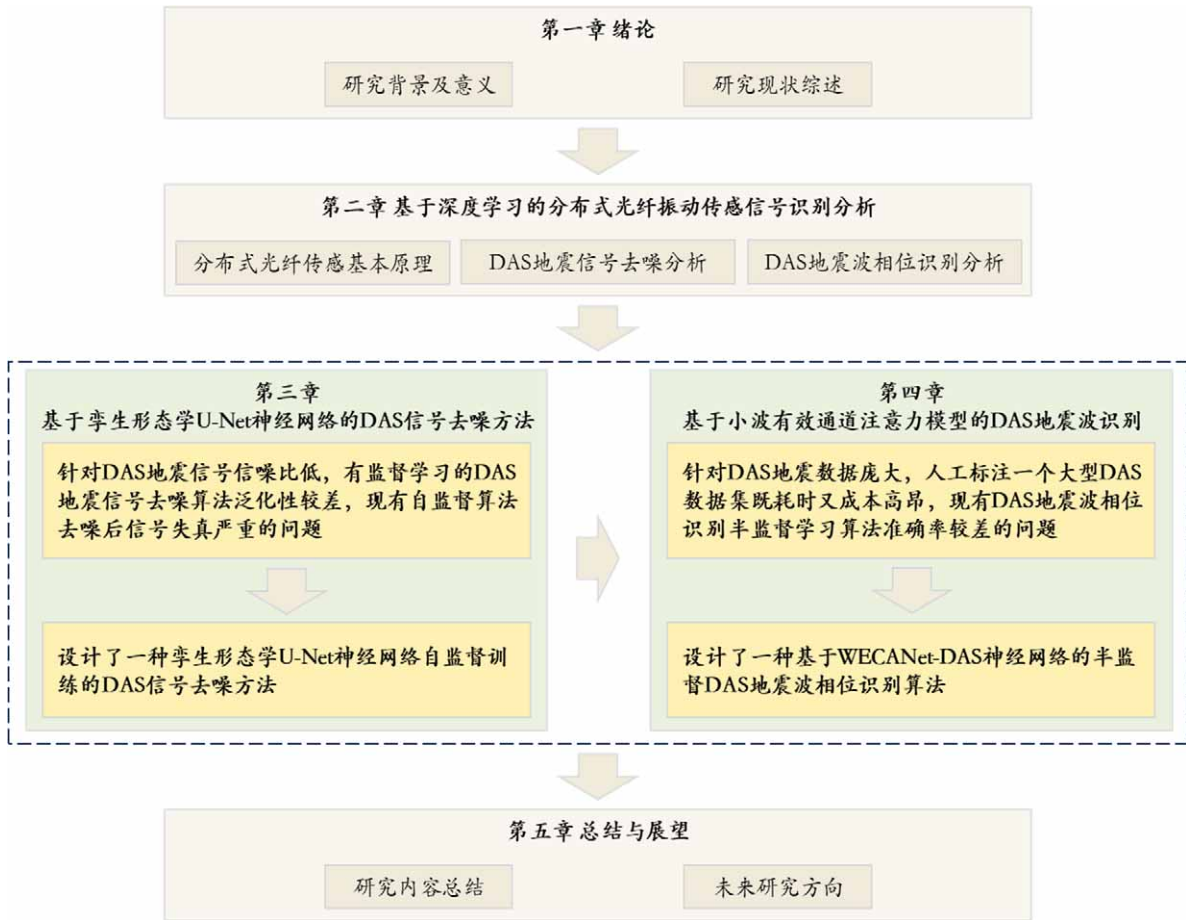


图 1.1 论文总体架构

第二章 基于深度学习的分布式光纤振动传感信号识别分析

2.1 分布式光纤传感技术基本原理

2.1.1 瑞利散射

光纤中光的散射主要分为拉曼散射、布里渊散射和瑞利散射，其中瑞利散射为弹性散射，在光子与微观介质碰撞过程中不会发生能量损失，光的强度最大。因此，分布式光纤传感通常解调光纤中的瑞利散射相关物理量来反映外界物理变化。瑞利散射过程如图 2.1 所示，光在光纤中传播时，若光纤密度不均匀，将向各个方向产生散射光，其中探测器会接收到图 2.1 所示的标为红色的后向瑞利散射光，其与入射光方向相反，会沿光纤传回。




图 2.1 瑞利散射过程

如图 2.1 所示是瑞利散射的原理图，当光纤中发生瑞利散射时，其光强计算公式如下^[71]：

$$I_r = \left(\frac{2\pi}{\lambda} \right)^4 \frac{\alpha^6}{r^4} \left[\frac{(n^2 - 1)}{(n^2 + 2)} \right]^2 (\cos^2 \theta \cos^2 \varphi + \sin^2 \varphi) \quad (2.1)$$

其中， I_r 为瑞利散射的光强度， λ 为光纤的入射波， α 为粒子的半径， r 为粒子与光纤事件扰动位置之间的距离， n 为光的有效折射率， θ 和 φ 分别表示为散射光与不同平面的夹角。

通过上述瑞利散射的光强计算公式可以发现，光的强度与入射光的波长的四次方成反比。因此，光强和波长之间的关系可以表示为公式(2.2)，当入射光的波长增大时，瑞利散射光的强度会减小^[71]。

$$I(\lambda) \propto \frac{1}{\lambda^4} \quad (2.2)$$

另外，瑞利散射的光强还与其散射方向有关。当入射光波长一定时，瑞利散射与

入射光方向夹角不同，其光强不同，具体如公式(2.3)所示：

$$I(\omega) = I_0(1 + \cos^2\omega) \quad (2.3)$$

其中， I_0 为垂直方向的上入射光强， ω 为散射光与入射光之间的夹角。

光在光纤中传播时，会受到光纤内部结构的影响，导致散射光只在向前和向后两个方向传播。当夹角 ω 为 0° 时瑞利散射光称为前向瑞利散射光，当 ω 为 180° 时称为后向瑞利散射光。如果一个光纤中的脉冲光的脉宽为 W ，则瑞利散射的功率 P_R 可以表示为：

$$P_R = PS\alpha_s W \frac{\nu}{2} = \frac{1}{4} \left(\frac{\lambda}{\pi n r} \right)^2 P\alpha_s W \frac{\nu}{2} \quad (2.4)$$

其中， P 表示光纤中脉冲光的峰值功率， S 为光功率的捕获因子， α_s 为瑞利散射的系数， ν 为光纤中光的速度， λ 为入射光的光波波长， n 为光纤纤芯的折射率， r 为光纤的模场半径。从公式(2.4)可知，瑞利散射的功率与光的功率成正比，并且与光纤纤芯的折射率有关。当光纤受到外界扰动时，光纤纤芯的折射率会发生变化，从而引起瑞利散射的功率发生变化。因此，可以通过分析光纤中瑞利散射功率的变化，来对扰动事件进行定位。

2.1.2 基于 Φ -OTDR 的 DAS 系统原理

根据上述瑞利散射原理，通过检测到的光纤中的后向瑞利散射光特性的变化，可以一定程度反映测量的环境外力参数。相位敏感光时域反射技术（ Φ -OTDR），通过解调光的相位变化来对外界干扰信息进行分析。其利用超窄线宽激光器产生的光脉冲的强相关性，它发出的激光相位会随光纤芯的折射率改变而改变^[72]。

基于 Φ -OTDR 的 DAS 系统中，瑞利散射光的相位延迟公式为^[73]：

$$\varphi = \beta L \quad (2.5)$$

其中 β 为传输常数， L 表示光纤长度。当光纤受到外界扰动时，光纤的长度、折射率和纤芯直径均会发生改变，进一步导致瑞利散射光的相位延迟发生改变，相位延迟变化 $\Delta\varphi$ 如公式(2.6)所示^[74]：

$$\Delta\varphi = \beta \Delta L + L \Delta\beta = \beta L \frac{\Delta L}{L} + L \left(\frac{\partial \beta}{\partial n} \right) \Delta n + L \left(\frac{\partial \beta}{\partial \alpha} \right) \Delta \alpha \quad (2.6)$$

其中， ΔL 为光纤长度的变化量， n 为光纤折射率， Δn 为光纤折射率的变化量， α 为纤芯直径， $\Delta \alpha$ 为纤芯直径的变化量。根据公式(2.6)可知，相位延迟的变化由光纤长度、光纤折射率和纤芯直径三项因素共同引起。其中纤芯直径引起的相位延迟变化相

比于前两个因素引起的相位延迟变化较小，因此该因素可以忽略^[72]。

如果只考虑光纤的长度变化引起的相位延迟变化，当光纤受到外界扰动时，光纤将产生轴向应变，长度为 l 光纤的弧长变化 Δl 如公式(2.7)所示：

$$\Delta l(t) = \int_{-l/2}^{l/2} \sqrt{1 + \left(\frac{dy}{dx}\right)^2} dx - l = \frac{\pi^2 y_0^2 \sin^2\left(\frac{\nu t}{2l}\right)}{l} \quad (2.7)$$

其中 ν 为振动频率， y_0 为纵向位移， x 为光纤的位置。轴向应变 e_z 如公式(2.8)所示^[72]：

$$e_z = \frac{\Delta l}{l} = \left(\frac{\pi y_0 \sin\left(\frac{\nu t}{2l}\right)}{l} \right)^2 \quad (2.8)$$

对应的相位变化如公式(2.9)所示^[73]：

$$\Delta\varphi = (1 + \gamma)\beta l e_z = 0.78\beta\pi y_0 \sin\left(\frac{\nu t}{2l}\right)^2 / l \quad (2.9)$$

其中， γ 为有效弹光系数。公式(2.5)至(2.9)表明当外力增大时， y_0 随之增大，对应的相位变化 $\Delta\varphi$ 随之增大，因此通过解调获取相位变化后，可以定量获取外界的扰动情况^[73]。

2.2 DAS 系统的性能指标

DAS 系统将一定频率的脉冲光输入到光纤中，通过解调光纤中的后向瑞利散射光，可精确获得频率、相位、振幅和位置等振动特征信息。通过这些信息可以进一步确定 DAS 系统的性能，这是后续分析 DAS 采集到的振动信号的基础。以下主要介绍 DAS 的空间分辨率、传感距离和频率响应范围几个性能指标。

(1) 空间分辨率

DAS 系统的空间分辨率描述的是 DAS 系统能够分辨不同振动事件的最小精度，能够区分不同振动事件的距离，也被称为定位精度。DAS 系统的空间分辨率 z 主要与脉冲光的脉冲宽度 T_w 有关。空间分辨率的计算公式如下^[75]：

$$z = \frac{cT_w}{2n} \quad (2.10)$$

其中， c 为光在真空中的传播速度， T_w 为脉冲光的脉冲宽度， n 为光纤的折射率。

(2) 传感距离

传感距离表征 Φ -OTDR 传感系统对系统有效监测的最大距离。光纤中一时刻只传感一个脉冲光，故测量范围 L 可定义为^[71]：

$$L = \frac{T_R c}{2n} \quad (2.11)$$

其中, T_R 为注入脉冲的重复周期, DAS 系统的传感距离与注入脉冲光的重复频率成正比。系统的实际有效测量范围取决于注入光纤中的检测光强度, 通过增加入射光的功率或应用某种放大技术可以提高系统的测量距离。

(3) 频率响应范围

DAS 系统的响应频率与注入光纤中的脉冲光的脉冲频率有关, 该指标用来描述 DAS 系统能够监测到振动的最大频率。在基于 Φ -OTDR 的 DAS 系统中, 注入脉冲的重复周期必须大于脉冲光在光纤中来回传输所需的时间, 避免相邻脉冲光造成的背向瑞利散射光叠加。脉冲光单程传输时间为 τ 为^[75]:

$$\tau = \frac{2nL}{c} \quad (2.12)$$

其中, L 为光纤的传感长度, 注入脉冲的重复周期应该大于 τ , 根据奈奎斯特定理, 系统最高频率为:

$$f_{\max} = \frac{1}{2T_R} \quad (2.13)$$

其中, 系统传感距离越短, 注入脉冲的重复周期越短, 系统的频率响应就越高。

2.3 DAS 信号去噪分析

随着深度学习技术的发展, 去噪问题正越来越多地采用深度学习方法来解决, 其中图像处理领域取得了最为显著的进展。与线性、f-k (时空频率) 或统计估计滤波器不同, 深度学习模型不受明确统计假设、响应权衡或手动参数化的限制。理想情况下, 它们具有直接从样本数据中“学习”经验性、抽象和非线性分层数据表示的能力, 从而能够在无需手动干预或对信号与噪声分布做出先验假设的情况下, 实现有效的信号过滤和特征提取。

2.3.1 有监督学习

信号去噪领域的初步成功归功于“标准”全监督范式, 该方法利用大量含噪-无噪信号对进行模型训练, 即每个训练样本均提供含噪和无噪两个信号, 模型通过直接将含噪信号映射为其无噪对应信号来进行训练。这种方法通常被称为“Noise2Clean”

(N2C), 并且已在地震信号处理上取得了显著成效^[56]。N2C 方法的目标是训练一个去噪模型 $f_\theta(x)$, 使得去噪模型 $f_\theta(x)$ 能够将含噪信号 x 转换为无噪信号 y (即真实信

号)。模型通过最小化损失函数 L 来优化模型参数 θ ，即：

$$\arg \min_{\theta} \sum_i L(f_{\theta}(x_i), y_i) \quad (2.14)$$

式中 x_i 表示第 i 个样本的含噪信号， y_i 表示第 i 个样本的无噪信号。对于每一对含噪信号和无噪信号 y_i ，模型的目标是尽量使输出 $f_{\theta}(x_i)$ 接近 y_i 。在 N2C 方法中，通常使用均方误差（MSE）损失来衡量预测信号与真实信号之间的差异，则模型的损失函数表示为：

$$L(\theta) = \frac{1}{N} \sum_{i=1}^N \|f_{\theta}(x_i) - y_i\|^2 \quad (2.15)$$

式中 N 表示样本数。然而，在许多应用中，获取足够数量的无噪或高信噪比记录信号以实现稳健的模型训练往往十分困难甚至不可能，因此该方法在实际应用中的适用性受到限制。对于 DAS 记录而言，这一问题尤为突出，因为观测数据通常受到强随机噪声过程的严重污染，而模拟地震波传播以生成覆盖长距离光纤的真实无噪信号不仅计算量大，而且建模难度较高。这种适用性受限促使研究者开发出无需无噪真实信号作为地面真值的去噪方法，例如弱监督学习^[76]或自监督学习方法^[77]。

2.3.2 弱监督学习

有监督学习在训练神经网络模型时需要大量的无噪信号作为训练目标数据，在实际应用中，尤其是在使用 DAS 监测环境等场景下，由于自然环境中的噪声通常较为强烈，且生成高信噪比的无噪信号非常耗时且计算复杂，因此有监督学习在很多实际场景下并不适用，弱监督学习则在训练过程中放宽了对无噪目标数据的要求。例如 Lapins^[59]等人提出的 DAS-N2N 方法正是基于一种开创性的弱监督去噪方法，该方法称为“Noise2Noise”（N2N）^[78]，其目标是使模型学会仅利用同一信号的含噪副本作为输入和目标训练数据，将含噪信号转换为无噪信号。

地震信号通常受到两种类型噪声的污染：相干噪声（即由某些不必要的外部来源产生的地震波）和非相干噪声（即随机噪声）。通过 DAS 记录的一个带噪声的地震信号 x 可以表示为独立信号组件的和，则信号 x 表示为：

$$x = y + n \quad (2.16)$$

其中 y 表示无噪信号，来自任何可记录外部地震源的信号（包括外部相干噪声源），而 n 是从某种噪声分布中随机抽取的样本，对于 y 中的每个元素都有一个对应的噪声样本。根据中心极限定理，噪声分布通常假设为高斯分布。

当熔接两根光纤时，第二根光纤可以同时记录无噪信号 y 的第二个含噪信号 x' ，表示为：

$$x' = y + n' \quad (2.17)$$

其中， n' 表示噪声样本，该噪声样本与噪声样本 n 独立同分布。根据 N2N 方法，将这两个含噪信号 x 和 x' 分别作为输入数据和目标数据，用于训练神经网络 $f_\theta(x)$ ，其中模型权重由 θ 表示。该神经网络通过最小化 $f_\theta(x)$ 和 x' 之间的期望损失来优化模型参数 θ ，即：

$$\arg \min_{\theta} \mathbb{E}\{L(f_\theta(x), x')\} \quad (2.18)$$

对于均方误差损失函数，这个期望损失可以表示为：

$$\mathbb{E}\{L[f_\theta(x_i), x'_i]\} = \mathbb{E}\left\{\frac{1}{M} \sum_{i=0}^M [(y_i + n'_i) - f_\theta(x_i)]^2\right\} \quad (2.19)$$

其中， i 表示训练样本索引，表示每批次的训练样本数。等式(2.19)可以展开为：

$$\begin{aligned} & \mathbb{E}\left\{\frac{1}{M} \sum_{i=0}^M [(y_i + n'_i) - f_\theta(x_i)]^2\right\} \\ &= \mathbb{E}\left\{\frac{1}{M} \sum_{i=0}^M [y_i - f_\theta(x_i)]^2\right\} + \mathbb{E}\left\{\frac{2}{M} \sum_{i=0}^M n'_i y_i\right\} \\ & \quad - \mathbb{E}\left\{\frac{2}{M} \sum_{i=0}^M n'_i f_\theta(x_i)\right\} + \mathbb{E}\left\{\frac{1}{M} \sum_{i=0}^M n'^2_i\right\} \end{aligned} \quad (2.20)$$

其中，第一项 $\mathbb{E}\{1/M \sum_{i=0}^M [y_i - f_\theta(x_i)]^2\}$ 相当于使用噪声-无噪数据对的有监督学习的 MSE 损失函数，当 n 和 n' 独立时，其余项为常数^[79]。因此，N2N 方法的损失函数表示为：

$$\mathbb{E}\{L[f_\theta(x_i), x'_i]\} = \mathbb{E}\left\{\frac{1}{M} \sum_{i=0}^M [y_i - f_\theta(x_i)]^2\right\} + C \quad (2.21)$$

这相当于标准的噪声-无噪数据对的有监督学习，只是多了一个常数 C ，该常数与噪声的方差有关。因此，N2N 方法能够与使用噪声-无噪信号数据训练的模型表现得一样好，其优势在于所有记录的数据都可以用于模型训练，而无需任何人工筛选或“生成”噪声-无噪信号对。

N2N 模型在训练过程中通过利用某些损失函数的点估计特性来抑制随机噪声^[79]。例如，均方误差 (MSE) 和平均绝对误差 (MAE) 损失函数分别通过一组观测值的均值和中位数来实现最小化。直观上，只要输入数据和目标数据中的噪声均是从某一（已知或未知）噪声分布中独立且随机抽取的，模型便不可能从输入数据中的随机噪声值

预测出目标数据中的随机噪声值。因此，为了最小化其期望损失，模型会依据所选损失函数学会将输入数据中的噪声映射为使与目标数据中噪声的平均偏差最小化的值，例如，噪声分布的均值、中位数或众数。同时，只要输入数据和目标数据中的底层干净信号一致，模型通过学习两者之间的直接一对一映射亦可使期望损失最小化。通过上述推导，以及 DAS-N2N 的实验证明，仅使用含噪信号进行训练的模型在性能上可以与采用含噪-无噪信号对进行全监督训练的模型相当，甚至更优。然而，N2N 方法存在一定局限性：在某些情况下，例如，分析未熔接的历史 DAS 数据或使用所谓的“暗”光纤，即现有未使用的电信光纤网络时，难以获取同一底层信号的多个含噪副本，此时 N2N 无法直接应用。

2.3.3 自监督学习

一种无需额外含噪或无噪目标数据进行训练的方法是自监督学习。自监督学习通常被表述为从“填空”问题中学习^[77]，即将输入数据的某一部分隐藏或屏蔽，并要求模型预测缺失数据的数值。当该方法应用于去噪任务时，其直观思路在于，通过训练，模型能够基于周围数据和大量训练样本学会内插或预测缺失的连贯或大尺度信号特征，但却无法预测随机、无序或细尺度的信号特征。与弱监督学习类似，模型通过根据某种损失函数学习将后者映射到使平均偏差最小的数值，从而最小化其期望损失。一种基于自监督方法的实现，称为 Noise2Self(N2S)^[80]，该方法已经应用于 DAS 数据去噪，被称为 jDAS^[60]。该方法在训练过程中会屏蔽单个 DAS 通道数据，模型利用相邻通道的数据来预测屏蔽通道数据，即神经网络模型有效地学会了从屏蔽通道周围的信号中重构出该通道信号。对于 jDAS 方法，模型训练的损失函数主要基于 $\mathcal{J}$ -invariant 理论，该理论具体如下。

假设 x 为含噪声的信号， x 的特征空间为 R^m ，如果 J 属于 m 是特征空间 R^m 的一个子集，则 J 中的 x 表示为 x_J 。

定义. 令 $\mathcal{J}$ 为维，并让 J 属于 $\mathcal{J}$ 。对于 x_J ，如果一个函数 $f: R^m \rightarrow R^m$ ，满足不依赖于 x_J 的值，则称函数 f 是 J -invariant。如果 $\mathcal{J}$ 中所有的 J ，函数 f 都满足 J -invariant，则函数 f 是 $\mathcal{J}$ -invariant^[80]。




图 2.2 J -invariant 感性解释图

为了能够更好的理解 J -invariant, 本文通过图 2.2 感性的解释该定义。从图 2.2 中可以了解到黄色部分的像素存在长程相干性, 假设黄色像素代表有效信息, 绿色像素代表噪声, 如果将图 2.2 中间阴影部分删掉, 则可以根据阴影部分周围相干的黄色像素将删掉的像素重构出来, 并且阴影中绿色像素由于没有足够的信息且与黄色像素不相干, 无法被重构, 因此重构出来的部分去除了绿色噪声像素。同理, 对于 DAS 采集的地震信号, 如果随机删除若干信号, 则被删除的信号中有用的地震信号可以通过周围相干的地震信号重构出来, 而不相干的噪声信息无法被重构, 从而达到去除 DAS 信号噪声的效果。




图 2.3 DAS 信号中通道屏蔽图

在 jDAS 中将输入的 DAS 信号其中一个通道作为 J , 如图 2.3 所示。 J^c 表示在输入信号的维度下 J 的补集, 则 jDAS 的损失函数 $L(f_\theta)$ 表示为:

$$L(f_\theta) = E(f_\theta(x_{J^c})_J - x_J)^2 \quad (2.22)$$

对于 jDAS 这一自监督方法尽管解决了有监督方法人工标记标签数据工作量大和弱监督方法某些情况下无法应用的问题, 但是该方法在训练时, 屏蔽的通道中的信号完全由其它通道重构, 导致该通道中原本包含的有用信号消失, 并且 jDAS 方法在重构信号时, 需要满足 J^c 中的噪声信号和 J 中的有用信号不相干, 而 DAS 在进行地震监测的时候, 由于环境、仪器、光纤耦合情况等因素, 采集到的信号包含与有用信号相干的噪声。因此, jDAS 去噪后的信号幅值大幅降低, 信号失真严重。基于上述问题, 本文提出一种增强自监督学习, 具体分析如下。

假设含噪声的 DAS 地震信号为 x , 则 x 可以表示为:

$$x = y + n \quad (2.23)$$

其中 y 表示 x 中无噪的 DAS 地震信号, n 表示噪声信号。将 x 作为神经网络的输入, 用来训练模型权重参数为 θ 的神经网络 f_θ 。本文选择均方误差 MSE 作为神经网络训练的损失函数, 则损失函数 $L(f_\theta)$ 可以表示为:

$$L(f_\theta) = E(f_\theta(x) - x)^2 \quad (2.24)$$

将公式(2.23)代入公式(2.24)中可以得到:

$$\begin{aligned} L(f_\theta) &= E(f_\theta(x) - x)^2 \\ &= E(f_\theta(x) - x + y - y)^2 \\ &= E(f_\theta(x) - y)^2 - 2E(f_\theta(x) - y)(x - y) + E(x - y)^2 \end{aligned} \quad (2.25)$$

其中公式的第一项 $E(f_\theta(x) - y)^2$ 相当于使用噪声-无噪数据对的有监督学习的 MSE 损失函数, 当噪声 n 均值为 0, 且与信号 y 独立时, 则公式的第二项 $-2E(f_\theta(x) - y)(x - y) = 0$, 第三项 $E(x - y)^2 = \sigma_n^2$ (σ_n^2 表示噪声 n 的方差), 因此损失函数 $L(f_\theta)$ 可以表示为:

$$L(f_\theta) = E(f_\theta(x) - y)^2 + D \quad (2.26)$$

这相当于使用噪声-无噪数据对的有监督学习的 MSE 损失函数加上一个与噪声方差相关的常数。在训练神经网络时, 通常是为了使损失函数达到最小化, 另外从统计学的角度看, 在样本量足够多的情况下, 公式(2.26)的最小值不会受到与噪声相关的常数 D 的影响, 即:

$$\arg \min_{\theta} E(f_\theta(x) - x)^2 \Leftrightarrow \arg \min_{\theta} E(f_\theta(x) - y)^2 \quad (2.27)$$

因此本文在训练去噪网络时, 无需任何手动生成噪声-无噪数据对, 所有的数据都可以用来训练, 减少了人工的操作成本。

进一步为了防止训练的神经网络模型成为一个恒等映射, 本文在损失函数 $L(f_\theta)$ 中加入 J -invariant 项。根据 J -invariant 理论可知, 利用 J^C 重构出 J 中有用信号的前提是 J^C 中存在与 J 长程相干的信号, 而 J^C 中的噪声信号与 J 中的有用信号不相干。但是并不是所有的噪声信号都与有用的信号不相干, 因此本文在损失函数 $L(f_\theta)$ 中加入 $E(f_\theta(x)_J - f_\theta(x_{J^C})_J)^2$ 项。该项表示当 J^C 中的噪声信号与 J 中的有用信号不相干时, $f_\theta(x)_J$ 与 $f_\theta(x_{J^C})_J$ 相等, 该项不会对损失函数 $L(f_\theta)$ 有影响; 当 J^C 中的噪声信号与 J 中的有用信号相干时, 为了避免 J^C 中的噪声信号对重构 J 的影响, 应当减小 $f_\theta(x)_J$ 与 $f_\theta(x_{J^C})_J$ 之间的差距。因此本文的损失函数 $L(f_\theta)$ 为:

$$L(f_\theta) = E(f_\theta(x) - x)^2 + \lambda E(f_\theta(x)_J - f_\theta(x_{J^C})_J)^2 \quad (2.28)$$

2.4 DAS 地震波相位识别分析

根据 1.4 节 DAS 地震波识别研究现状可知, DAS 系统采集的数据庞大, 并且大多数尚未经过人工分析师的处理。手动标注一个大型 DAS 数据集既耗时又成本高昂。依赖标签的有监督学习训练 DAS 地震波相位识别模型较为困难。针对这些问题, 使用半监督学习可以一定程度解决这些问题。

对于传统地震检波器采集到的地震数据, 在过去几十年中已经由人工分析师手动标注了大量相位到达时间数据。因此, 传统的地震检波器基于深度学习的地震波识别一般是采用有监督学习的训练方式。而 DAS 系统由于高空间分辨率、高采样频率、长时间连续观测等特点使得 DAS 系统会产生海量数据, 如果手工标注深度学习训练数据不仅费时费力, 而且在很多应用场景中, 正确标注每个事件可能需要专业领域的知识和昂贵的设备, 这使得获取高质量、全面的标注数据变得非常困难。针对这一问题, 本文使用一种 Noisy Student 半监督方法训练 DAS 地震波识别模型。以下具体介绍本文的半监督学习流程, 以及详细介绍该流程中用来提高伪标签质量的贝叶斯高斯混合模型相位关联方法 (BGaMMA)。

2.4.1 Noisy Student 半监督方法步骤

Noisy Student 方法最先是由 Xie 提出的, 它旨在通过利用大量未标记数据和在学生模型中注入噪声, 提升 ImageNet 模型的分类准确率和鲁棒性。该方法主要包含三个步骤: (1) 在标签数据上训练教师模型; (2) 利用教师模型在未标注数据上生成伪标签; (3) 将有标签数据与伪标签数据合并, 使用含噪声的训练策略来训练一个容量更大、泛化能力更强的学生模型。

根据 Noisy Student 方法, 本文利用未标注的 DAS 数据来训练深度学习地震波识别模型, 具体步骤如下:

1. 由于原始采集的 DAS 数据含有较多的背景噪声, 地震信号的信噪比较低。因此, 先通过第三章预训练的 SiamMorph-Unet 模型对原始的 DAS 数据去噪, 得到去噪后较为干净的 DAS 数据。

2. 在具有人工标注相位到达时间的地震波形上训练一个基于深度学习的地震波识别模型作为教师模型。由于人工标注一个 DAS 数据集较为困难, 并且已有多个广泛使用的深度学习地震波识别模型, 如 PhaseNet 和 EQTransformer, 因此直接使用现有的相位识别模型作为教师模型。为了能够更好的与 PhaseNet-DAS 进行对比, 本文使用与 PhaseNet-DAS 相同的教师模型 PhaseNet。

3. 将预训练的 PhaseNet 模型作为教师模型, 应用于去噪后 DAS 数据每个通道的 P 波和 S 波到达时间拾取, 从而生成 P 波和 S 波伪标签。

4. 使用相位关联方法—高斯混合模型关联器^[81] (Bayesian Gaussian Mixture Model Associator, BGaMMA) 来过滤这些拾取结果, 从而构建带有伪标签的 DAS 训练数据集。BGaMMA 仅选择在与关联地震位置相对应的理论到达时间的窄窗口内出现的拾取。在本文中将该时间窗口设为 0.3 秒。这个超参数可根据对伪标签数量和质量的需求进行调整: 较小的窗口可得到高质量但规模较小的训练数据集; 而较大的窗口则能获得规模更大的训练数据集, 但相位拾取到达时间的准确度可能有所下降。

5. 通过高斯混合模型关联器过滤后的伪标签来训练 DAS 地震波识别模型, 将该模型作为学生模型。

该方法的流程概括如图 2.4 所示。




图 2.4 Noisy Student 半监督学习流程

通过上述步骤, 可以自动生成一个拥有高质量伪标签的大规模数据集, 并在此基础上训练深度神经网络模型来处理 DAS 数据。随后, 还可以利用新训练的模型作为教师模型生成新的伪标签, 进而训练更优的模型。该过程可以重复多次以进一步提升性能。

2.4.2 贝叶斯高斯混合模型关联器

在上一节中介绍了 Noisy Student 半监督方法原理和训练的步骤, 其中获取高质量伪标签的关键是教师模型预测的 DAS 数据具有高信噪比和相位关联方法对伪标签的筛选。高信噪比的 DAS 数据可通过本文提出的 SiamMorph-Unet 模型对 DAS 数据去噪来获得, 而相位关联方法本文使用的是贝叶斯高斯混合模型关联方法, 本节将具体介绍该方法的原理。

相位识别是在各个地震台站检测诸如 P 波和 S 波等地震相位, 而相位关联则将来自地震网络多个台站的这些相位聚合为分别与各次地震相关的独立组。随后, 通过利用相位到达时间和振幅等相关相位信息来估计地震位置和震级。在地震监测系统中基

于反投影的相位关联方法最为常见，如 Hydra、Earthworm 和 SeisComP3。这些方法通常部署网格搜索，并基于距离对应的预期走时对相位拾取数据进行反投影。地震及其初步位置的确认依据是空间网格内相位拾取数据的数量。尽管基于反投影的关联方法稳健且有效，但当地震序列在时间和空间上极为密集，以至于难以解释反投影所产生的极值时，其性能会受到限制。

本文使用的基于贝叶斯高斯混合模型的相位关联方法，是一种用于聚类的无监督机器学习方法，已广泛应用于图像处理、语音识别以及地震研究等不同领域。地震相位关联可以被视为一个无监督聚类问题，其中在时间和空间上分布的相位拾取数据来源于一组离散的地震起源。将 GMM 与地震定位、起震时刻和震级估计相结合，使得高斯混合模型关联（GaMMA）方法能够基于相位到达时间走时和振幅随距离衰减的物理约束对相位拾取数据进行聚类。传统的关联方法往往忽略相位振幅信息，因为这在处理上存在一定困难，而 GaMMA 的设计使其能够同时利用相位到达时间、相位类型识别和振幅信息来进行关联，同时估计潜在的事件源特征（即位置和震级）。此外，GaMMA 不需要额外的网格搜索或监督训练等关联步骤。




图 2.5 高斯混合模型相位关联建模过程

地震相位关联的目标是对在各个地震台站上拾取的大量相位数据进行后处理，并将这些数据聚类成各自源自同一地震事件的相位组，以便对单个地震事件执行后续的地震特征描述任务。来自同一次地震的 P 波和 S 波的到达时间遵循一条由震中距离和地震波速决定的双曲线走时规律。这一走时规律使得关联算法能够区分不同地震产生的相位。在 GaMMA 中，通过同时利用相位到达时间和相位振幅信息来扩展相位关联

问题。通常，地震相位的振幅与地震震级成比例，并随震中距离增加而衰减。因此，振幅提供了额外的信息来改善相位关联。将该关联问题表述如下：给定 N 个地震相位 $(x_i, y_i, z_i, t_i, a_i)$ ，其中 t_i 和 a_i 分别为记录在位于 (x_i, y_i, z_i) 的第 i 个台站的到达时间和振幅，然后将这些相位分为 K 次地震，并估计相应的事件源参数 $(x_k, y_k, z_k, t_k, m_k)$ ，即第 k 次地震的位置信息 (x_k, y_k, z_k) 起震时刻 t_k 和震级 m_k 。在 GaMMA 中，使用高斯混合模型来解决这一关联问题，该模型是一种无监督聚类方法，通过最大化这 N 个数据点可以由 K 个高斯分布混合解释的概率，将其分为 K 个簇。将相位到达时间和振幅的物理约束引入到 GMM 中，使其适用于地震相位的关联问题。图 2.5 展示了如何对高斯分布进行建模，以计算由两个地震产生的相位序列的概率。首先基于理论相位到达时间和振幅建立高斯分布模型，从而通过各拾取点与理论到达时间及振幅的差异确定其概率。然后通过期望最大化 (EM) 算法求解相位关联任务。EM 迭代过程会收敛至每个地震事件的正确相位聚类，并估算其近似震源参数，同时利用相位到达时间和相位振幅信息进行关联。具体建模和计算过程如下。

假设将相位关联问题置于一个概率框架中，在该框架下，使用高斯分布混合来建模由多个地震源产生的每个相位拾取的概率：

$$p(x_i) = w_i \sum_{k=1}^K \phi_k \mathcal{N}(x_i | \mu_k, \Sigma_k) \quad (2.29)$$

$$\mathcal{N}(x_i | \mu_k, \Sigma_k) = \frac{1}{(2\pi)^{n/2} |\Sigma_k|^{1/2}} \exp\left(-\frac{1}{2}(x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k)\right) \quad (2.30)$$

$$\sum_{k=1}^K \phi_k = 1 \quad (2.31)$$

其中， x_i 表示第 i 个台站的相位拾取，包含到达时间和振幅 (t_i, a_i) 值。 ϕ_k 为第 k 个地震的混合权重系数。 $\mathcal{N}(x_i | \mu_k, \Sigma_k)$ 表示均值为 μ_k ，协方差矩阵为 Σ_k 的高斯分布，其均值 μ_k 对应由第 k 个地震确定的第 i 个台站的理论相位到达时间和振幅 $(\hat{t}_{ik}, \hat{a}_{ik})$ 。 w_i 是相位拾取质量评分，取值范围为 $[0, 1]$ 。 n 为特征维度数：若仅使用时间信息，则 $n = 1$ ；若同时使用时间和振幅信息，则 $n = 2$ 。基于高斯混合分布，可计算一组记录的相位 $(x_1, x_2, \dots, x_N)$ 由 K 个事件生成的概率。若假设观测值独立同分布 (i.i.d.)，则对数似然函数为：

$$\log(p(X | \phi, \mu, \Sigma)) = \sum_{i=1}^N \log\left(w_i \sum_{k=1}^K \phi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)\right) \quad (2.32)$$

通过最大化公式 (2.32) 的对数似然，可以将 N 个相位拾取关联到 K 个地震（即相位关联的目标），并估计相应的地震震源参数。

高斯混合模型（GMM）的一个局限性是需要预先假设潜在地震事件的数量 K 。为解决这一问题，采用贝叶斯高斯混合模型，利用变分推断近似计算高斯混合分布的参数后验分布。为此引入了三个共轭先验分布：

（1）混合成分系数的 Dirichlet 先验： $p(\phi) = \text{Dir}(\alpha_0)$ ，其中 α_0 为权重集中先验，用于控制混合权重的集中程度；

（2）均值的高斯先验： $p(\mu_k | \Sigma_k) = \mathcal{N}(\mu_0, \beta_0 \Sigma_k)$ ，其中 μ_0 是均值的先验， β_0 是均值的精度先验；

（3）协方差的 Wishart 先验： $p(\Sigma_k) = W(W_0, \nu_0)$ ，其中 W_0 是协方差先验， ν_0 为自由度先验。这决定了对协方差的估计。

贝叶斯模型会惩罚偏离先验的参数，从而在数据拟合和模型复杂度之间实现平衡。那些对于解释数据没有贡献的混合分量（即地震）将具有接近零的混合系数，因此可以在混合模型中选择大量冗余的地震震中，而贝叶斯 GMM 会抑制不必要的源，从而推断出与相位拾取相关的准确地震数量。

接着使用 EM 算法来求解方程(2.32)中所示的最大似然估计 $p(X)$ 。为了在关联过程中考虑相位到达时间和振幅所体现的物理约束，在 EM 算法中引入地震源参数 $(x_k, y_k, z_k, t_k, m_k)$ 和震级的估计。然后在 E 步骤中迭代更新相位拾取与地震事件之间的分配关系，并在 M 步骤中对地震参数进行优化。EM 算法具体步骤如下：

（1）E 步

$$\gamma_{ik} = \frac{\phi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)}{\sum_{k=1}^K \phi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)} \quad (2.33)$$

其中， γ_{ik} 表示相位拾取 x_i 由第 k 个地震生成的概率。

（2）M 步

1. 第 k 个地震的有效拾取数为：

$$N_k = \sum_{i=1}^N \gamma_{ik} \quad (2.34)$$

$$\phi_k = \frac{N_k}{N} \quad (2.35)$$

2. 第 k 个地震的定位、发震时间和震级为：

$$\underset{(x_k, y_k, z_k, t_k)}{\text{minimize}} I(x_k, y_k, z_k, t_k) = \sum_{i=1}^N \gamma_{ik} \mathcal{L}(t_i, \hat{t}_{ik}(x_k, y_k, z_k, t_k)) \quad (2.36)$$

$$m_k = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} \mathcal{F}'_a(a_i, d_{ik}) \quad (2.37)$$

3. 理论到达时间、振幅及残差统计量

$$\mu_k = \begin{bmatrix} \hat{t}_{ik} \\ \hat{a}_{ik} \end{bmatrix} = \begin{bmatrix} \mathcal{F}_t(x_k, y_k, z_k, t_k) \\ \mathcal{F}_a(m_k, d_{ik}) \end{bmatrix} \quad (2.38)$$

$$\Sigma_k = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} (x_i - \mu_k)(x_i - \mu_k)^T \quad (2.39)$$

其中 $\mathcal{L}$ 是相位到达时间 t_i 与第 k 个地震的理论到达时间 $\hat{t}_{ik}$ 之间绝对残差的损失函数。通过最小化损失函数 $\mathcal{L}$ ，可以估计地震的位置和发震时间 (x_k, y_k, z_k, t_k) 。 m_k 表示第 k 个地震的震级。 $\mathcal{F}_t$ 是用于计算理论相位到达时间 $\hat{t}_{ik}$ 的函数。 $\mathcal{F}_a$ 是根据地震震级 m_k 计算理论相位振幅 $\hat{a}_{ik}$ 的函数。 $\mathcal{F}'_a$ 是使用相位振幅估计地震震级的函数。 d_{ik} 是第 k 个地震到第 i 个地震台站的距离。将地震震级的优化(2.37)与地震位置和时间的优化(2.36)解耦。使用到达时间约束地震位置，相位振幅约束地震震级。尽管两个优化是解耦的，但协方差(2.39)考虑了到达时间与振幅残差之间的相关性。通过这种方式，到达时间和振幅信息均被用于地震之间的拾取聚类关联过程(2.33)。

在贝叶斯高斯混合模型中，M 步增加了一个阶段用于更新后验参数：

$$\alpha_k = \alpha_0 + N_k \quad (2.40)$$

$$\beta_k = \beta_0 + N_k \quad (2.41)$$

$$\mathbf{m}_k = \frac{1}{\beta_k} (\beta_0 \mathbf{m}_0 + N_k \mu_k) \quad (2.42)$$

$$W_k^{-1} = W_0^{-1} + N_k \Sigma_k + \frac{\beta_0 N_k}{\beta_0 + N_k} (\mu_k - \mathbf{m}_0)(\mu_k - \mathbf{m}_0)^T \quad (2.43)$$

$$\nu_k = \nu_0 + N_k \quad (2.44)$$

E 步的更新规则调整为：

$$\gamma_{ik} \propto \tilde{\pi}_k \tilde{\Lambda}_k^{1/2} \exp \left\{ -\frac{D}{2\beta_k} - \frac{\nu_k}{2} (\mathbf{x}_n - \mathbf{m}_k)^T \mathbf{W}_k (\mathbf{x}_n - \mathbf{m}_k) \right\}, \quad \sum_{k=1}^K \gamma_{ik} = 1 \quad (2.45)$$

$$\ln \tilde{\Lambda}_k = \sum_{i=1}^D \psi \left(\frac{\nu_k + 1 - i}{2} \right) + D \ln 2 + \ln |\mathbf{W}_k| \quad (2.46)$$

$$\ln \tilde{\pi}_k = \psi(\alpha_k) - \psi(\hat{\alpha}) \quad (2.47)$$

其中 $\hat{\alpha} = \sum_k \alpha_k$ ， ψ 为双伽马函数。

EM 算法的迭代过程基于地震事件更新相位拾取的聚类,并优化相应的震源参数。为了更高效的相位关联而非震源参数的精确性,因此选择两种基本方法估计近似的地震位置和震级。为减少异常值的影响,使用 Huber 损失函数优化公式(2.36):

$$\mathcal{L}_\delta(t - \hat{t}) = \begin{cases} \frac{1}{2}(t - \hat{t})^2, & |t - \hat{t}| \leq \delta \\ \delta\left(|t - \hat{t}| - \frac{1}{2}\delta\right), & |t - \hat{t}| > \delta \end{cases} \quad (2.48)$$

其中,超参数 δ 设置为 1 秒。接着使用均匀速度模型计算理论相位到达时间:

$$\hat{t}_{ik}(x_k, y_k, z_k, t_k) = \mathcal{F}_t(x_k, y_k, z_k, t_k) = \frac{d_{ik}}{v} + t_k \quad (2.49)$$

其中 v 为波速, d_{ik} 表示第 k 个地震到第 i 个台站的距离。随后,使用 BFGS 算法求解方程(2.36)的最小化问题。为估计方程(2.37)中的地震震级,假设相位振幅的对数与地震震级之间存在线性关系:

$$\hat{m}_{ik} = \mathcal{F}_a^l(a_i, d_{ik}) = c_0 + c_1 \log a_i + c_2 \log d_{ik} \quad (2.50)$$

2.5 本章小结

本章首先介绍了分布式光纤传感技术的基本原理,包含瑞利散射和基于相位敏感的光时域反射仪的 DAS 系统原理。随后,介绍了 DAS 系统的空间分辨率、灵敏度和频率响应范围等性能指标。之后分析了基于深度学习的 DAS 信号去噪存在的问题,引出了本文的 DAS 去噪方法。最后,介绍了基于 DAS 地震波相位识别的 Noisy Student 半监督方法的训练步骤,并详细介绍了贝叶斯高斯混合模型相位关联方法。

第三章 基于孪生形态学 U-Net 神经网络的 DAS 信号去噪方法

上一章介绍了基于深度学习的 DAS 信号去噪方法和各方法的优缺点，并针对现有 DAS 信号自监督去噪方法存在去噪后的信号幅值大幅降低，信号失真严重问题，提出了一种增强自监督损失函数用于神经网络模型的训练。本章基于提出的增强自监督损失函数，以及 DAS 采集到的信号特点，提出一种自监督的孪生形态学 U-Net 去噪神经网络，并详细介绍该网络的构建过程。

3.1 基于形态学滤波的卷积模块构建

3.1.1 形态学滤波原理

形态学滤波方法是通过结构元素与待滤波图片对应位置上的值计算，根据操作的不同，得到最大值或最小值替代图片上对应位置原有的值。形态学滤波包含膨胀和腐蚀两种基本操作，这两种操作是形态学滤波去噪的基础，本文以 3×3 的结构元素具体说明膨胀和腐蚀操作原理。

假设待滤波 DAS 数据为 X ，其大小为 $n \times t$ ， n 为光纤通道数， t 为光纤单个通道的采样时间，则 X 可以表示为：

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1t} \\ x_{21} & x_{22} & \cdots & x_{2t} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nt} \end{bmatrix} \quad (3.1)$$

其中，矩阵中任意一个数据 x_{ij} 表示光纤第 i 个通道在 j 时刻的值。同样，结构元素 K 可以表示为：

$$K = \begin{bmatrix} k_{11} & k_{12} & k_{13} \\ k_{21} & k_{22} & k_{23} \\ k_{31} & k_{32} & k_{33} \end{bmatrix} \quad (3.2)$$

其中，矩阵中任意一个元素 k_{ij} 表示结构元素在第 i 行 j 列位置处的值。为了保证滤波前后数据大小一致，在膨胀或腐蚀操作前先对数据 X 进行 padding 操作，padding 的大小可以通过以下公式计算：

$$\begin{aligned} P_H &= \frac{K_H - 1}{2} \\ P_W &= \frac{K_W - 1}{2} \end{aligned} \quad (3.3)$$

其中 P_H 表示数据行方向上的 padding 大小, K_H 表示结构元素的行数, P_W 表示数据列方向上的 padding 大小, K_W 表示结构元素的列数。本文中的结构元素大小为 3×3 , 因此数据行和列方向上的 padding 大小均为 1。数据 X 补零后的数据 X' 表示为:

$$X' = \begin{bmatrix} 0 & 0 & 0 & \cdots & 0 & 0 \\ 0 & x_{11} & x_{12} & \cdots & x_{1t} & 0 \\ 0 & x_{21} & x_{22} & \cdots & x_{2t} & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & x_{n1} & x_{n2} & \cdots & x_{nt} & 0 \\ 0 & 0 & 0 & \cdots & 0 & 0 \end{bmatrix} \quad (3.4)$$

根据结构元素的大小, 可以将 X' 分为 $n \times t$ 个大小为 3×3 的局部数据, 令:

$$\begin{aligned} X_{11} &= \begin{bmatrix} 0 & 0 & 0 \\ 0 & x_{11} & x_{12} \\ 0 & x_{21} & x_{22} \end{bmatrix}, \quad X_{12} = \begin{bmatrix} 0 & 0 & 0 \\ x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \end{bmatrix}, \quad \dots, \quad X_{1t} = \begin{bmatrix} 0 & 0 & 0 \\ x_{1t-1} & x_{1t} & 0 \\ x_{2t-1} & x_{2t} & 0 \end{bmatrix} \text{ 以此类推,} \\ X_{nt} &= \begin{bmatrix} x_{n-1t-1} & x_{n-1t} & 0 \\ x_{nt-1} & x_{nt} & 0 \\ 0 & 0 & 0 \end{bmatrix} \end{aligned} \quad (3.5)$$

进一步可以定义膨胀操作为 $X \oplus K$, 则 $X \oplus K$ 表示为:

$$X \oplus K = \{x_{ij} | \max(x_{ij} + k_{ij}), x_{ij} \in X, k_{ij} \in K\} \quad (3.6)$$

其中, $\{x_{ij} | x_{ij} \in X\}$ 表示局部数据 X 中位置为 (i, j) 处的数值, $\{k_{ij} | k_{ij} \in K\}$ 表示结构元素 K 中位置为 (i, j) 处的值, $\max(\cdot)$ 为取局部最大值。膨胀操作的一般步骤如下:

1. 将结构元素 K 与 X 的局部数据 X_{11} 对应元素相加得到新的矩阵 A_{11} , 即:

$$A_{11} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \quad (3.7)$$

其中, $\{a_{ij} = x_{ij} + k_{ij} | x_{ij} \in X_{11}, k_{ij} \in K\}$ 。

2. 计算 A_{11} 中最大值, 并且记录最大值所在位置 (p, q) ;
3. 将 X_{11} 中位置 (p, q) 处的值作为膨胀后的值;

4. 依次对 $X_{12}, X_{13}, \dots, X_{nt}$ 进行膨胀操作，直至完成所有数据的膨胀。

同理，将腐蚀操定义作为 $X \ominus A$ ，则 $X \ominus K$ 表示为：

$$X \ominus K = \{x_{ij} | \min(x_{ij} - k_{ij}), x_{ij} \in X, k_{ij} \in K\} \quad (3.8)$$

其中， $\{x_{ij} | x_{ij} \in X\}$ 表示局部数据 X 中位置为 (i, j) 处的数值， $\{k_{ij} | k_{ij} \in K\}$ 表示结构元素 K 中位置为 (i, j) 处的值， $\min(\cdot)$ 为取局部最小值。腐蚀操作的一般步骤如下：

1. 将结构元素 K 与 X 的局部数据 X_{11} 对应元素相加得到新的矩阵 B_{11} ，即：

$$B_{11} = \begin{bmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \\ b_{31} & b_{32} & b_{33} \end{bmatrix} \quad (3.9)$$

其中， $\{b_{ij} = x_{ij} - k_{ij} | x_{ij} \in X_{11}, k_{ij} \in K\}$ 。

2. 计算 B_{11} 中最大值，并且记录最小值所在位置 (p, q) ；

3. 将 X_{11} 中位置 (p, q) 处的值作为腐蚀后的值；

4. 依次对 $X_{12}, X_{13}, \dots, X_{nt}$ 进行腐蚀操作，直至完成所有数据的腐蚀。

进一步，可以得到开运算和闭运算，其中开运算为先进行腐蚀操作再进行膨胀操作，闭运算为先进进行膨胀操作再进行腐蚀操作。则开运算和闭运算的表示如下：

$$OPEN(X, K) = (X \ominus K) \oplus K \quad (3.10)$$

$$CLOSE(X, K) = (X \oplus K) \ominus K \quad (3.11)$$

其中， $OPEN(\cdot)$ 表示开运算， $CLOSE(\cdot)$ 表示闭运算。

通过上述形态学滤波原理可以发现，形态学滤波方法在对数据进行滤波时，其中结构元素值的选取至关重要，这决定着滤波的效果。但是面对不同数据，结构元素的选取依赖对该数据的理解，这带来了结构元素取值的困难。其次，可以发现，形态学滤波在对数据进行滤波后，数据滤波后的值为原始的数据值，无法产生新的值，这在一定程度上制约了滤波后的效果。因此，可以使用卷积神经网络中的卷积核替代形态学滤波中的结构元素，根据不同数据通过反向传播自动更新结构元素的值，然后通过训练神经网络模型模拟形态学滤波的过程。另外，根据卷积的计算方式以及在神经网络中加入激活函数，滤波后的数据存在着和原始数据不同的变异值。

3.1.2 形态学卷积模块构建

在上一节中，了解到形态学滤波存在结构元素取值困难，以及滤波后的数据无法产生新的值，制约了滤波后的效果。而后提出了使用神经网络的方式解决上述问题。

本节具体介绍形态学卷积模块的创建。

在神经网络中，卷积的运算方式与形态学滤波的运算方式类似，给定一个矩阵 $X \in \mathbb{R}^{H \times W}$ 和一个卷积核 $K \in \mathbb{R}^{M \times N}$ ，一般 $M \ll H, N \ll W$ ，其卷积操作的输出矩阵 Y 的每个元素 y_{ij} 为：

$$y_{i,j} = \sum_{m=1}^M \sum_{n=1}^N X_{i+m-1,j+n-1} \cdot K_{m,n} \quad (3.12)$$

其中， i 和 j 是输出矩阵的行和列索引，输出矩阵 Y 的大小为 $(H - M + 1) \times (W - N + 1)$ ， m 和 n 是卷积核的行和列索引。

进一步考虑卷积核滑动的步长 s 和填充大小 $p_h \times p_w$ ，则卷积操作的输出矩阵 Y 的大小为：

$$\begin{aligned} Y_H &= \left\lfloor \frac{H + 2p_h - k_M}{s} \right\rfloor + 1 \\ Y_W &= \left\lfloor \frac{W + 2p_w - k_N}{s} \right\rfloor + 1 \end{aligned} \quad (3.13)$$

矩阵 Y 中每个元素 y_{ij} 为：

$$y_{i,j} = \sum_{m=1}^M \sum_{n=1}^N X_{i \cdot s + m - p_h, j \cdot s + n - p_w} \cdot K_{m,n} \quad (3.14)$$

卷积操作的具体步骤如下：

1. 为了控制输出矩阵的大小，在输入矩阵周围填充零。
2. 将卷积核 K 在输入矩阵 X 上滑动，每次滑动一个步长 s 。
3. 在每个滑动位置，按照公式(3.12)计算卷积核与输入矩阵对应位置的元素乘积，并求和。
4. 将每个滑动位置的加权和作为输出矩阵的对应元素。

通过卷积的操作方式与形态学滤波运算方式相对应，使用卷积核替代形态学滤波中的结构元素，将膨胀操作中的相加计算替换为神经网络中的卷积计算，然后利用神经网络中的最大池化选择最大值。即形态学膨胀卷积（Morphological Dilated Convolution, MDConv）表示如下：

$$X_{dilate} = \sigma(\text{Conv}(\text{MaxPool}(\sigma(\text{Conv}(X)))))) \quad (3.15)$$

其中， X_{dilate} 表示 X 经过形态学膨胀卷积后的特征， $\sigma(\cdot)$ 表示神经网络的激活函数， $\text{Conv}(\cdot)$ 表示神经网络的卷积操作， $\text{MaxPool}(\cdot)$ 表示神经网络最大池化操作。形态学膨胀卷积模块如图 3.1 所示。




图 3.1 形态学膨胀卷积

同理，可以定义形态学腐蚀卷积（Morphological Erosion Convolution, MEConv）。和膨胀操作相反，腐蚀操作是先将局部数据与结构元素相减，然后取相减后的最小值。但是在目前主流神经网络中没有相减的操作，以及最小池化层。因此，本文为了模型的通用性和兼容性，先将 X 取反，然后再进行卷积操作，模拟形态学腐蚀操作中相减的过程；另外，通过最大池化层选择取反后的最大值，由于在最大池化之前对数据进行了取反操作，因此，这里得到的最大值是原始数据中的最小值的相反数，然后再对通过最大池化操作后的数据取反得到最小值。形态学腐蚀卷积表示如下：

$$X_{erode} = -\sigma(\text{Conv}(\text{MaxPool}(\sigma(\text{Conv}(-X)))) \quad (3.16)$$

其中， $-X$ 表示对数据取反。形态学腐蚀卷积如图 3.2 所示。




图 3.2 形态学腐蚀卷积

在形态学滤波中，形态学膨胀操作和形态学腐蚀操作是形态学开运算和形态学闭运算的基础。通常，想要对一组二维数据进行滤波时，会将形态学开运算和形态学闭运算结合使用，经过若干次开运算和闭运算之后得到滤波后数据。同样，在形态学卷积模块的构建中，可以参照形态学滤波中的开运算和闭运算，构建形态学开卷积模块（Morphological Open Convolution Module, MOCM）和形态学闭卷积模块（Morphological Close Convolution Module, MCCM）。先经过形态学腐蚀卷积模块再经过形态学膨胀卷积的形态学开卷积模块如图 3.3 所示。




图 3.3 形态学开卷积模块

同理，参照形态学中闭运算方式，构建先经过膨胀卷积再经过腐蚀卷积的形态学闭卷积模块。形态学闭卷积模块如图 3.4 所示：




图 3.4 形态学闭卷积模块

3.2 孪生形态学神经网络模型构建

上一节中，本文主要基于形态学滤波操作，定义了形态学开卷积模块和形态学闭卷积模块，为构建孪生形态学模型提供了基础。本节着重阐述孪生形态学模型的构建过程。

由于 U-Net 模型的编码器-解码器结构能有效地在图像中保留重要的细节信息，从而实现高质量的去噪。另外，模型中的跳跃连接可以将编码器阶段的低层特征直接传递到解码器对应层，从而帮助网络在恢复图像时能够同时利用低级别和高级别的特征信息。这种结构不仅提高了去噪效果，还增强了网络对细节和边缘的恢复能力，避免了由于信息丢失而导致的模糊。因此，在本文中，使用 U-Net 结构作为本文孪生形态学神经网络模型的基础结构，为了提高去噪效果，本文构建了形态学开卷积模块和形态学闭卷积模块替换 U-Net 模型中原始的卷积层，并且在模型的编码器与解码器之间加入形态学多尺度卷积注意力模块（Multi-scale Convolutional Attention Module, MSCAM），使模型更关注有用信号的特征。该模型是一个 U 型结构，包含输入层、编码器、解码器和输出层 4 部分，模型整体结构如图 3.5 所示。




图 3.5 孪生形态学神经网络架构

对于一个二维 DAS 信号 $X \in \mathbb{R}^{N \times T}$ ，其中 N 表示 DAS 信号通道数， T 表示在单个 DAS 通道上的采样点数。则根据本文 2.3.3 节中提出的损失函数(2.28)可以得到，输入数据包含噪声信号 X 和经过掩码后的 X_{jc} 。

编码器部分包含两个 3×5 卷积、四个最大池化层和三个形态学开卷积模块。输入的 DAS 数据首先经过第一层的两个卷积提取特征。随后该特征经过最大池化层后数据的大小降低为 $N \times T/2$ ，再将该特征输入到第二层形态学开卷积模块。第三、四和五层卷积均为最大池化层和形态学开卷积模块，数据经过这三层后时间维度的大小都降低为原来的一半，分别为 $N \times T/8$ 、 $N \times T/16$ 和 $N \times T/32$ 。从第二层卷积到第五层卷积数据特征的通道数分别为 16、32、64 和 128。编码器通过卷积操作提取数据的特征，并逐步降低数据的空间分辨率，形成一个抽象的特征表示。

解码器部分设置的层数和编码器部分相同，形成对称 U 型结构。解码器中，包含四层上采样和形态学闭卷积模块，经过该四层中的每层卷积后数据的大小都增加为原来的两倍，特征通道数都降为原来的一半。解码器的最后一层包含一个 1×1 大小的卷积，该层最终输出去噪后的数据。

另外，本文在模型的编码与解码器之间加入多尺度卷积注意力模块，将每层编码器输出的特征输入到多尺度卷积注意力模块中提取注意力特征，然后将提取到的特征输入到对应解码器层中，使模型更关注有用信号的特征，降低信号去噪后的误差。该模块结构如图 3.6 所示。其中多尺度卷积注意力模块的计算过程为：输入特征首先经过 3×3 卷积核提取特征，然后将提取到的特征分别经过 1×5 、 5×1 卷积核路径；1

$\times 7$ 、 7×1 卷积核路径； 1×11 、 11×1 卷积核路径。再将三条路径得到的特征和 3×3 卷积核提取特征到的特征逐元素相加，相加后的特征通过 1×1 卷积核卷积运算进行特征融合，最后与输入特征逐元素相乘。




图 3.6 多尺度卷积注意力模块结构

3.3 实验数据和模型训练

3.3.1 实验数据

本节主要介绍用于模型训练和实验分析的数据集，包括 DAS 系统采集到的真实数据和使用三分量地震仪采集到的地震数据合成的 DAS 数据。

（1）实际的 DAS 数据

本文采用两个公开的 DAS 数据对模型进行训练，验证本章提出的 DAS 去噪方法的有效性。这两个公开的 DAS 数据为 HCMR 数据和 NESTOR 数据。HCMR 数据由 HCMR 光纤在 2019 年 4 月 18 日至 19 日采集的数据，该光纤连接了位于爱奥尼亚海的 EMSO Hellenic Arc 节点和 Methoni 的陆地站点，由希腊海洋研究中心（HCMR）管理，因此称为 HCMR 光纤。NESTOR 数据由中微子扩展海底望远镜与海洋研究项目（NESTOR 项目）中使用的光纤在 2019 年 4 月 19 日至 25 日采集的数据，同样连接了海底观测站和 Methoni 的希腊大陆。两条光纤均使用 Febus Optics 公司开发的商业 Febus A1 DAS 询问器进行传感。HCMR 和 NESTOR 两根光纤的标距长度和 DAS 通道间距均为 19.2 米，采样间隔分别为 6 毫秒和 5 毫秒。

为了本文研究的目的，将数据滤波在 1-10Hz 的频率范围内，并以 50Hz 的频率进行时间下采样。然后，从 HCRM 中选择了 21 个事件，从 NESTOR 中选择了 8 个事件，这些事件被识别为（潜在的）地震，其中 6 个已被定位和编目。对于每个事件，本文提取了一个 41 秒的时间窗口内的数据，包含 2048 个时间样本，该窗口大致围绕高幅度地震波列的首次到达。最后，对每个通道的数据进行了标准差归一化处理。HCRM 和 NESTOR 部分数据如图 3.7（a）和（b）所示，从展示的部分数据中可以看出，DAS 采集到的信号中含有大量噪声。




图 3.7 实际 DAS 数据。（a）HCRM 数据；（b）NESTOR 数据

（2）合成的 DAS 数据

为了对模型的性能有一个初步的了解，将模型先在合成的 DAS 数据集上训练。本文利用美国加利福尼亚州 Pinon Flats 观测站阵列的 82 次单独地震的三分量宽带地震仪记录中获得的干净应变率波形合成 DAS 数据。通过 DAS 通道测量的应变率与地震检波器测量的粒子速度之间的有限差分关系来合成干净的 DAS 应变率波形，DAS 在位置 x 处记录的应变率 $\dot{\epsilon}_{DAS}(x)$ 表示为：

$$\dot{\epsilon}_{DAS}(x) = \frac{\dot{u}\left(x + \frac{L}{2}\right) - \dot{u}\left(x - \frac{L}{2}\right)}{L} \quad (3.17)$$

其中 $\dot{\epsilon}_{DAS}(x)$ 表示 DAS 在 x 通道位置的应变率， L 表示 DAS 的标距， $\dot{u}$ 表示 DAS 通道 x 两侧半标距的地震检波器记录的粒子速度。

进一步模拟 DAS 的应变率记录，本文选取阵列中的两个宽频台站，这两个台站相距 50m，并通过它们各自波形记录之差除以台站间距来计算应变率波形。由于这些浅埋钻孔地震仪的噪声水平极低，所得到的应变率波形具有极高的信噪比。PFO 的宽频台站采样频率为 40Hz，因此，为了模拟一个 1-10Hz 频带、采样率为 50 Hz 的信号，即 0.04-0.4 倍奈奎斯特频率的范围，本文对合成波形进行了 0.8-8Hz 频带滤波。所有

波形根据各自的标准差进行归一化，使得不同波形之间在幅值上具有可比性。这些经过处理的波形被称为“母”波形（master waveforms），如图 3.8 所示。




图 3.8 DAS 合成数据母波形

在模型训练过程中，每个训练周期样本的合成过程如下：

1. 随机选取一条母波形，如图 3.9 (a) 所示。另外从一个范围为 ± 0.2 到 10km/s 的分布中随机抽取一个波速值，该波速决定了地震波在空间上传播时的移动时间差。




图 3.9 母波形裁剪。(a) 原始母波形；(b) 裁剪后的母波形

2. 对选择的母波形进行裁剪，选取包含 2048 个采样点的窗口，如图 3.9 (b) 所示。该窗口的位置在首波到达附近随机选取，以增加数据的多样性，防止模型过拟合于特定的时间窗结构。

3. 从 $[0.01, 100]$ 均匀分布中随机抽取一个 SNR 值，并对波形进行重新缩放，使得信号的最大幅值达到 $2\sqrt{SNR}$ 。

4. 将缩放后的信号叠加上单位方差的高斯白噪声，然后进行标准差归一化。

5. 创建该含噪波形的 N 个副本，然后对每个副本施加时间偏移，使其模拟波在不同空间位置的到达延迟。时间偏移计算公式为：

$$\Delta T_i = \text{int}\left(\frac{iLf}{v}\right) \quad (3.18)$$

其中， ΔT_i 为第 i 个副本的时间偏移量（ $0 < i < N$ ）， L 为标距长度（30m）， f 为采样频率（50Hz）， v 为表观波速。

6. 通过对信号进行随机极性翻转和时间反转来增强数据集。

7. 选择合成的 DAS 数据中的一个通道进行掩码。

每个训练周期样本的合成流程图如下：




图 3.10 每个训练周期样本的合成流程图

3.3.2 模型训练

实验在 64 位 Windows11 操作系统上运行, 硬件配置为 AMD Ryzen 7 7745HX with Radeon Graphics 3.60 GHz CPU, 16GB 内存和 NVIDIA GeForce RTX 4060 GPU。使用 Python 版本为 3.7.1, 使用核心库 Tensorflow 为 2.2.0 版本。

算法 3.1 基于孪生形态学 U-Net 神经网络的自监督学习去噪算法

输入: DAS 数据集 D , SiamMorph-Unet 模型参数 θ_0 , 批量大小 M , 最大迭代次数 Q , 波形副本数 N 。

输出: 训练后 SiamMorph-Unet 模型参数。

初始化: 初始化 θ_0 。

1. **While** $q < Q$ **Do**
 2. 通过图 3.10 流程合成训练数据 X 和掩码后的数据 Y 。
 3. **For** $i = 1$ to I **Do**
 4. $X^{(0)}, Y^{(0)} = \text{Conv}(X, Y)$ #卷积操作。
 5. **For** $i = 1$ to K **Do** #编码器。
 6. $X_{\text{MaxPool}}^{(i)}, Y_{\text{MaxPool}}^{(i)} = \text{MaxPool}(X^{(0)}, Y^{(0)})$ #使用最大化层下采样。
 7. $X_{\text{MOCM}}^{(i)}, Y_{\text{MOCM}}^{(i)} = \text{MOCM}(X_{\text{MaxPool}}^{(i)}, Y_{\text{MaxPool}}^{(i)})$ #形态学开卷积操作。
 8. **End For**
 9. **For** $i = 1$ to K **Do** #解码器。
 10. **If** $i = 1$ **Do**
 11. $X_{\text{UpSample}}^{(i)}, Y_{\text{UpSample}}^{(i)} = \text{UpSample}(X_{\text{MOCM}}^{(K)}, Y_{\text{MOCM}}^{(K)})$ #上采样操作。
 12. **Else**
 13. $X_{\text{UpSample}}^{(i)}, Y_{\text{UpSample}}^{(i)} = \text{UpSample}(X_{\text{MCCM}}^{(i-1)}, Y_{\text{MCCM}}^{(i-1)})$
 14. **End If**
 15. $X_{\text{MSCAM}}^{(i)}, Y_{\text{MSCAM}}^{(i)} = \text{MSCAM}(X_{\text{MOCM}}^{(K-i)}, Y_{\text{MOCM}}^{(K-i)})$ #多尺度卷积注意力操作。
 16. $X_{\text{skip}}^{(i)}, Y_{\text{skip}}^{(i)} = \text{Concatenate}([X_{\text{UpSample}}^{(i)}, X_{\text{MSCAM}}^{(i)}], [Y_{\text{UpSample}}^{(i)}, Y_{\text{MSCAM}}^{(i)}])$ #跳跃连接
 17. $X_{\text{MCCM}}^{(i)}, Y_{\text{MCCM}}^{(i)} = \text{MCCM}(X_{\text{skip}}^{(i)}, Y_{\text{skip}}^{(i)})$ #形态学闭卷积操作。
 18. **End For**
 19. **End For**
 20. 根据公式 (2.28) 计算损失函数, 更新模型参数。
 21. **End While**
-

在模型训练之前, 为了提高真实的 DAS 数据集收敛速度, 本文首先在合成数据集上训练模型。将数据集 8:2 拆分为训练集和验证集, 并使用这些单独的数据集来生成训练和验证样本。在每个训练周期后按照上一节中合成 DAS 的步骤生成一批新的合成样本, 从而减轻过拟合, 一个训练周期包含 3424 个样本。训练过程采用 Adam 优化器对参数进行优化, 学习率为 0.0004, batch size 设置为 32, 训练 2000 个 epoch。然后将合成 DAS 数据集上训练的模型参数作为实际 DAS 数据集上模型训练的预训练参数, 接着在实际 DAS 数据集上训练。在 HCMR 数据的 21 个事件和 NESTOR 数据的 8 个事件中, 分别选择 4 个和 2 个事件用于验证, 其余事件用于训练。在训练过程中, 随机选取一个事件, 并随机确定一个中心 DAS 通道。然后从中心通道的左右各

取 5 个通道，总共形成一个包含 11 个 DAS 通道的集合，在这 11 个通道中，随机选择一个作为目标通道，对其进行掩码。模型可以利用剩余的 10 个通道信息来重建这个被屏蔽的目标通道的数据。同样，在实际 DAS 数据上使用极性翻转和时间反转来增强数据集。将波形进行时间反转，虽然这种操作在物理上不具备实际意义，但作为数据增强手段，可以有效增加训练样本的变化，从而鼓励模型更好地泛化。每个训练周期结束后都会生成一批新的样本。由于预训练的缘故，模型在大约 50 个周期（15 分钟）后在验证集上已达到令人满意的性能饱和值，这表明对新的 DAS 数据集进行进一步的微调只需少量时间。为了更清楚的表述，基于孪生形态学 U-Net 神经网络的自监督学习去噪算法训练的主要过程如算法 3.1 所示。

3.3.3 评估指标

为了能够更好的对比不同去噪方法的去噪效果，本文使用信噪比和均方误差两个评价指标对去噪方法进行定量分析

（1）信噪比（Signal-to-Noise Ratio, SNR）

信噪比是表征信号与背景噪声能量分布关系的核心参数，其对数化表达形式如式 (3.19) 所示：

$$SNR = 10 \log \frac{P_{signal}}{P_{noise}} \quad (3.19)$$

式中， P_{signal} 和 P_{noise} 分别对应有效信号与噪声的功率谱密度积分值。针对分布式光纤声波传感（DAS）系统的多通道特性，SNR 可进一步划分为全局信噪比（Global SNR）和局部信噪比（Local SNR）两类，其中全局信噪比的计算公式如下：

$$Global\ SNR = 10 \log_{10} \frac{\sum_{j=1}^n \sum_{i=1}^t (s_{ij} - \bar{s})^2}{\sum_{j=1}^n \sum_{i=1}^t (x_{ij} - s_{ij})^2} \quad (3.20)$$

式中， n 为 DAS 数据通道数，为每个通道数据的采样点数， s 为干净信号， x 为去噪后的信号， $\bar{s}$ 为干净信号的均值。

（2）均方误差（Mean Squared Error, MSE）

均方误差通过量化去噪信号 x_{ij} 与干净信号 s_{ij} 的偏差程度，直接反映算法对信号波形的保真能力，其定义如公式 (3.21) 所示：

$$MSE = \frac{1}{n \times t} \sum_{i=1}^n \sum_{j=1}^t (x_{ij} - s_{ij})^2 \quad (3.21)$$

其中， x_{ij} 为去噪后的 DAS 信号， s_{ij} 为干净的 DAS 信号， n 为 DAS 数据通道数， t 为每个通道数据的采样点数。MSE 值越小，表明去噪结果与原始信号相似度越高，算法

对噪声抑制及信号保留能力越强；反之，MSE 增大则反映去噪过程引起信号畸变，算法性能下降。

3.4 实验结果与分析

3.4.1 合成 DAS 数据去噪结果

为了验证孪生形态学 U-Net 模型的去噪性能，首先使用合成 DAS 数据来对其进行测试，并与带通滤波、小波变换、NLM 和 jDAS 算法的去噪效果进行对比。图 3.11

(a) 展示的是几乎干净的 DAS 数据，其中包含了 300 个地震道，每个地震道包含了 2048 个采样记录，时间采样率为 2ms，空间采样率为 19.2m。图 3.11 (b) 展示的是添加了信噪比为 10 的随机噪声的合成含噪数据，可以看见 P 波信号被噪声所影响失真。图 3.11 (c) 展示的是添加了信噪比为 1 的随机噪声的合成含噪数据，可以看见 P 波信号完全被噪声所覆盖，S 波信号也失真。




图 3.11 合成 DAS 数据。(a) 干净的 DAS 数据；(b) 添加信噪比为 10 的随机噪声的含噪 DAS 数据；(c) 添加信噪比为 1 的随机噪声的含噪 DAS 数据。

图 3.12 (a) 到 (d) 显示的使用不同去噪算法对信噪比为 10 的随机噪声的含噪

DAS 数据去噪后得到的结果。图 3.12 (a) 是使用 1-20Hz 巴沃斯带通滤波处理得到的结果；图 3.12 (b) 利用 sym4 的小波基，4 层变换的小波变换处理后得到的结果；图 3.12 (c) 是使用非局部均值滤波 (Non-Local Means, NLM) 去噪得到的结果；图 3.12 (d) 是 jDAS 算法处理后得到的结果；图 3.12 (e) 是使用本文算法 SiamMorph-Unet 处理后得到的结果。




图 3.12 信噪比为 10 时不同去噪算法处理后的结果。(a) 带通滤波；(b) 小波变换；
(c) NLM；(d) jDAS；(e) SiamMorph-Unet。

从图 3.12 可以发现，在对包含信噪比为 10 的 DAS 信号去噪时，传统的去噪方法

带通滤波、小波变换和非局部均值滤波，经过处理后的信号要么保持较强的背景噪声，要么有效信号泄露严重。jDAS 算法能有效分离高斯白噪声和有效信号，具有良好的背景噪声抑制能力，经过处理后的数据的背景噪声得到了明显的减弱，但是在信号较弱的初始波和尾波部分，出现了许多条状噪声，信号失真。本文的算法 SiamMorph-Unet 相比于 jDAS 实现了更进一步的噪声压制，并且去噪后信号没有出现条状噪声。




图 3.13 信噪比为 1 时不同去噪算法处理后的结果。(a) 带通滤波；(b) 小波变换；(c) NLM；(d) jDAS；(e) SiamMorph-Unet。

图 3.13 (a) 到 (d) 显示的使用不同去噪算法对信噪比为 1 的随机噪声的含噪 DAS

数据去噪后得到的结果。图 3.13 (a) 是使用 1-20Hz 巴沃斯带通滤波处理得到的结果；图 3.13 (b) 利用 sym4 的小波基，4 层变换的小波变换处理后得到的结果；图 3.13 (c) 是使用非局部均值滤波去噪得到的结果；图 3.13 (d) 是 jDAS 算法处理后得到的结果；图 3.13 (e) 是使用本文算法 SiamMorph-Unet 处理后得到的结果。

从图 3.13 可以发现，当信噪比为 1 时，带通滤波去噪后的 DAS 信号依然保持较强的背景噪声，去噪效果欠佳。小波变换和非局部均值滤波去噪后的 DAS 信号只含有信号强度较强的部分，信号较弱的初始波和尾波被去除，去噪后信号恢复较差。jDAS 去噪后的 DAS 信号，噪声得到了较好的抑制，但是初始波和尾波部分失真较为严重。相比之下，本文的噪声去除更彻底，去噪后的信号 S 波的幅值只是略微降低，初始波和尾波也得到了较好的恢复。

为了验证不同去噪算法对于局部细节的还原能力，从信噪比为 1 的 DAS 数据的局部区域选择了一个 30×200 尺寸的小切片数据。图 3.14 (a) 到 (d) 显示的是选择的局部切片数据在 DAS 数据中的具体位置（红框所示）。




图 3.14 选取的局部切片数据。(a) 干净的 DAS 数据；(b) 位于 (a) 中红框内的局部切片；(c) 含噪的 DAS 数据；(d) 对应于 (c) 中红框内的局部切片

图 3.15 (a) 到 (e) 分别是经过不同去噪算法处理后的 DAS 数据在相同位置的局部切片数据。可以观察到：对于被噪声淹没的微弱有效信号，带通滤波存在大量噪声

未去除，有效信号完全淹没在噪声中，小波变换和 NLM 这两种方法把原有的有效信号去除，无法将原有的有效信号还原，jDAS 去噪方法能够很好的去除噪声的同时将部分信号还原出来，但信号的特征变化的较为严重，而 SiamMorph-UNet 算法能够较好的将信号的纹理特征基本还原出来，背景噪声也得到了最大的抑制。




图 3.15 不同去噪算法处理后的局部切片数据。(a) 带通滤波；(b) 小波变换；(c) NLM；(d) jDAS；(e) SiamMorph-UNet

为了评估不同去噪算法对于振动波形的影响，从不同去噪结果中选取单道数据进行对比分析。这里，选取的是第 80 道数据，该地震道接收到的地震信号最为明显。图

3.16 (a) 到 (f) 显示的是不同方法处理后第 80 道振动信号数据和干净数据的对比。从下图可以看出, 带通滤波去噪后振动信号的幅度不仅发生了畸变而且还含有较多噪声; 小波变换去噪后无法恢复幅度较低的部分, 幅度较高的部分也发生了畸变; NLM 去噪后振动信号幅度较高的部分恢复的比较好, 但是幅度较低的部分无法恢复; jDAS 和 SiamMorph-Unet 这两种方法在去噪后, 对有效振动信号幅度的影响较小, 振动波形还原度较高, 其中 SiamMorph-Unet 方法去噪后振动波形信号幅度恢复的更好, 特别是在振动波形幅度较低的部分 SiamMorph-Unet 去噪后的振动波形幅度得到了很好的恢复。




图 3.16 经过不同方法处理后的第 80 道振动信号和干净信号对比。(a) 原始含噪信号; (b) 带通滤波; (c) 小波变换; (d) NLM; (e) jDAS; (f) SiamMorph-Unet

前面都是从定性的角度分析不同去噪算法的去噪性能, 以下基于整体信噪比

(SNR) 和均方误差 (MSE) 这两个指标来定量地对不同去噪算法的性能进行评估。本文选取了三个噪声强度不同的合成数据进行测试, 测试结果如表 3.1 到表 3.3。

表 3.1 信噪比为 10 时, 各个方法去噪处理后 SNR 和 MSE 对比

去噪方法	SNR	MSE
原始含噪信号 (为处理)	10	0.14587
带通滤波	11.13141	0.13532
小波变换	5.7204	0.4704
非局部均值滤波	9.17012	0.21257
jDAS	15.04881	0.05491
SiamMorph-Unet	19.54039	0.01952

表 3.2 信噪比为 1 时, 各个方法去噪处理后 SNR 和 MSE 对比

去噪方法	SNR	MSE
原始含噪信号 (为处理)	1	1.46364
带通滤波	1.12074	1.35654
小波变换	2.37625	1.01597
非局部均值滤波	8.58111	0.24344
jDAS	9.61549	0.19185
SiamMorph-Unet	13.16575	0.08471

表 3.3 信噪比为-10 时, 各个方法去噪处理后 SNR 和 MSE 对比

去噪方法	SNR	MSE
原始含噪信号 (为处理)	-10	14.66288
带通滤波	-8.88687	13.58923
小波变换	0.23923	1.66182
非局部均值滤波	4.64838	0.60210
jDAS	4.70195	0.59472
SiamMorph-Unet	7.04420	0.34681

从上面实验数据可以看出, 对于不同信噪比的噪声经过 SiamMorph-Unet 去噪方法处理后的数据, 信噪比要明显好于其它算法, 均方误差要普遍低于其他算法, 说明利用该方法处理后的 DAS 数据对于噪声的抑制效果更好, 对原始有效信号的还原能力更强。

3.4.2 实际 DAS 数据去噪结果

为了验证算法应用于实际数据的真实效果, 使用合成数据训练的模型参数作为预训练参数, 继续在 HCMR 数据和 NESTOR 数据上训练, 然后分别从 HCMR 和 MESTOR 验证集中分别选择一个地震事件测试。如图 3.7 所示。




图 3.17 不同去噪算法对 HCMR 数据处理后的结果。(a) 带通滤波；(b) 小波变换；
(c) NLM；(d) jDAS；(e) SiamMorph-Unet。

图 3.17 (a) 到 (e) 和图 3.18 (a) 到 (e) 为使用不同去噪算法对 HCMR 数据和 NESTOR 数据去噪后得到的结果。图 3.17 (a) 和 3.18 (a) 是使用 1-20Hz 巴沃斯带通滤波处理得到的结果，图 3.17 (b) 和 3.18 (b) 是利用 sym4 的小波基，4 层变换的小波变换处理后得到的结果，图 3.17 (c) 和 3.18 (c) 是非均值局部滤波处理后得到的结果，图 3.17 (d) 和 3.18 (d) 是 jDAS 算法处理后得到的结果，图 3.17 (e) 和 3.18 (e) 是 SiamMorph-Unet 算法处理后得到的结果。从图中可以观察到，传统的去噪算

法中，带通滤波对于数据中存在的随机噪声的抑制效果不佳，处理后的数据依然存在大量的噪声；小波变换和 NLM 虽然在一定程度上有效消除了噪声，但是却是以损伤了大部分信号特征为代价；jDAS 和 SiamMorph-Unet 不仅消除了数据中存在的大量噪声，并且保留了绝大部分有效信号的特征，但是 jDAS 去噪后的信号强度降低，相比之下 SiamMorph-Unet 方法去噪后有效信号细节特征和信号强度保留的更完整。




图 3.18 不同去噪算法对 NESTOR 数据处理后的结果。(a) 带通滤波；(b) 小波变换；(c) NLM；(d) jDAS；(e) SiamMorph-Unet。

为了评估不同去噪算法对于振动信号幅度的影响，从不同去噪结果中选取单道数

据进行对比分析。这里，选取的是 NESTOR 光纤的第 500 道数据。图 3.19 (a) 到 (e) 对应不同去噪算法处理前和处理后 NESTOR 光纤的第 500 道振动信号数据对比。可以看出，带通滤波后振动波形中仍然含有大量噪声，基本无法去除波形当中的噪声；小波变换处理后的数据，振动信号的幅度大幅降低，信号发生畸变；经过 NLM 处理后的数据，幅度较低初始波和尾波部分信号失真，幅度降低；jDAS 处理后的数据，振动幅度整体明显降低，初始波和尾波部分振动波形也发生畸变；而经过 SiamMorph-Unet 处理后，不仅整体噪声得到了有效抑制，振动波形也得到了很好的恢复。




图 3.19 不同去噪算法处理前和处理后 NESTOR 光纤的第 500 道振动信号对比。(a) 带通滤波；(b) 小波变换；(c) NLM；(d) jDAS；(e) SiamMorph-Unet

3.4.3 消融实验

为了验证多尺度卷积注意力模块 (MSCAM) 和 $J - invariant$ 项损失 (JLoss) 对模型去噪性能的影响, 本文使用信噪比为 1 的合成 DAS 数据对其进行消融实验。为了更好的说明实验结果, 将仅使用形态学卷积模块构建的 U-Net 模型称为 Morph-Unet。实验结果如表 3.4 所示, 可以发现分别加入 MSCAM 和 JLoss 后 Morph-Unet 模型的 SNR 均有所提高, MSE 均降低。相比之下, 加入 JLoss 后模型效果提升更大, 说明模型在训练时将较多的噪声信号映射成了有效信号, 在使用 JLoss 后可以有效抑制噪声信号对模型的影响。将 MSCAM 和 JLoss 同时加入后相比于 Morph-Unet 模型的 SNR 增加较为明显, MSE 也大幅降低。由此可见 MSCAM 和 JLoss 可以提升模型的去噪效果, 使去噪后的信号误差更小。

表 3.4 消融实验结果

模型	SNR	MSE
Morph-Unet	10.55696	0.15446
Morph-Unet+MSCAM	11.50379	0.12420
Morph-Unet+JLoss	12.17567	0.10640
SiamMorph-Unet	13.16575	0.08471

3.5 本章小结

本章首先基于图片的膨胀和腐蚀形态学滤波操作, 构建形态学膨胀卷积和形态学腐蚀卷积, 进一步根据形态学滤波原理创建形态学开卷积模块和形态学闭卷积模块, 替换 U-Net 网络中的普通卷积块, 在对 DAS 信号去噪的同时可以有效降低模型对信号幅值的影响; 此外, 通过在模型的编码与解码之间加入形态学多尺度卷积注意力机制, 使模型更关注有用信号的特征, 降低信号去噪后的误差。实验结果表明, 和其他算法相比, 本章提出的算法在 DAS 信号上取得了较好的去噪效果, 整体信噪比提升了 12.92dB。

第四章 基于小波有效通道注意力模型的 DAS 地震波识别

上一章介绍了基于孪生形态学 U-Net 神经网络的 DAS 信号去噪方法的原理以及构建过程，并使用合成的 DAS 数据和实际的 DAS 数据验证了该方法的有效性。本章在这基础上获取信噪比较高的伪标签数据，用来训练 WECAConv-DAS 半监督 DAS 地震波识别模型。以下详细介绍 WECAConv-DAS 模型的构建过程，以及基于 WECAConv-DAS 模型的 DAS 地震波识别。

4.1 小波有效通道注意力模型构建

4.1.1 网络架构

DAS 具有高空间分辨率和高灵敏性等特点，通过 DAS 采集到的地震波信号同时包含时间信息与长程相干的空间信息，但是其高灵敏度的特点，也让 DAS 采集到的地震波信号中含有大量的噪声信号。PhaseNet-DAS 中使用的原始 U-Net 模型相对简单，提取地震波相位特征能力较弱，容易受到噪声信号的影响，而且缺乏长程相干信息提取的能力。因此，为了提高模型的特征提取和长程关系建模能力，提高 DAS 地震波相位拾取能力，本文提出了基于小波有效通道注意力卷积的 U-Net 模型（WECAConv-DAS）。




图 4.1 WECAConv-DAS 模型结构

模型具体结构如图 4.1 所示，模型网络结构是一个 U 型结构，主要包含编码器、解码器和跳跃连接三部分。编码器部分包含小波下采样（Wavelet Downsampling, WTD）、小波有效通道注意力卷积（Wavelet Efficient Channel Attention Convolutions, WECAConv）。解码器部分包含 UP 上采样模块、WECA 和 UCS 上采样模块，其中 UP

上采样模块包含转置卷积层 (TransposeConv)、Relu 激活函数和批量归一化层 (BN)，UCS 上采样模块包含上采样层 (Upsample)、卷积层 (Conv) 和 Softmax 激活函数。此外，位于编码器和解码器相同层级的特征提取模块和上采样模块之间引入了跳跃连接 (skip-connect)。

4.1.2 WECACConv 和 WTD 介绍

DAS 通过光纤感知环境振动，生成高时空分辨率的连续波场数据，该数据在时间维度和空间维度上均具有极高的分辨率，包含瞬态事件（如地震波、车辆振动）和长程相干信息。为有效建模 DAS 数据，神经网络需具备大感受野以捕获长程依赖关系。传统方法通常采用大尺寸卷积核直接扩展感受野，但大核卷积参数随尺寸平方增长，计算复杂度高。同时大核卷积的全局平滑操作会抑制高频细节，降低对微弱信号的特征提取。另外，由于 DAS 的高灵敏性，采集到的 DAS 数据包含大量噪声，这些噪声信号会干扰模型对有用特征的提取，使得模型性能降低。为了解决上述问题，本文创建小波注意力卷积来扩展神经网络的感受野，同时减小噪声信息对模型性能的影响。

为了更好的介绍小波有效通道注意力卷积，本文先详细介绍小波卷积。对于 DAS 数据 X ，其大小为 $n \times t$ ， n 为光纤通道数， t 为光纤单个通道的采样时间，通过以下二维 Haar 小波变换的四个滤波器：

$$\begin{aligned} f_{LL} &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}, & f_{LH} &= \frac{1}{2} \begin{bmatrix} 1 & -1 \\ 1 & -1 \end{bmatrix} \\ f_{HL} &= \frac{1}{2} \begin{bmatrix} 1 & 1 \\ -1 & -1 \end{bmatrix}, & f_{HH} &= \frac{1}{2} \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix} \end{aligned} \quad (4.1)$$

其中 f_{LL} 是低通滤波器， f_{LH} ， f_{HL} ， f_{HH} 是一组高通滤波器，将 X 分解为 X_{LL} ， X_{LH} ， X_{HL} ， X_{HH} 四个分量，每个分量的空间分辨率为原图 X 的一半，其中 X_{LL} 为 X 的低频分量， X_{LH} ， X_{HL} ， X_{HH} 分别为 X 的水平、垂直和对角线方向的高频分量。接着可以继续将低频分量 X_{LL} 进行小波分解，这一分解过程表示如下：

$$X_{LL}^{(i)}, X_{LH}^{(i)}, X_{HL}^{(i)}, X_{HH}^{(i)} = WT(X_{LL}^{(i-1)}) \quad (4.2)$$

其中， $WT(\cdot)$ 表示小波变换， $X_{LL}^{(0)} = X$ ， i 表示当前分解层。接着对每个分量进行卷积，提取不同频率的特征，最后将逆小波变换 (IWT) 重构后的特征与上一层卷积后的特征相加输出。具体流程表示为：

$$Y_i = \begin{cases} Conv(X_{LL}^{(i)}) + Y_{i+1} & i = 0 \\ IWT(Conv(WT(X_{LL}^{(i-1)})) + Y_{i+1}) & i > 0 \end{cases} \quad (4.3)$$

其中, $Conv(\cdot)$ 表示卷积操作, Y_i 表示第 i 层输出特征, 小波逆变换 $IWT(\cdot)$ 使用转置卷积替代。小波卷积的具体过程如图 4.2 所示,




图 4.2 小波卷积结构

通过上述小波卷积的过程可以发现, 最后输出的特征 Y 中包含下级所有特征, 而这些下级特征中同时含有有用信息和噪声信息。每一级特征 Y_i 合并到上级特征的时候都会将下级所有噪声信息携带到上级特征, 给上级提取有用信息造成困难。针对这一问题, 本文引入注意力机制, 使得特征合并时更关注有用信息, 降低噪声信息对模型的影响。




图 4.3 小波有效通道注意力结构

图 4.3 为本文构建的小波有效通道注意力（Wavelet Efficient Channel Attention, WECA），在小波变换的到高频分量和低频分量后, 先经过卷积得到各分量大小为 $H \times W \times C$ 的特征。将卷积后的高低频特征分别经过平均池化（AvgPool）和最大池化（MaxPool），得到八个 $1 \times 1 \times C$ 大小的张量。之后将 AvgPool 和 MaxPool 后的张量分别拼接在一起, 各自形成一个 $1 \times 4 \times C$ 的张量。拼接形成的张量随后交给与有效

通道注意力机制（Efficient Channel Attention, ECA）相同的一层卷积，该卷积层的卷积核尺寸为 $4 \times k$ 。卷积核尺寸中的 k 的计算如下所示：

$$k = \left\lceil \frac{\log_2 C + b}{\gamma} \right\rceil_{\text{odd}} \quad (4.4)$$

其中， C 表示通道数， γ 和 b 表示控制卷积核尺寸的权重参数，通常设置为 2 和 1， $\lceil \cdot \rceil_{\text{odd}}$ 表示 k 取奇数。计算完成后分别得到 AvgPool 和 MaxPool 的 $1 \times 1 \times C$ 张量，接着将这两个 $1 \times 1 \times C$ 张量拼接得到一个 $1 \times 2 \times C$ 张量。将该张量使用公式(4.4)计算得到的卷积核卷积，将卷积后的 $1 \times 1 \times C$ 张量通过使用 Sigmoid 激活函数可以得到一个二分类的结果，该结果即为输入特征通道各自的权重值。将得到的通道权重值与输入特征图逐通道相乘，即可获得根据通道权重进行调整的特征图，该输出特征图与输入特征图的空间维度保持一致。WECA 注意力的输出公式如下所示：

$$\begin{aligned} F_{\text{avg}} &= \text{Conv}(\text{Conc}(P_{\text{avg}}(F_{\text{wt}}))) \\ F_{\text{max}} &= \text{Conv}(\text{Conc}(P_{\text{max}}(F_{\text{wt}}))) \\ \text{WECA}(F_{\text{wt}}) &= F_{\text{wt}} \times \sigma(\text{Conv}(\text{Conc}(F_{\text{avg}}, F_{\text{max}}))) \end{aligned} \quad (4.5)$$

其中， F_{wt} 表示经过卷积后的小波变换分量， P_{avg} 和 P_{max} 表示平均池化和最大池化， $\text{Conc}(\cdot)$ 表示拼接操作， $\text{Conv}(\cdot)$ 表示卷积操作， $\sigma(\cdot)$ 表示激活操作。将 WECA 注意力加入到小波卷积中，得到的小波有效通道注意力卷积（WECAConv）的计算公式如下：

$$Y_i = \begin{cases} \text{Conv}(X_{LL}^{(i)}) + Y_{i+1} & i = 0 \\ \text{IWT}(\text{WECA}(\text{Conv}(\text{WT}(X_{LL}^{(i-1)}))) + Y_{i+1}) & i > 0 \end{cases} \quad (4.6)$$

通过上述小波卷积的过程可以发现，小波变换后可以将特征转换为低频和高频两部分，同时降低了特征空间的维度，这一过程基本不会丢失特征原有信息。因此，根据小波变换这一特点本文构建小波下采样（WTD）来替换最大池化层进行下采样操作，减少下采样时特征信息的损失。WTD 具体如图 4.4 所示。




图 4.4 小波下采样结构

从图 4.4 可以得知，本文构建的小波下采样通过将 X 小波变换分解得到 X_{LL} ，

X_{LH} , X_{HL} , X_{HH} 四个分量, 然后将这四个分量与经过卷积下采样后的 X 相加, 再将相加得到的四个分量沿通道方向拼接, 最后通过卷积操作得到下采样后的特征。小波下采样具体公式如下:

$$Y = \text{Conv}(\text{Concat}(\text{WT}(X) + \text{DConv}(X))) \quad (4.7)$$

4.1.3 损失函数

确定地震波相位识别训练网络模型的架构后, 需要定义该网络的损失函数保证后期模型在训练过程中, 模型能逐渐收敛于目标效果, 即最符合训练样本的模型, 使参数达到最优。本实验训练模型选择的损失函数是交叉熵损失函数。该损失函数是一种在分类任务中常用的损失函数, 它衡量的是模型预测的概率分布与实际标签的概率分布之间的差异, 本实验交叉熵损失函数公式如下:

$$H(p, q) = - \sum_{i=1}^3 \sum_x p_i(x) \log q_i(x) \quad (4.8)$$

其中, $i=1, 2, 3$ 分别表示噪声, P 波和 S 波类别; $p(x)$ 表示真实标签的概率分布, $q(x)$ 表示预测标签的概率分布。由于神经网络训练的 P 波和 S 波标签由教师模型预测得到, 直接将其作为确定性的“硬标签”会导致模型对标注误差敏感。因此, 通过以教师模型预测的 P 波和 S 波到达时间为中心, 构造一个高斯分布, 认为真实到相位到达时间以一定概率分布在标注附近, 且越接近标注点概率越高。标签的高斯型目标函数计算公式如下:

$$P_P = e^{-\frac{(t-t_p)^2}{2\sigma^2}} \quad (4.9)$$

$$P_S = e^{-\frac{(t-t_s)^2}{2\sigma^2}} \quad (4.10)$$

$$P_N = \max(0, 1 - P_P - P_S) \quad (4.11)$$

其中 t_p 和 t_s 分别表示 P 波和 S 波的到达时间, P_P 、 P_S 和 P_N 分别为 P 波、S 波和噪声的目标函数; σ 为高斯形目标函数的宽度, 用于考虑相位到达时间中的不确定性, 类似于计算机视觉中常用的标签平滑技术。在本文中将 σ 设为 1.5 秒。

4.2 实验数据和模型训练

4.2.1 实验数据

本文采用两个公开的 DAS 阵列数据验证本章提出的 DAS 地震波相位识别方法的有效性。这两个公开的 DAS 数据为 Ridgecrest 数据和 Eureka 数据。Ridgecrest 数据由

Ridgecrest DAS 阵列在 2020 年 6 月 20 日至 2020 年 7 月 29 日期间, 沿着 Ridgecrest 和 Inyokern 机场之间的光纤记录。Ridgecrest DAS 阵列为一根长度 10km, 通道间距为 8m 的光缆。Eureka 数据则是由 Eureka DAS 阵列在 2022 年 5 月 18 日至 2022 年 7 月 19 日, 从 Arcata 延伸至 Eureka 的光纤记录。Eureka DAS 阵列为一根长 15km, 通道间距为 2m 的光缆, 该光缆由 Vero Communications 公司提供。另外, 本文从南加州地震数据中心获取 Ridgecrest DAS 阵列对应的地震事件和位置信息, 用于后续相位关联和定量分析, 总共包含 751 个事件。

图 4.5 展示的是 Ridgecrest DAS 阵列和 Eureka DAS 阵列采集到的部分 DAS 数据。图 4.5(a) 为 Ridgecrest DAS 阵列采集的 DAS 数据, 该数据的采样频率为 100Hz。图 4.5(b) 为 Eureka DAS 阵列采集到的 DAS 数据, 该数据的采样频率为 250Hz。




图 4.5 Ridgecrest 和 Eureka DAS 数据。(a) Ridgecrest 数据; (b) Eureka 数据。

4.2.2 模型训练

按照 2.4.1 节中半监督学习流程, 先使用预训练的 SiamMorph-Unet 模型对原始的 DAS 数据去噪, 接着使用预训练的 PhaseNet-DAS 模型对这些事件数据中的 P 波和 S 波到达时间进行拾取。拾取结果使用 BGaMMA 模型进行相位关联, 并保留具有至少 500 个 P 和 S 波拾取的事件作为训练数据集, 从 Ridgecrest 光缆中获得了 27 个事件数据集。由于没有人工标注的“真实值”来评估模型性能, 因此仅将数据集按 8:2 划分为训练集和验证集。训练时对每个事件数据随机选取大小为 3072×5120 (时间采样点 $\times$ 空间通道数) 的训练样本, 并对每个通道应用滑动窗口归一化。该归一化方法使用卷积操作实现, 窗口大小为 1024, 步幅为 256, 在固定窗口内先去除平均值再除以标准差, 从而与输入数据长度无关。为了更清楚的表述, 基于小波有效通道注意力模型的半监督 DAS 地震波相位识别算法训练的主要过程如算法 4.1 所示。

算法 4.1 基于小波有效通道注意力模型的半监督 DAS 地震波相位识别算法

输入：无标签 DAS 数据集 D ，批量大小 M ，最大迭代次数 Q ，WECANet-DAS 模型参数 θ_0^{WECA} ，预训练 SiamMorph-Unet 模型参数 θ_1 。

输出：分类结果 P 。

初始化：初始化 θ_0^{WECA} ，以及使用参数 θ_1 初始化 SiamMorph-Unet 模型参数。

1. $D_{denoise} = SiamMorph - Unet(D)$ #使用预训练的 SiamMorph-Unet 模型对数据去噪。
2. $Y = PhaseNet(D_{denoise})$ #通过预训练的教師模型 PhaseNet 得到伪标签数据。
3. $Y_{GaMMA} = B GaMMA(Y)$ #使用贝叶斯高斯混合模型过滤标签数据。
4. **While** $q < Q$ **Do**
5. **For** $i = 1$ to I **Do**
6. **For** $i = 1$ to K **Do** #编码器。
7. $X_{WTD}^{(i)} = WTD(D)$ #小波下采样。
8. $X_{EW}^{(i)} = WECAConv(X_{WTD}^{(i)})$ #小波有效通道注意力卷积。
9. **End For**
10. **For** $i = 1$ to K **Do** #解码器。
11. **If** $i = 1$ **Do**
12. $X_{Up}^{(i)} = TransposeConv(X_{EW}^{(K)})$ #上采样操作。
13. **Else**
14. $X_{Up}^{(i)} = TransposeConv(X_{DW}^{(i-1)})$
15. **End If**
16. $X_{skip}^{(i)} = Concatenate(X_{Up}^{(i)}, X_{EW}^{(K-i)})$ #跳跃连接。
17. $X_{DW}^{(i)} = WECAConv(X_{skip}^{(i)})$
18. **End For**
19. **End For**
20. 根据公式 (4.9)、(4.10) 和 (4.11) 计算分类结果 P 。
21. 根据公式 (4.8) 计算损失函数并更新 θ_0^{WECA} 。
22. **End While**

实验在具有两个 12GB 显存 NVIDIA GeForce RTX 4070ti 的 Linux 服务器上进行。使用 Python 版本为 3.10.14，使用核心库 Pytorch 为 2.1.0 版本，CUDA 版本为 12.2。训练过程采用 Adam 优化器对参数进行优化，学习率为 0.001，batch size 设置为 8，训练 100 个 epoch。

4.2.3 评估指标

为了能够准确的衡量不同相位识别方法的性能，本文使用相位关联后得到的相位数量和相位关联比率作为模型性能的评估指标。相位关联比率的计算公式如下：

$$R_p = \frac{M}{N} \quad (4.12)$$

其中， M 表示使用相位关联器进行相位相关联后的相位数量， R_p 为相位关联比率，

N 表示识别得到的总的相位数，相位关联器使用 BGaMMA 相位关联器。相位关联对相邻通道进行约束，即相邻通道的相位类型应当一致，且相位到达时间应遵循由通道位置和波速确定的时间移动规律。通过相位关联，可以去掉因相位时间不准确或相位类型错误的相位，得到接近真值的相位数，近似衡量模型的效果。




图 4.6 不同方法的相位识别结果。(a) 在 Ridgecrest 数据集上的相位识别结果；(b) Eureka 数据集上的相位识别结果。

4.3 实验结果与分析

4.3.1 对比实验

为了验证本文提出的 WECA-Net-DAS 地震波相位识别的性能，本文在 Ridgecrest 数据集和 Eureka 数据集上与 PhaseNet 和 PhaseNet-DAS 方法进行对比。从两个数据集中分别挑选一个可观察到的地震信号进行识别，图 4.6 展示了不同方法的识别结果。

从图 4.6 可知，PhaseNet 方法识别到的 P 波和 S 波较为杂乱，无法很好的区分 P 波和 S 波相位信号。PhaseNet-DAS 方法能够较好的识别出 P 波和 S 波信号，但是对于 S 波信号的识别存在较多误判，将一些 P 波信号和噪声信号识别为 S 波信号。本文

提出的 WECA Net-DAS 方法在对 P 波和 S 波信号识别上均有明显提升，能够很好的区分出 P 波信号和 S 波信号。另外，从图 4.6 (b) 中可以发现，相比于 PhaseNet-DAS 本文的方法泛化性更好，在未训练的数据上也能有较好的识别效果。

表 4.1 到 4.3 展示的是图 4.6 事件上，三种相位识别方法识别到的相位信号经过相位关联器关联后的相位数量和相位关联比率；表 4.4 展示的是在 Ridgecrest DAS 阵列的 751 个地震事件上三种方法的识别效果对比。从表中可知，本文提出的 DAS 相位识别方法相比于 PhaseNet-DAS 方法在 DAS 相位识别效果上有明显提升，识别到的总相位信号更准确。PhaseNet 方法由于使用单通道波形训练，无法有效利用 DAS 阵列的空间相关性，识别到的有效相位信号较少，识别精度较低。PhaseNet-DAS 相比于 PhaseNet 方法有较大提升，但是识别到的相位信号中还存在较多误判相位信号，特别是对 S 波信号的识别精度较低。

表 4.1 P 波相位关联对比

方法	识别相位数	关联相位数量	关联比率 (%)
PhaseNet	893	330	36.95
PhaseNet-DAS	689	474	68.80
WECA Net-DAS	1501	952	63.42

表 4.2 S 波相位关联对比

方法	识别相位数	关联相位数量	关联比率 (%)
PhaseNet	440	166	37.73
PhaseNet-DAS	1802	821	45.56
WECA Net-DAS	1594	932	58.47

表 4.3 P+S 波相位关联对比

方法	识别相位数	关联相位数量	关联比率 (%)
PhaseNet	1333	496	37.21
PhaseNet-DAS	2491	1295	51.99
WECA Net-DAS	3095	1884	60.87

表 4.4 总事件相位关联对比

方法	识别相位数	关联相位数量	关联比率 (%)
PhaseNet	97581	44139	45.23
PhaseNet-DAS	218469	115789	53.00
WECA Net-DAS	313479	204290	65.17

4.3.2 消融实验

为了验证本文提出的 WECA 注意力和小波下采样对模型性能的影响，对网络模块进行消融实验。以 PhaseNet-DAS 中的 U-Net 模型为基准，分别对比小波卷积 U-Net (WTUNet)，以及在 WTUNet 中依次加入小波有效通道注意力 (WECA) 和小波下采

样（WTD）后模型的相位识别效果。通过对比这些消融实验的结果，可以清晰地评估每个改进模块对相位识别的贡献，并进一步验证整个方法在 DAS 地震波相位识别任务中的有效性和优势。




图 4.7 消融实验的相位识别结果。(a) 原始 DAS 数据；(b) U-Net 识别结果；(c) WTUNet 识别结果；(d) WTUNet+WECA 识别结果；(e) WTUNet+WECA+WTD 识别结果。

实验结果如表 4.5 和图 4.7 所示，从中可以发现，在 U-Net 中的普通卷积替换为小波卷积后，关联相位数和关联比率均有增加，模型识别效果提高。在 WTUNet 中加入 WECA 注意力后，尽管识别到的相位数减少，但是关联相位数增加，关联比率提高，模型识别准确率提高；接着在模型中使用 WTD 下采样后，关联数量进一步增加，关联比率也进一步提高，识别到更多有效相位信号。

表 4.5 消融实验结果

模型	识别相位数	关联相位数量	关联比率
U-Net	2491	1295	51.99
WTUNet	3272	1809	55.29
WTUNet+WECA	3246	1818	56.01
WTUNet+WECA+WTD	3095	1884	60.87

4.4 本章小结

现有 DAS 地震波相位识别方法 PhaseNet-DAS, 提取地震波相位特征能力较弱, 容易受到噪声信号的影响, 而且缺乏长程相干信息提取的能力。本章针对以上问题提出了一种基于小波有效通道注意力卷积的 U-Net 模型 (WECANet-DAS), 通过在小波卷积中添加小波有效通道注意力, 在增加神经网络感受野的同时, 提高了模型提取有效信息的能力。此外, 将小波下采样作为模型的下采样模块, 降低了模型下采样时特征的损失。通过对比实验表明, WECANet-DAS 模型能够更好的识别出 DAS 地震波相位信号, 相比于 PhaseNet-DAS 整体有效相位识别数增加了 0.76 倍, 相位识别率提高了 12.17%。

第五章 总结与展望

5.1 工作总结

本文基于深度学习方法开展了分布式光纤振动传感（DAS）信号识别研究，具体内容如下：

（1）针对 DAS 地震记录中存在大量噪声问题，提出了一种基于孪生形态学 U-Net 神经网络的自监督学习去噪算法（SiamMorph-Unet）。该方法首先根据形态学滤波原理创建形态学开卷积模块和形态学闭卷积模块，替换 U-Net 网络中的普通卷积块，在对 DAS 信号去噪的同时有效降低了模型对信号幅值的影响；随后，在新构建的 U-Net 模型的编码与解码之间加入多尺度卷积注意力机制，使模型更关注有用信号的特征，降低信号去噪后的误差。此外，根据 DAS 地震记录相邻通道间强相关特点，在 Noise2Self 自监督方法的损失函数上加入 $J - invariant$ 约束项，防止模型恒等映射，影响模型去噪效果。通过在合成 DAS 数据和实际 DAS 数据上进行测试，结果表明 SiamMorph-Unet 算法能有效抑制 DAS 信号中的噪声，且对于有效信号的损伤较轻，整体信噪比提升了 12.92dB。

（2）针对 DAS 地震数据庞大，手动标注一个大型 DAS 数据集既耗时又成本高昂，现有 DAS 地震波相位识别半监督学习算法准确率较差的问题，提出了一种基于 WECA Net-DAS 神经网络的半监督 DAS 地震波相位识别算法。该方法首先在半监督学习流程中添加去噪步骤，在使用教师模型生成伪标签之前，使用第一部分提出的去噪方法对 DAS 信号去噪，提高伪标签的质量；其次，提出了一种小波有效通道注意力卷积替换传统 U-Net 模型中的普通卷积，在增大模型感受野的同时，提高模型的识别精度。此外，使用小波下采样卷积作为模型的下采样模块，减少下采样时有效信息的损失。结果表明，本文提出的方法识别到的有效地震波相位信号相比于 PhaseNet-DAS 方法增加了 0.76 倍，相位识别率提高了 12.17%。

5.2 研究展望

本文针对 DAS 系统采集的地震波信号数据量大，信号的信噪比低，人工标注一个大型 DAS 数据集较为困难，导致有监督的深度学习难以应用，而现有的半监督 DAS 地震波信号识别效果欠佳，提出了基于 SiamMorph-Unet 的自监督 DAS 信号去噪方法和基于 WECA Net-DAS 的半监督 DAS 地震波相位信号识别方法。尽管 SiamMorph-Unet 方法和 WECA Net-DAS 方法分别在 DAS 地震信号去噪和地震相位信号识别方面

效果得到了提升，但本文的工作仍存在以下可以继续优化的方向：

（1）进一步实现地震波震源定位和震级估计。本文工作聚焦于 DAS 地震波相位信号的识别，后续可以根据识别到的地震波相位信号的到时和强度，对地震波震源定位和震级估计，达到地震预警的目的。

（2）实现 DAS 地震信号去噪、识别和定位一体化，搭建全智能 DAS 地震监测系统。DAS 地震信号的去噪和识别，尽管是不同的两个任务，但是使用的模型整体架构大致相同。考虑将两个任务的模型进行融合，使用同一个模型进行去噪和识别，后续再增加地震定位任务，打造一个全智能 DAS 地震监测系统。

参考文献

- [1] Lindsey N J, Martin E R. Fiber-Optic Seismology[J]. Annual Review of Earth and Planetary Sciences, 2021, 49(1): 309-336.
- [2] Martin E R, Lindsey N J, Ajo-Franklin J B, et al. Introduction to Interferometry of Fiber-Optic Strain Measurements[M]. Distributed Acoustic Sensing in Geophysics: American Geophysical Union, 2021. 111-129.
- [3] Li J, Kim T, Lapusta N, et al. The break of earthquake asperities imaged by distributed acoustic sensing[J]. Nature, 2023, 620(7975): 800-806.
- [4] Zhu W, Biondi E, Li J, et al. Seismic arrival-time picking on distributed acoustic sensing data using semi-supervised learning[J]. Nature Communications, 2023, 14(1): 8192.
- [5] Zhan Z. Distributed Acoustic Sensing Turns Fiber-Optic Cables into Sensitive Seismic Antennas[J]. Seismological Research Letters, 2019, 91(1): 1-15.
- [6] Allen R V. Automatic earthquake recognition and timing from single traces[J]. Bulletin of the seismological society of America, 1978, 68(5): 1521-1532.
- [7] Ross Z E, Trugman D T, Hauksson E, et al. Searching for hidden earthquakes in Southern California[J]. Science, 2019, 364(6442): 767-771.
- [8] Li Z, Zhan Z. Pushing the limit of earthquake detection with distributed acoustic sensing and template matching: a case study at the Brady geothermal field[J]. Geophysical Journal International, 2018, 215(3): 1583-1593.
- [9] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436-444.
- [10] Zhu W, Tai K S, Mousavi S M, et al. An end-to-end earthquake detection method for joint phase picking and association using deep learning[J]. Journal of Geophysical Research: Solid Earth, 2022, 127(3): e2021JB023283.
- [11] 戴宗辉, 郑建常, 周连庆, 等. 基于深度学习的山东平原 $M_s5.5$ 地震余震检测及发震构造研究[J]. 地球物理学报, 2025, 68(03): 925-937.
- [12] Wilding J D, Zhu W, Ross Z E, et al. The magmatic web beneath Hawai‘i[J]. Science, 2023, 379(6631): 462-468.
- [13] Retailleau L, Saurel J M, Zhu W, et al. A wrapper to use a machine-learning-based algorithm for earthquake monitoring[J]. Seismological Research Letters, 2022, 93(3): 1673-1682.
- [14] 李子昊, 赵国为, 郭攀, 等. 人工智能在震害学中的应用[J]. 防灾减灾学报, 2024, 40(04): 84-90.
- [15] 侯宝瑞, 代昊祯, 宋晋东, 等. 基于中国强震动数据的 PhaseNet 网络拾 P 波到时研究[J]. 世界地震工程, 2024, 40(04): 131-141.
- [16] Retailleau L, Saurel J M, Laporte M, et al. Automatic detection for a comprehensive view of Mayotte seismicity[J]. Comptes Rendus. Géoscience, 2022, 354(S2): 153-170.
- [17] Wang H F, Zeng X, Miller D E, et al. Ground motion response to an ML 4.3 earthquake using co-located distributed acoustic sensing and seismometer arrays[J]. Geophysical Journal International, 2018, 213(3): 2020-2036.
- [18] Lindsey N J, Dawe T C, Ajo-Franklin J B. Illuminating seafloor faults and ocean dynamics with dark

- p>fiber distributed acoustic sensing[J]. Science, 2019, 366(6469): 1103-1107.
- [19] Karrenbach M, Shen Z, Li Z, et al. Rapid deployment of distributed acoustic sensing systems to track earthquake activity[M]. SEG Technical Program Expanded Abstracts: Society of Exploration Geophysicists, 2020. 490-494.
- [20] Farghal N S, Saunders J K, Parker G A. The Potential of Using Fiber Optic Distributed Acoustic Sensing (DAS) in Earthquake Early Warning Applications[J]. Bulletin of the Seismological Society of America, 2022, 112(3): 1416-1435.
- [21] Li Z, Shen Z, Yang Y, et al. Rapid response to the 2019 Ridgecrest earthquake with distributed acoustic sensing[J]. AGU Advances, 2021, 2(2): e2021AV000395.
- [22] Baba S, Araki E, Yamamoto Y, et al. Observation of shallow slow earthquakes by distributed acoustic sensing using offshore fiber-optic cable in the Nankai Trough, Southwest Japan[J]. Geophysical Research Letters, 2023, 50(12): e2022GL102678.
- [23] Matias L, Carrilho F, Sá V, et al. The contribution of submarine optical fiber telecom cables to the monitoring of earthquakes and tsunamis in the NE Atlantic[J]. Frontiers in Earth Science, 2021, 9, 686296.
- [24] Biondi B L, Yuan S, Martin E R, et al. Using telecommunication fiber infrastructure for earthquake monitoring and near-surface characterization[M]. Distributed Acoustic Sensing in Geophysics: Geophysical Monograph Series, 2021. 131-148.
- [25] Zeng X, Bao F, Thurber C H, et al. Turning a Telecom Fiber - Optic Cable into an Ultradense Seismic Array for Rapid Postearthquake Response in an Urban Area[J]. Seismological Research Letters, 2021, 93(2A): 853-865.
- [26] Tsuji T, Tsuji S, Kinoshita J, et al. 4 cm Portable Active Seismic Source (PASS) for Meter-to Kilometer-Scale Imaging and Monitoring of Subsurface Structures[J]. Seismological Society of America, 2023, 94(1): 149-158.
- [27] Yin J, Soto M A, Ramírez J, et al. Real-data testing of distributed acoustic sensing for offshore earthquake early warning[J]. The Seismic Record, 2023, 3(4): 269-277.
- [28] Zhai Q, Zhan Z, Chavarria J A. Thousand-kilometer DAS array reveals an uncatalogued magnitude-5 dynamically triggered event after the 2023 Turkey earthquake[J]. Journal of Geophysical Research: Solid Earth, 2024, 129(3): e2023JB027680.
- [29] Cheng F, Chi B, Lindsey N J, et al. Utilizing distributed acoustic sensing and ocean bottom fiber optic cables for submarine structural characterization[J]. Scientific reports, 2021, 11(1): 5613.
- [30] 邓棣珉, 徐团伟, 张汉羽, 等. 深海级分布式光纤地震系统的南海海试[J]. 光学学报, 2024, 44(01): 375-383.
- [31] Nishimura T, Emoto K, Nakahara H, et al. Source location of volcanic earthquakes and subsurface characterization using fiber-optic cable and distributed acoustic sensing system[J]. Scientific Reports, 2021, 11(1): 6319.
- [32] Brenguier F, Boué P, Ben-Zion Y, et al. Train traffic as a powerful noise source for monitoring active faults with seismic interferometry[J]. Geophysical Research Letters, 2019, 46(16): 9529-9536.
- [33] Biagioli F, Métaxian J P, Stutzmann E, et al. Array analysis of seismo-volcanic activity with distributed acoustic sensing[J]. Geophysical Journal International, 2024, 236(1): 607-620.
- [34] Nakano M, Ichihara M, Suetsugu D, et al. Monitoring volcanic activity with distributed acoustic sensing using the Tongan seafloor telecommunications cable[J]. Earth, Planets and Space, 2024, 76(1): 25.
- [35] Caudron C, Miao Y, Spica Z J, et al. Monitoring underwater volcano degassing using fiber-optic

- sensing[J]. Scientific reports, 2024, 14(1): 3128.
- [36] Jousset P, Currenti G, Schwarz B, et al. Fibre optic distributed acoustic sensing of volcanic events[J]. Nature communications, 2022, 13(1): 1753.
- [37] Currenti G, Jousset P, Napoli R, et al. On the comparison of strain measurements from fibre optics with a dense seismometer array at Etna volcano (Italy)[J]. Solid Earth, 2021, 12(4): 993-1003.
- [38] Currenti G, Allegra M, Cannavò F, et al. Distributed dynamic strain sensing of very long period and long period events on telecom fiber-optic cables at Vulcano, Italy[J]. Scientific Reports, 2023, 13(1): 4641.
- [39] 刘合, 王松, 叶泽禹, 等. 光纤传感技术在油气田开发中的应用[J]. 石油物探, 2024, 63(04): 707-717.
- [40] Kishida K, Aung T L, Lin R. Monitoring a Railway Bridge with Distributed Fiber Optic Sensing Using Specially Installed Fibers[J]. Sensors, 2024, 25(1): 98.
- [41] 曹鹏涛, 韦义师, 李轶, 等. 基于分布式光纤声波传感技术(DAS)的地下管道、隧道侵入监测方法研究[J]. 物探化探计算技术, 2025, 47(01): 104-116.
- [42] Lin J, Fang S, He R, et al. Monitoring ocean currents during the passage of Typhoon Muifa using optical-fiber distributed acoustic sensing[J]. Nature Communications, 2024, 15(1): 1111.
- [43] Olofsson B, Martinez A. Validation of DAS data integrity against standard geophones—DAS field test at Aquistore site[J]. The Leading Edge, 2017, 36(12): 981-986.
- [44] Yu G, Cai Z, Chen Y, et al. Borehole seismic survey using multimode optical fibers in a hybrid wireline[J]. Measurement, 2018, 125: 694-703.
- [45] Correa J, Pevzner R, Popik S, et al. Application of 3D VSP acquired with DAS and 3C geophones for site characterization and monitoring program design: preliminary results from Stage 3 of the CO2CRC Otway project[J]. SEG International Exposition and Annual Meeting, 2018.
- [46] Dautov C P, Özerdem M S. Wavelet transform and signal denoising using Wavelet method[C]. In: 26th Signal Processing and Communications Applications Conference (SIU). Izmir, Turkey: IEEE, 2018. 1-4.
- [47] Christiano L J, Fitzgerald T J. The band pass filter[J]. International economic review, 2003, 44(2): 435-465.
- [48] Zhu J, Li P, Zhang T, et al. Seismic data denoising using the 3D curvelet transform method[J]. Petroleum Science and Technology, 2024, 1-18.
- [49] Chen S, Cao S, Sun Y, et al. Seismic time-frequency analysis via time-varying filtering based empirical mode decomposition method[J]. Journal of Applied Geophysics, 2022, 204: 104731.
- [50] Yao X, Zhou Q, Wang C, et al. An adaptive seismic signal denoising method based on variational mode decomposition[J]. Measurement, 2021, 177: 109277.
- [51] Binder G, Titov A, Liu Y, et al. Modeling the seismic response of individual hydraulic fracturing stages observed in a time-lapse distributed acoustic sensing vertical seismic profiling survey[J]. Geophysics, 2020, 85(4): T225-T235.
- [52] Sun W, Zhu S, Li W, et al. Noise Suppression of Distributed Acoustic Sensing Based on f-x Deconvolution and Wavelet Transform[J]. IEEE Photonics Journal, 2020, 12(1): 1-8.
- [53] Zhu W, Mousavi S M, Beroza G C. Seismic Signal Denoising and Decomposition Using Deep Neural Networks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(11): 9476-9488.
- [54] Klochikhina E, Crawley S, Frolov S, et al. Leveraging deep learning for seismic image denoising[J]. First Break, 2020, 38(7): 41-48.
- [55] Li Y, Ma Z. Deep learning-based noise reduction for seismic data[J]. Journal of Physics: Conference

- Series, 2021, 1861(1): 012011.
- [56] Yang L, Liu X, Zhu W, et al. Toward improved urban earthquake monitoring through deep-learning-based noise suppression[J]. Science Advances, 2022, 8(15): eabl3564.
- [57] Zhao Y, Li Y, Wu N. Coupled Noise Reduction in Distributed Acoustic Sensing Seismic Data Based on Convolutional Neural Network[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5.
- [58] Wang C, Huang X, Li Y, et al. Removing multiple types of noise of distributed acoustic sensing seismic data using attention-guided denoising convolutional neural network[J]. Frontiers in Earth Science, 2023, 10: 986470.
- [59] Lapins S, Butcher A, Kendall J M, et al. DAS-N2N: machine learning distributed acoustic sensing (DAS) signal denoising without clean data[J]. Geophysical Journal International, 2024, 236(2): 1026-1041.
- [60] Van den Ende M, Lior I, Ampuero J P, et al. A Self-Supervised Deep Learning Approach for Blind Denoising and Waveform Coherence Enhancement in Distributed Acoustic Sensing Data[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 34(7): 3371-3384.
- [61] Perol T, Gharbi M, Denolle M. Convolutional neural network for earthquake detection and location[J]. Science Advances, 2018, 4(2): e1700578.
- [62] Zhu W, Beroza G C. PhaseNet: a deep-neural-network-based seismic arrival-time picking method[J]. Geophysical Journal International, 2019, 216(1): 261-273.
- [63] Mousavi S M, Ellsworth W L, Zhu W, et al. Earthquake transformer—an attentive deep-learning model for simultaneous earthquake detection and phase picking[J]. Nature communications, 2020, 11(1): 3952.
- [64] Ross Z E, Meier M, Hauksson E, et al. Generalized Seismic Phase Detection with Deep Learning[J]. Bulletin of the Seismological Society of America, 2018, 108(5A): 2894-2901.
- [65] Michellini A, Cianetti S, Gaviano S, et al. INSTANCE – the Italian seismic dataset for machine learning[J]. Earth System Science Data, 2021, 13(12): 5509-5544.
- [66] Zhao M, Xiao Z, Chen S, et al. DiTing: A large-scale Chinese seismic benchmark dataset for artificial intelligence in seismology[J]. Earthquake Science, 2023, 36(2): 84-94.
- [67] Mousavi S M, Sheng Y, Zhu W, et al. STanford EArthquake Dataset (STEAD): A Global Data Set of Seismic Signals for AI[J]. IEEE Access, 2019, 7: 179464-179476.
- [68] Woollam J, Rietbrock A, Bueno A, et al. Convolutional neural network for seismic phase classification, performance demonstration over a local seismic network[J]. Seismological Research Letters, 2019, 90(2A): 491-502.
- [69] Woollam J, Münchmeyer J, Tilmann F, et al. SeisBench—A toolbox for machine learning in seismology[J]. Seismological Society of America, 2022, 93(3): 1695-1709.
- [70] Spica Z J, Ajo-Franklin J, Beroza G C, et al. Pubdas: A public distributed acoustic sensing datasets repository for geosciences[J]. Seismological Society of America, 2023, 94(2A): 983-998.
- [71] 杨振国. 基于深度学习的分布式光纤传感事件识别方法的研究[D]. 齐鲁工业大学, 2023.
- [72] 干登轲. 基于无监督脉冲神经网络的分布式光纤传感信号识别方法[D]. 电子科技大学, 2022.
- [73] 彭飞. 相位敏感型光时域反射仪及其应用研究[D]. 电子科技大学, 2015.
- [74] 李康. 光纤分布式声波传感系统的信号增强及其处理的研究[D]. 电子科技大学, 2019.
- [75] 杨文晨. ϕ -OTDR 系统性能提升方法的研究[D]. 山东大学, 2022.
- [76] Van Engelen J E, Hoos H H. A survey on semi-supervised learning[J]. Machine Learning, 2020, 109(2): 373-440.

- [77] Ericsson L, Gouk H, Loy C C, et al. Self-Supervised Representation Learning: Introduction, advances, and challenges[J]. IEEE Signal Processing Magazine, 2022, 39(3): 42-62.
- [78] Lehtinen J, Munkberg J, Hasselgren J, et al. Noise2Noise: Learning Image Restoration without Clean Data[C]. In: 35th International Conference on Machine Learning. Stockholmsmässan, Stockholm Sweden: ICML, 2018. 4620-4631.
- [79] Pang T Y, Zheng H, Quan Y H, et al, Recorrupted-to-Recorrupted: Unsupervised Deep Learning for Image Denoising[C]. In: 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: IEEE, 2021. 2043-2052.
- [80] Batson J, Royer L. Noise2Self: Blind Denoising by Self-Supervision[C]. In: 36th International Conference on Machine Learning. Long Beach, CA, USA: ICML, 2019. 524-533.
- [81] Zhu W, McBrearty I W, Mousavi S M, et al. Earthquake phase association using a Bayesian Gaussian mixture model[J]. Journal of Geophysical Research: Solid Earth, 2022, 127(5): e2021JB023249.