

光纤扰动信号识别的可解释性特征选择方法

孙敏, 方拯*

上海大学通信与信息工程学院, 特种光纤与光接入网重点实验室, 特种光纤与先进通信国际合作联合实验室,
上海 200444

摘要 特征选择对基于机器学习方法的相敏光时域反射仪(φ -OTDR)系统的扰动信号的识别具有重要意义。提出一种高效的、具有可解释性的特征选择方法。该方法利用机器学习可解释性方法[沙普利加和解释(SHAP)]量化特征对模型的贡献,并按特征重要性进行排名,选择若干重要的特征构建特征子集。利用北京交通大学的开源数据集,提取6种扰动事件的22种特征,并构建4种常用的分类模型进行信号识别。在保证识别准确率的前提下,根据模型的特征重要性排名结果的差异性,选择不同数量的特征重新训练模型后,识别时间均有不同程度的减少,识别性能获得不同程度的提升,其中随机森林的性能最优,平均识别准确率提高到96.5%,且单个样本的平均识别时间减少19.3%。在选择同样数量的特征条件下,所提方法的平均识别准确率均高于其他方法。实验结果证实了所提可解释性特征选择方法的优越性和可靠性。

关键词 传感器; 相敏光时域反射仪; 信号识别; 特征选择; 机器学习可解释性

中图分类号 TP212

文献标志码 A

DOI: 10.3788/AOS241101

1 引言

相敏光时域反射仪(φ -OTDR)技术^[1]是分布式光纤传感的典型技术之一,相较于传统的电子传感技术,具有灵敏度高、传感距离长、抗电磁干扰、结构简单等优势,因而备受关注,目前已在油气管道监测^[2]、铁路安全监测^[3]、建筑结构健康监测^[4]、地震监测^[5]、周界安防^[6-7]等诸多领域得到应用。将 φ -OTDR技术应用于周界安防领域时,环境复杂多变、干扰信号较多导致容易出现误报,因此需要采用信号识别技术。

目前,基于机器学习的信号识别方法是提高 φ -OTDR扰动信号识别准确率的主要手段^[8]。传统机器学习方法主要包括信号采集与预处理、特征提取与分类器识别等阶段。特征提取阶段通常使用快速傅里叶变换^[9]、经验模态分解^[10]、变分模态分解^[11]、小波包分解^[12](WPD)等手段提取信号的时域、频域及时频域特征,并融合为信息更为丰富的特征数据集。近年来,以支持向量机(SVM)^[13]、K-近邻(KNN)^[14]、决策树(DT)^[15]、随机森林(RF)^[16]、极限梯度提升树^[17]、隐马尔可夫模型^[18]为代表的分类算法,在 φ -OTDR扰动信号识别中取得了一系列成果。

传统机器学习方法的多域特征提取过程在一定程度上提高了信号识别方法的识别准确率,然而特征数量的增加往往会引入一些冗余特征或负面特征,从而

影响信号识别方法的实时性甚至识别准确率。因此,采用有效的特征选择方法,可在兼顾识别准确率的同时去除冗余特征,提高实时性,对基于传统机器学习方法的 φ -OTDR扰动信号识别具有重要意义。

目前,特征选择的策略大致可分为三类:过滤式、包装式、嵌入式^[19]。Zhao等^[20]使用QuickReduct算法进行特征选择,所保留的特征更有效。Jia等^[21]使用Fisher评分方法计算每个特征的评价分数,按照分数从高到低排序并选择25个特征,基于极限学习机分类器的单个样本识别时间少于0.1 s且5类事件的平均识别准确率超过95%。Wang等^[22]基于方差准则和类内-类间距离判定准则,将40个特征筛选为16个,基于改进的梯度提升决策树分类器将单个样本识别时间从1 s缩短至0.3 s,同时5类事件的平均识别准确率仍然可以达到97.41%。Huang等^[23]基于互信息矩阵对主成分分析后的特征进行选择,并在时间序列数据集上验证了该方法的有效性。上述方法多为与模型无关的过滤式方法,筛选指标较为单一,对特征与模型之间的联系缺乏考虑。

本文提出了一种具有较高可靠性与可解释性的可识别 φ -OTDR扰动信号的特征选择方法,即利用沙普利加和解释(SHAP)方法^[24]对传统机器学习分类模型进行可解释性分析,量化特征对模型的贡献并将其由大到小排名,排名越靠前,则特征对模型的预测结果

收稿日期: 2024-05-30; 修回日期: 2024-06-25; 录用日期: 2024-07-15; 网络首发日期: 2024-07-29

基金项目: 国家自然科学基金(62075123)、高等学校学科创新引智计划(111)资助(D20031)

通信作者: *nfang@shu.edu.cn

越准确,特征的重要性就越明显,这里只需要选择若干重要的特征,用于扰动信号的识别。在北京交通大学开源的 φ -OTDR系统时空信号数据集上进行特征提取,并使用SVM、KNN、DT和RF等常用机器学习模型进行分类,应用所提出的特征选择方法可在提高识别准确率的同时,进一步提高信号识别的实时性。

2 信号识别的可解释性特征选择方法

2.1 机器学习可解释性方法 SHAP

机器学习分类算法可以取得较高的分类精度,但其黑盒特性导致其应用有一定的限制。机器学习的可解释性指对模型的内部运行机制以及模型的输出结果做出更加透明的解释。可解释性可分为内在可解释性和事后可解释性。线性回归、决策树等模型由于运行机制简单,存在较高的内在可解释性,而复杂模型的决策过程与预测结果则难以解释,往往需要进行事后可解释性研究。

SHAP方法便是一种典型的事后可解释性方法,即它是在模型训练完成后对预测结果进行解释。Lundberg等^[24]从博弈论中受到启发,将机器学习模型的预测结果看作是多个输入特征合作博弈的结果。对于一个由多个特征参与训练的机器学习模型,每个特征对模型预测结果的贡献由其Shapley值表示,计算方法^[24]如下:

$$\phi_i = \sum_{S \subseteq F(i)} \frac{|S|!(|F| - |S| - 1)!}{|F|!} \times [f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S)], \quad (1)$$

式中: ϕ_i 为第*i*个特征的Shapely值; S 为不包含该特征的特征子集; $f_{S \cup \{i\}}$ 为包含该特征时的模型预测值; $x_{S \cup \{i\}}$ 为包含该特征时的输入特征值; f_S 为不包含该特征时的模型预测值; x_S 为不包含该特征时的输入特征值; F 为所有特征组成的集合; $f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S)$ 为该特征是否会引起模型预测结果的差异。模型的预测结果通过线性相加特征的贡献获得,即原模型 $f(x)$ 与其对应的可解释模型 $g(x')$ ^[24]满足

$$f(x) = g(x') = \phi_0 + \sum_{i=1}^M \phi_i x'_i, \quad (2)$$

式中: M 为输入特征的个数; x' 为简化的特征值, $x' \in \{0, 1\}$; ϕ_0 为未引入任何特征时的模型的预测基值。

2.2 基于SHAP的可解释性特征选择方法

SHAP方法提供局部解释和全局解释两种解释方案。局部解释即通过计算单个样本中的特征的Shapley值来解释特征对模型预测结果的影响。全局解释则通过计算整个样本集中每个特征的Shapley值绝对值的平均值,再依据大小排序后得到一个全局特征重要性排名。本文把SHAP方法的局部解释和全局解释都用于扰动信号的特征选择,具体流程如图1所示。首先对信号进行多域特征提取,构建特征数据集




图1 用于信号识别的可解释性特征选择方法的流程图


Fig. 1 Flow chart of signal recognition with explainable feature selection method

训练模型;其次用特征数据集与训练好的模型进行SHAP分析,局部解释提供单个样本的决策依据,增加可信度,全局解释得到的全局特征重要性排名作为特征选择的主要依据;最后使用特征选择后的特征子集重新训练模型,获得识别效率的提升。

3 实验

3.1 实验用数据集与数据预处理

在北京交通大学开源数据集^[25]上对本文所提出的 φ -OTDR系统的扰动信号特征选择方法的有效性进行验证,该数据集可在GitHub平台(https://github.com/BJTUSensor/Phi-OTDR_dataset_and_codes)下载获得。实验用数据集通过图2所示的实验系统进行采集,包括背景噪声、挖掘、敲击、浇水、摇晃、行走等6种类型的扰动事件。数据样本为时空信号样本,即每个信号由空间域中12个相邻的传感点与时间域中的10000个采样点组成。由于系统固有噪声及环境噪声随时间的变化很小,仅通过数据差分便可以使扰动产生的传感信号变化更明显。因此,本文对原始信号进行了差分处理,差分处理后信号的维度为 12×9999 。空间域中间的6个传感点的信号变化明显^[26],因此,本文进行了合理的数据裁剪,裁剪后信号的维度为 6×9999 ,以进一步提高泛化性能。训练集和测试集的样本数按照文献^[25]的划分比例(8:2)选取,以便于其他使用该开源数据集的学者进行对比,数据集的细节如



EDFA: Erbium Doped Fiber Amplifier; AOM: Acoustic Optic Modulator; PD: Photodetector; DAQ: Data Acquisition Card; PC: Personal Computer

图2 采集数据集的 φ -OTDR系统的结构^[25]

Fig. 2 Structure of φ -OTDR system for dataset acquisition^[25]

表1所示。以原12个传感点中第6个传感点的时域信号进行差分处理后的信号为例,6种事件对应的时域信号如图3所示。

表1 数据集的细节
Table 1 Details of dataset

Event type	Number of training samples	Number of test samples	Label
Background noise	2357	589	0
Digging	2010	502	1
Knocking	2024	506	2
Watering	1802	451	3
Shaking	2182	546	4
Walking	1960	490	5

3.2 特征提取

在 φ -OTDR系统扰动信号的特征提取中,一般进行多域分析以全面体现不同类型扰动信号之间的差

异。时域特征反映了时域信号的波形变化特点。时域信号经傅里叶变换后变为频域信号,频域信号可以反映信号频段能量分布特性,但不能体现特定频段能量随时间变化的情况。本文采用WPD来找到不同信号在频率分布上的差异。采用db3作为小波函数对信号进行两层WPD,获取4个频段分量 $D_1 \sim D_4$,即低频分量中的低频成分(LLP)与高频成分(HLP)以及高频分量中的低频成分(LHP)与高频成分(HHP),并分别计算这4个频段分量的能量,将其作为特征值。此外,计算信号的小波信息熵(WE)和小波信息量(WIQ)作为特征值。该过程共提取16个时域特征和6个频域特征。对各个特征的名称与计算方法在文献[14]的基础上进行了补充与修正,如表2和表3所示,其中 x 为时域信号, x_i 为信号的第 i 个幅值, n 为信号的长度, $\bar{x}$ 为信号的均值, N 为每个频段分量的长度, k 为每个频段分量的离散数据点编号, $E(i)$ 为每个频段分量所对应的能量, $p(i)$ 为 $E(i)$ 占有所有分量能量之和的比例。




图3 6种事件的时域信号图。(a)背景噪声;(b)挖掘;(c)敲击;(d)浇水;(e)摇晃;(f)行走

Fig. 3 Time-domain signals of six types of events. (a) Background noise; (b) digging; (c) knocking; (d) watering; (e) shaking; (f) walking

为了提高计算效率并在一定程度上减少过拟合,将所提取的特征向量 $\mathbf{X}$ 进行了归一化处理,归一化公式为

$$\mathbf{X} = \frac{\mathbf{X} - \min(\mathbf{X})}{\max(\mathbf{X}) - \min(\mathbf{X})}. \quad (3)$$

通过归一化处理,将各特征的数值映射到 $[0,1]$ 之间,从而构建了对应的特征数据集。

3.3 SHAP分析与特征选择

本文使用SVM、KNN、DT、RF这4种常见的机器学习分类器进行扰动信号识别,分类器基于Python3.6

及机器学习库Scikit-learn实现,其中SVM的核函数采用径向基函数,核函数系数为3,KNN使用曼哈顿距离作为距离函数,其余模型的参数均为默认值。信号识别结果通过混淆矩阵以及平均识别准确率(A)、精确率(P)、召回率(R)、F1-Score(F_1)等指标进行评价。4个评价指标的计算方法如下:

$$A = \frac{N_{TP} + N_{TN}}{N_{TP} + N_{FP} + N_{TN} + N_{FN}} \times 100\%, \quad (4)$$

$$P = \frac{N_{TP}}{N_{TP} + N_{FP}} \times 100\%, \quad (5)$$

表 2 时域特征表

Table 2 Definitions of time-domain features

Feature	Definition	Feature	Definition
Peak value	$X_{PK} = \max(x)$	Standard deviation	$X_{Std} = \sqrt{X_{Var}}$
Minimum	$X_{Min} = \min(x)$	Energy	$X_E = x_i^2$
Peak to peak value	$X_{PK-PK} = X_{PK} - X_{Min}$	Kurtosis	$X_{Kur} = \frac{1}{n} \frac{\sum_{i=1}^n (x_i - \bar{x})^4}{X_{RMS}^4}$
Mean	$X_{Mean} = \frac{1}{n} \sum_{i=1}^n x_i$	Skewness	$X_{Skew} = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{X_{std}} \right)^3$
Rectified mean value	$X_{RMV} = \frac{1}{n} \sum_{i=1}^n x_i $	Margin factor	$X_{MF} = \frac{X_{PK}}{X_{RSA}}$
Root mean square	$X_{RMS} = \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}$	Peak factor	$X_{PF} = \frac{X_{PK}}{X_{RMS}}$
Root square amplitude	$X_{RSA} = \left(\frac{1}{n} \sqrt{\sum_{i=1}^n x_i } \right)^2$	Impulse factor	$X_{IF} = \frac{X_{PK}}{X_{RMV}}$
Variance	$X_{Var} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$	Shape factor	$X_{SF} = \frac{X_{RMS}}{X_{RMV}}$

表 3 频域特征表

Table 3 Definitions of frequency-domain features

Feature	Definition	Feature	Definition
LLP energy	$X_{LLPE} = \sum_{k=1}^N D_1(k) ^2$	LHP energy	$X_{LHPE} = \sum_{k=1}^N D_2(k) ^2$
HLP energy	$X_{HLPE} = \sum_{k=1}^N D_3(k) ^2$	HHP energy	$X_{HHPE} = \sum_{k=1}^N D_4(k) ^2$
Wavelet entropy	$X_{WE} = -\sum_{i=1}^4 p(i) \cdot \log_2 p(i)$	Wavelet information quantum	$X_{WIQ} = \sum_{i=1}^4 p(i) \cdot E(i)$

$$R = \frac{N_{TP}}{N_{TP} + N_{FN}} \times 100\%, \quad (6)$$

$$F_1 = \frac{2 \times N_{TP}}{2 \times N_{TP} + N_{FP} + N_{FN}} \times 100\%, \quad (7)$$

式中: N_{TP} 为真实标签和预测标签都是正类的样本数量; N_{FP} 为真实标签为负类而预测标签为正类的样本数量; N_{FN} 为真实标签为正类而预测标签为负类的样本数量; N_{TN} 为真实标签和预测标签都为负类的样本数量。

未进行特征选择的特征数据集在 4 种分类器下的测试集混淆矩阵如图 4 所示。根据混淆矩阵, 事件标签 1、2、4 的精确率、召回率和 F1-Score 以及 6 类事件的平均识别准确率的计算结果如表 4 所示。

如前所述, 利用 SHAP 方法对模型进行解释时, 需要将特征数据集输入训练好的模型用于计算其 Shapley 值。尤其是计算式(1)中 $f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S)$ 时, 需要对所有特征是否参与模型训练的结果进行遍

历, 这一计算过程是非常耗时的。因此, 本文仅使用了每类事件的 1000 个样本进行 SHAP 分析, 所有分析在基于 Python 的 SHAP 工具箱上完成, 对于 SVM 与 KNN 模型使用 KernelSHAP 进行分析, 对于 DT 与 RF 模型则使用 TreeSHAP 进行分析。

这里以 SVM 分类器和挖掘事件中的某一样本为例, 展示不同特征如何影响模型的预测值, 结果如图 5 所示。图 5 中的基值为与特征无关的该样本被识别为该类别的概率, 为 0.1684, 接近于 1/6, 由于样本具有随机性, 所以该结果是合理的。特征的 Shapley 值分别用红蓝两种颜色显示, 以表示该特征将预测值由基值变为更高或更低的值, 即表示该特征对预测正确具有积极或消极的影响。从图 5 可以看出, 红色的 MF、PF、RMV、PK-PK、min、IF、WE、SF 等特征是该样本被正确识别的重要特征, 可以作为构建特征子集的备选项, 特别是数值较大的 WE、min 等特征的贡献较大,




图 4 未进行特征选择时 4 个模型的混淆矩阵。(a) SVM; (b) KNN; (c) DT; (d) RF

Fig. 4 Confusion matrices of four models without feature selection. (a) SVM; (b) KNN; (c) DT; (d) RF

表 4 未进行特征选择时 4 个模型的识别结果

Table 4 Recognition results of four models without feature selection

Model	Label	$P / \%$	$R / \%$	$F_1 / \%$	$A / \%$
SVM	1	70.38	76.69	73.40	81.68
	2	86.67	87.35	87.01	
	4	86.34	93.77	89.90	
KNN	1	87.72	91.04	89.35	94.29
	2	94.18	99.21	96.63	
	4	97.79	97.07	97.43	
DT	1	89.24	79.28	83.97	85.31
	2	91.55	92.09	91.82	
	4	93.74	93.22	93.48	
RF	1	96.16	89.84	92.89	96.11
	2	97.46	98.62	98.04	
	4	97.61	97.44	97.53	

属于比较重要的特征,而蓝色的 skew 特征则有一定的

负面影响,不宜选用。如果不进行特征选择,则该样本只有 0.71 的概率被识别为挖掘事件。

图 6 分别展示了所提取的 22 个特征对于 4 个分类器识别 6 类扰动事件的平均影响,并依据特征的 Shapley 值的平均值进行特征重要性排序。图 6 中各子图的横轴为 Shapley 值的平均值 (M_{Shapley}),代表特征对模型预测结果的平均影响,纵轴为 22 个特征;彩条的颜色代表不同的类别标签,彩条的长度对应于特征的重要性变化范围,特征的重要性体现在横轴位置上,即在某个特征的彩条中出现的左右位置对应于重要性程度,彩条越靠右说明该特征对该类信号的识别越重要。对比这些子图可以看出,相同特征对不同分类器的影响程度不同,这主要是由于模型的运行机制具有差异性。对于 SVM 与 KNN 模型,尽管特征重要性的排序不同,但排名靠前的特征中包含了几乎相同的特征。此外,在 WPD 后提取的频域特征(如 LHPE、HLPE、HHPE、WIQ 等频域特征)对二者的平均影响较小,可以认为是冗余特征。相反地,对于 DT 与 RF




图 5 不同特征对模型预测结果的影响

Fig. 5 Influences of different features on model prediction results




图6 基于SHAP的4个模型的特征重要性排名。(a) SVM;(b) KNN;(c) DT;(d) RF

Fig. 6 Feature importance rank of four models based on SHAP. (a) SVM; (b) KNN; (c) DT; (d) RF

这样的树模型,频域特征是对识别结果有较大影响的重要特征。对于所有的模型,WE与SF都是排名较为靠前的重要特征,受模型变化的影响较小。

筛选过多特征将导致识别准确率降低,因此,通过比较图6的4个子图中代表特征贡献的Shapley值的绝对值的平均值的变化的情况,并结合测试集的识别准确率的变化情况,对于4个分类器分别保留排名前12名、前10名、前13名、前11名的特征作为重要特征,并以此构成特征子集,重新训练4个分类器,测试集混淆矩阵以及评价指标结果分别如图7与表5所示。对比表4和表5可以看出,大幅减少特征数量后,平均识别准确率并没有显著下降,反而获得了一定程度的提高。尤其是RF分类器,其平均识别准确率达96.5%。得益于SHAP分析,一些冗余特征以及负面特征得以剔

除,且可解释性更强。

3.4 实时性

在实际应用中, φ -OTDR系统需要对抗动信号进行实时监测与识别,才能对入侵事件及时预警。对于传统机器学习模型,单个样本的识别时间包含特征提取时间与模型识别时间,其中特征提取时间取决于特征数据的复杂度,而模型识别时间取决于算法的复杂度。本文在配备i5-10300H CPU与16G内存的计算机设备下测试4个模型识别3084个样本所需的时间与单个样本的平均识别时间,如表6所示。提取22个特征需要较长的运行时间,由于算法运行机制的差异,树模型的运行时间较短。依据本文所提出的特征选择方法,针对不同模型只需提取不同数量的少量特征,特征提取时间与模型识别时间均得以缩短。综合考虑,在




图 7 特征选择后 4 个模型的混淆矩阵。(a) SVM; (b) KNN; (c) DT; (d) RF

Fig. 7 Confusion matrices of four models after feature selection. (a) SVM; (b) KNN; (c) DT; (d) RF

表 5 特征选择后 4 个模型的识别结果

Table 5 Recognition results of four models after feature selection

Model	Label	$P / \%$	$R / \%$	$F_1 / \%$	$A / \%$
SVM	1	72.28	82.07	76.87	83.07
	2	86.06	90.32	88.14	
	4	86.82	94.14	90.33	
KNN	1	88.34	92.03	90.15	95.04
	2	95.81	99.41	97.58	
	4	98.17	98.35	98.26	
DT	1	89.14	80.08	84.37	90.01
	2	92.46	92.09	92.28	
	4	95.41	91.39	93.36	
RF	1	96.61	90.84	93.63	96.5
	2	96.71	98.62	97.65	
	4	98.35	97.99	98.17	

表 6 识别时间对比

Table 6 Comparison of recognition time

Model	Feature extraction time / s		Model recognition time / ms		Average time / ms	
	Original	Proposed	Original	Proposed	Original	Proposed
SVM	252.35	191.46	6920.00	2670.00	84.07	62.95
KNN	252.35	182.17	5130.00	1092.00	83.00	59.69
DT	252.35	217.64	6.05	4.98	81.83	70.57
RF	252.35	203.58	42.11	37.90	81.82	66.01

4 种分类器中,RF 分类器具有高达 96.5% 的平均识别准确率,其单个样本平均识别时间仅为 66.01 ms,能更好地满足实时监测与识别的要求。

3.5 不同特征提取方法的对比

本节对所提出的基于 SHAP 的特征选择方法与广泛使用的基于 Fisher 得分^[21]与互信息^[23]的过滤式特征选择方法在特征选择后各模型的识别性能进行了比较。这两种特征选择方法只基于特征的方差、相关性等统计学指标选择特征,有时能在一定程度上缩短识别时间,但因其与模型无关,不能反映特征对模型预测结果的贡献,丢失重要特征会导致识别准确率下降。我们认为特征选择应该兼顾识别的实时性和准确性,故通过控制变量保证在选择的特征数量一样的情况下对比 3 种特征选择方法的信号识别效果,结果如表 7 所示。对于 4 个分类模型,本文所提出的特征选择方法能够保留更重要的特征,获得了更高的识别准确率。

表 7 利用不同特征选择方法得到的平均识别准确率对比
Table 7 Comparison of average recognition accuracy A with different feature selection methods

Model	$A / \%$		
	Proposed method	Fisher score ^[21]	Mutual information ^[23]
SVM	83.07	82.74	81.82
KNN	95.04	94.63	94.38
DT	90.01	88.34	87.47
RF	96.50	96.26	96.15

4 结 论

本文提出了一种具有可解释性和可靠性的特征选择方法。该方法利用机器学习可解释性方法 SHAP 量化不同特征对于模型的重要性,依据特征重要性排名进行选择,该方法可以选择出对模型分类最有效的重要特征,去除冗余或负面特征,在降低计算成本和缩短识别时间的同时提升识别准确率。基于北京交通大学开源数据集中的 6 种扰动事件,提取 22 个特征,并构建 4 个常用机器学习模型进行信号识别。充分考虑模型的特征重要性排名结果的差异性,选择不同数量和种类的特征构造相应的特征子集,4 个模型的单个样本测试时间均显著减少,且平均识别准确率有不同程度的提升。与基于统计学指标的过滤式特征选择方法相比,所提出的方法选择出的特征更有价值,获得的识别准确率更高。

上述结论仅基于所用数据集得出,在更为复杂或实际应用系统的数据集上是否适用,还需要进一步的验证。此外,后续工作中还可以比较更多模型的特征重要性排名,并与其他特征选择方法进行结合,从而融

合出光纤扰动信号识别中具有通用性的重要特征提取方案。

参 考 文 献

- [1] 吴慧娟,刘欣雨,饶云江. 基于 Φ -OTDR 的光纤分布式传感信号处理及应用[J]. 激光与光电子学进展, 2021, 58(13): 1306003.
- [2] Wu H J, Liu X Y, Rao Y J. Processing and application of fiber optic distributed sensing signal based on Φ -OTDR[J]. Laser & Optoelectronics Progress, 2021, 58(13): 1306003.
- [3] Yang Y Y, Zhang H F, Li Y. Long-distance pipeline safety early warning: a distributed optical fiber sensing semi-supervised learning method[J]. IEEE Sensors Journal, 2021, 21(17): 19453-19461.
- [4] Li Z Q, Zhang J W, Wang M N, et al. Fiber distributed acoustic sensing using convolutional long short-term memory network: a field test on high-speed railway intrusion detection[J]. Optics Express, 2020, 28(3): 2925-2938.
- [5] Hubbard P G, Xu J, Zhang S H, et al. Dynamic structural health monitoring of a model wind turbine tower using distributed acoustic sensing (DAS)[J]. Journal of Civil Structural Health Monitoring, 2021, 11(3): 833-849.
- [6] Lior I, Rivet D, Ampuero J P, et al. Magnitude estimation and ground motion prediction to harness fiber optic distributed acoustic sensing for earthquake early warning[J]. Scientific Reports, 2023, 13: 424.
- [7] 王鸣,沙洲,封皓,等. 基于 LSTM-CNN 的 ϕ -OTDR 模式识别[J]. 光学学报, 2023, 43(5): 0506001.
- [8] Wang M, Sha Z, Feng H, et al. ϕ -OTDR pattern recognition based on LSTM-CNN[J]. Acta Optica Sinica, 2023, 43(5): 0506001.
- [9] 尚秋峰,黄达. 基于 MATCN 的光纤周界入侵信号识别方法[J]. 光学学报, 2023, 43(20): 2006006.
- [10] Shang Q F, Huang D. Identification method of optical fiber perimeter intrusion signal based on MATCN[J]. Acta Optica Sinica, 2023, 43(20): 2006006.
- [11] Kandamali D F, Cao X M, Tian M L, et al. Machine learning methods for identification and classification of events in ϕ -OTDR systems: a review[J]. Applied Optics, 2022, 61(11): 2975-2997.
- [12] Wang Z Y, Pan Z Q, Ye Q, et al. Novel distributed passive vehicle tracking technology using phase sensitive optical time domain reflectometer[J]. Chinese Optics Letters, 2015, 13(10): 100603.
- [13] 王鸣,封皓,沙洲,等. 基于经验模态分解的马赫-曾德尔干涉仪事件识别方案优化[J]. 光学学报, 2023, 43(19): 1906005.
- [14] Wang M, Feng H, Sha Z, et al. Optimization of Mach-Zehnder interferometer event recognition scheme based on empirical mode decomposition[J]. Acta Optica Sinica, 2023, 43(19): 1906005.
- [15] 于森,张耀鲁,何禹潼,等. 变分模态分解-排列熵方法用于分布式光纤振动传感系统去噪[J]. 光学学报, 2022, 42(7): 0706005.
- [16] Yu M, Zhang Y L, He Y T, et al. Variational mode decomposition and permutation entropy method for denoising of distributed optical fiber vibration sensing system[J]. Acta Optica Sinica, 2022, 42(7): 0706005.
- [17] Wu H J, Qian Y, Zhang W, et al. Feature extraction and identification in distributed optical-fiber vibration sensing system for oil pipeline safety monitoring[J]. Photonic Sensors, 2017, 7(4): 305-310.
- [18] 张俊楠,姜淑琴,梁生. 基于 SVM 算法的 ϕ -OTDR 分布式光纤扰动传感系统模式识别研究[J]. 红外与激光工程, 2017, 46(4): 0422003.
- [19] Zhang J N, Lou S Q, Liang S. Study of pattern recognition based on SVM algorithm for ϕ -OTDR distributed optical fiber

- disturbance sensing system[J]. Infrared and Laser Engineering, 2017, 46(4): 0422003.
- [14] Jia H Z, Liang S, Lou S Q, et al. A k -nearest neighbor algorithm-based near category support vector machine method for event identification of φ -OTDR[J]. IEEE Sensors Journal, 2019, 19(10): 3683-3689.
- [15] Huang Y Z, Zhao H M, Zhao X T, et al. Pattern recognition using self-reference feature extraction for φ -OTDR[J]. Applied Optics, 2022, 61(35): 10507-10518.
- [16] Wang X, Liu Y, Liang S, et al. Event identification based on random forest classifier for Φ -OTDR fiber-optic distributed disturbance sensor[J]. Infrared Physics & Technology, 2019, 97: 319-325.
- [17] Wang Z D, Lou S Q, Liang S, et al. Multi-class disturbance events recognition based on EMD and XGBoost in φ -OTDR[J]. IEEE Access, 2020, 8: 63551-63558.
- [18] Wu H J, Liu X R, Xiao Y, et al. A dynamic time sequence recognition and knowledge mining method based on the hidden Markov models (HMMs) for pipeline safety monitoring with Φ -OTDR[J]. Journal of Lightwave Technology, 2019, 37(19): 4991-5000.
- [19] Effrosynidis D, Arampatzis A. An evaluation of feature selection methods for environmental data[J]. Ecological Informatics, 2021, 61: 101224.
- [20] Zhao Z F, Liu D, Wang L W, et al. Feature extraction and identification of pipeline intrusion based on phase-sensitive optical time domain reflectometer[M]//Jia M, Guo Q, Meng W X. Wireless and satellite systems. Lecture notes of the institute for computer sciences, social informatics and telecommunications engineering. Cham: Springer, 2019, 280: 665-675.
- [21] Jia H Z, Lou S Q, Liang S, et al. Event identification by F-ELM model for Φ -OTDR fiber-optic distributed disturbance sensor[J]. IEEE Sensors Journal, 2020, 20(3): 1297-1305.
- [22] Wang X, Zhang G F, Lou S Q, et al. Two-round feature selection combining with LightGBM classifier for disturbance event recognition in phase-sensitive OTDR system[J]. Infrared Physics & Technology, 2022, 123: 104191.
- [23] Huang L, Zhou X Q, Shi L H, et al. Time series feature selection method based on mutual information[J]. Applied Sciences, 2024, 14(5): 1960.
- [24] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]//Advances in Neural Information Processing Systems 30 (NIPS 2017), December 4–9, 2017, Long Beach, CA, USA. New York: Curran Associates, 2017: 4765-4774.
- [25] Cao X M, Su Y S, Jin Z Y, et al. An open dataset of φ -OTDR events with two classification models as baselines[J]. Results in Optics, 2023, 10: 100372.
- [26] Sun M, Fang N. Explainable feature selection by SHAP for signal recognition of Φ -OTDR system[J]. Proceedings of SPIE, 2023, 12935: 1293540.

Interpretable Feature Selection Method for Optical-Fiber Disturbance Signal Recognition

Sun Min, Fang Nian*

School of Communication and Information Engineering, Key Laboratory of Specialty Fiber Optics and Optical Access Networks, Joint International Research Laboratory of Specialty Fiber Optics and Advanced Communication, Shanghai University, Shanghai 200444, China

Abstract

Objective The distributed optical fiber sensing system based on a phase-sensitive optical time-domain reflectometer (φ -OTDR) has been widely used for disturbance signal recognition in perimeter security, pipeline monitoring, railway transportation monitoring, and other fields, due to its advantages of high sensitivity, multi-point monitoring, and wide coverage. Currently, machine learning-based methods are the primary approach to enhance the accuracy of disturbance signal recognition. Classical machine learning algorithms require preprocessing of raw input signals through manual feature extraction. Typically, increasing the number of extracted features is aimed at achieving higher recognition accuracy with the growth in the number of disturbance events. However, introducing irrelevant features can adversely affect recognition accuracy and efficiency. Therefore, the feature selection process, which eliminates irrelevant features to strengthen recognition performance, plays a crucial role in the preprocessing stage. Feature selection methods can be categorized into three types: filter, wrapper, and embedded methods. Particularly, most feature selection methods used for optical fiber disturbance signal recognition fall under the filter method category, often overlooking the relationship between features and models. In this study, we aim to develop a more efficient and interpretable feature selection method for identifying key features to further boost recognition performance.

Methods We propose a novel feature selection method based on Shapley additive explanations (SHAP), which is an explainable artificial intelligence (XAI) method. SHAP is inspired by game theory to calculate the Shapley value, which can quantify the contribution of each feature to the model's prediction (Equation 1). We use SHAP to obtain the mean SHAP value for a classification model. The higher the mean, the more important the feature. We rank the features by

importance and select some of the most significant ones to form a feature subset while ensuring high recognition rates. This subset is used to retrain the model, thereby improving recognition efficiency.

Results and Discussions Experimental validation is conducted using an open dataset of optical-fiber disturbance events from Beijing Jiaotong University, divided into training and test sets at an 8:2 ratio (Table 1). The dataset includes six typical disturbance events: background noise, digging, knocking, watering, shaking, and walking. We extract sixteen time-domain features from the disturbance signals after differentiation and segmentation. Additionally, wavelet packet decomposition (WPD) is employed to extract six frequency-domain features (Tables 2 and 3). The feature set, comprising twenty-two features, is normalized and inputted into four common machine learning models as baselines: support vector machine (SVM), K-nearest neighbor (KNN), decision tree (DT), and random forest (RF). KernelSHAP is applied to SVM and KNN, while tree SHAP is used for DT and RF. The ranking of these twenty-two features is determined across the four models (Fig. 6). Importantly, each feature contributes differently to the classification of the six disturbance events depending on the model. To maintain recognition accuracy without compromise, we retain a varying number of key features for each model. Comparing the accuracy, precision, recall, and F1-score from the test confusion matrices (Tables 4–5), we observe improvements in recognition performance across varying degrees due to feature selection. Among the four models, the RF model achieves the highest recognition accuracy of 96.5%. Furthermore, the average recognition time per sample for the RF model decreases from 81.82 ms without feature selection to 66.01 ms, which marks a 19.3% reduction (Table 6). Common feature selection methods such as fisher score and mutual information are also used for comparison with the SHAP-based feature selection method. The SHAP-based method demonstrates superior recognition accuracy compared to these alternatives (Table 7).

Conclusions We propose a feature selection method characterized by interpretability and reliability. This method leverages explainable AI (XAI) techniques to quantify the importance of different features for the model and selects them based on their importance rankings. By retaining the most effective features for model classification and discarding redundant or detrimental ones, our approach enhances recognition accuracy while reducing computational costs and identification time. Twenty-two features are extracted from six types of disturbance events using an open dataset from Beijing Jiaotong University. We employ four common machine learning models for signal recognition. By carefully considering variations in feature importance rankings across models, we construct different subsets of features. This results in significant decreases in single-sample testing times for all four models and varying degrees of improvement in average recognition accuracy. Compared with filtering methods based on statistical metrics, our proposed method selects more valuable features, thereby achieving higher recognition rates. It is important to note that these conclusions are drawn solely from the dataset used. Further validation is necessary to assess its applicability to more complex or real-world datasets. Future work could involve comparing feature importance rankings across more models and integrating other feature selection methods to develop a versatile approach for optical-fiber disturbance signal recognition.

Key words sensor; phase-sensitive optical time-domain refractometer; signal recognition; feature selection; explainable machine learning