



(21) 申请号 202210588497.8

(22) 申请日 2022.05.26

(65) 同一申请的已公布的文献号

申请公布号 CN 114861732 A

(43) 申请公布日 2022.08.05

(73) 专利权人 中国石油大学(华东)

地址 266580 山东省青岛市黄岛区长江西
路66号专利权人 朴牛(山东)能源科技发展有限责
任公司

(72) 发明人 刘均荣 韩艳慧

(74) 专利代理机构 济南竹森知识产权代理事务
所(普通合伙) 37270

专利代理师 刘宏广

(51) Int.Cl.

G06F 18/241 (2023.01)

G06F 18/243 (2023.01)

G06F 18/10 (2023.01)

G06F 18/15 (2023.01)

G06F 18/2131 (2023.01)

G06F 18/2135 (2023.01)

G06F 18/25 (2023.01)

G06N 3/084 (2023.01)

E21B 49/08 (2006.01)

(56) 对比文件

CN 104021295 A, 2014.09.03

CN 110414554 A, 2019.11.05

审查员 刘欢


权利要求书4页 说明书13页 附图9页

(54) 发明名称

基于分布式光纤声波监测数据的井筒流体
类型识别方法、系统

(57) 摘要

一种基于分布式光纤声波监测数据的井筒流体类型识别方法,对DAS系统采集的声波监测数据进行处理,得到相关的滤波和归一化处理之后的声波数据;进行声波特征参数提取,得到与井筒流体类型相关的声波特征;将低方差散射特征集a和短时时频特征集b融合形成的融合特征集c;将得到的声波特征输入至分类算法中进行训练为识别模型;将声波监测数据输入识别模型,输出井筒流体类型。本发明将低方差散射特征与短时时频特征相结合形成融合特征用于流体类型识别,融合特征属于多源特征,综合了低方差散射特征与短时时频特征中包含的信息,为井筒流体类型的准确识别提供了更多数据源,有效解决单一特征识别流体类型准确率低的问题,极大提高了识别精度。



1. 一种基于分布式光纤声波监测数据的井筒流体类型识别方法,其特征在于,包括,

步骤一:对DAS系统采集的声波监测数据进行预处理,用于得到与井筒流体类型相关的滤波和归一化处理之后的声波数据;

步骤二:对步骤一预处理后的数据进行声波特征参数提取,得到与井筒流体类型相关的声波特征;

所述与井筒流体类型相关的声波特征包括:低方差散射特征集a和短时时频特征集b融合形成的融合特征集c;

步骤三:将步骤二得到的声波特征输入至分类算法中进行训练,得到井筒流体类型识别模型;

步骤四:将实时DAS系统声波监测数据输入至所述步骤三所述井筒流体类型识别模型中,输出结果即为对应的井筒流体类型;

所述步骤二中,进行声波特征参数提取,得到与井筒流体类型相关的声波特征的方法,包括:

2-1利用小波时间散射变换提取DAS声波数据集的低方差散射特征集a;其中,所述低方差散射特征集a的维度为 $(w*k) \times p$,k为DAS声波数据集的个数,p为信号经散射变换后得到的散射路径的个数,w为每条散射路径对应的时间窗口的个数,p和w与DAS系统的采样频率有关;

同时,利用短时傅里叶变换对DAS声波数据集进行处理,得到DAS的时频数据集,将时频数据集输入到主成分分析算法中进行处理,提取DAS声波数据集的短时时频特征集b;其中,短时时频特征集b的维度为 $k \times r$,r为短时傅里叶变换处理声波数据时采用的窗口重叠宽度加1,所述窗口重叠宽度为窗口宽度的一半,所述短时傅里叶变换是关于时间和频率的二维函数:

$$STFT(k', t) = \sum_{m=1}^N x(t)w(t - m/fs)e^{-2\pi k' \cdot jm/N} \quad (2)$$

在公式(2)中,N表示DAS声波数据时间序列维数;t为时间参数;k'为频率参数;fs为DAS系统的采样频率; $m=1, 2, \dots, N$;j为虚数单位, $j = \sqrt{-1}$;x(t)为需要处理的时域DAS声波数据; $w(t - m/fs)$ 代表中心位于m/fs时刻的窗口函数;

2-2将低方差散射特征集a与短时时频特征集b融合形成融合特征集c:

低方差散射特征集a的数据维度为 $(w*k) \times p$,短时时频特征集b的数据维度为 $k \times r$,重复短时时频特征集b的数据,将其维度扩展到 $(w*k) \times r$;利用顺序排列的方式得到融合特征集c,融合特征集c的维度为 $(w*k) \times (p+r)$;

2-3利用分类算法训练形成井筒流体类型识别模块:所述融合特征集c作为输入,将融合特征集c对应的已知流体类型作为输出;所述分类算法包括BP神经网络、决策树和随机森林;

2-4对BP神经网络、决策树和随机森林分别进行训练并分别形成BP神经网络训练模型、决策树训练模型和随机森林训练模型。

2. 根据权利要求1所述的一种基于分布式光纤声波监测数据的井筒流体类型识别方

法,其特征在于,所述步骤一中所述预处理方法,包括:

1-1采用滤波器对井筒流体流动过程中声波监测数据进行处理,得到频率范围在[200Hz,2000Hz]的声波幅值;

1-2将经步骤1-1得到的声波幅值,进行Z-score归一化处理,所述的Z-score归一化公式表示为:

$$x' = \frac{x - \mu}{\sigma} \quad (1)$$

其中, x 为声波幅值; x' 为归一化后的结果,即DAS声波数据集; μ 为 x 的平均值, σ 为 x 的标准差。

3.根据权利要求1所述的一种基于分布式光纤声波监测数据的井筒流体类型识别方法,其特征在于,BP神经网络训练模型为三层网络结构,在前向传播的过程中,输入数据从输入层经隐含层处理,直至输出层;如果输出层得不到期望输出,则转入反向传播,根据预测误差调整网络权值和阈值,从而使BP神经网络预测输出不断逼近期望输出,BP神经网络选择适用于模式识别的比例共轭梯度(SCG)算法,选择交叉熵为损失函数,设置BP神经网络最大训练次数范围为5000-20000,学习速率范围为0.01-0.05;

决策树训练模型是一个树形结构,由节点和有向边组成;所述节点包括内部节点和叶节点,内部节点表示一个特征或一个属性,叶节点表示一个类;采用自顶向下的递归方式,从树的根节点开始,在它的内部节点上进行属性值的测试比较,然后按照实例的属性值确定对应的分支,最后在决策树的叶节点得出分类结论,决策树模型选择的节点分裂特征是信息增益,模型中叶节点含有的最少样本数默认为1;

随机森林训练模型基本单元是决策树,通过自助法重采样:随机森林从原始训练样本集中有放回地重复随机抽取 n' 个样本生成新的训练样本集来训练决策树,按以上步骤生成 m' 棵决策树组成随机森林,随机森林集成了所有的分类投票结果,将投票次数最多的类别指定为最终输出,设置随机森林中决策树棵树范围为50-500棵,不限制决策树的最大深度。

4.一种基于分布式光纤声波监测数据识别井筒内油水两相流中含水范围的方法,其特征在于,包括:

步骤一:对DAS系统采集的声波监测数据进行预处理,用于得到与油水两相流中不同含水范围相关的滤波和归一化处理之后的声波数据;

步骤二:对步骤一预处理后的数据进行声波特征参数提取,得到与油水两相流中不同含水范围相关的声波特征;

所述与油水两相流中不同含水范围相关的声波特征包括:低方差散射特征集a和短时频特征集b融合形成的融合特征集c;

步骤三:将步骤二得到的声波特征输入至分类算法中进行训练,得到油水两相流中不同含水范围识别模型;

步骤四:将实时DAS系统声波监测数据输入至所述步骤三所述油水两相流中不同含水范围识别模型中,输出结果即为对应的油水两相流中不同含水范围;

所述步骤二中,进行声波特征参数提取,得到与油水两相流中不同含水范围相关的声波特征的方法,包括:3-1利用DAS系统实时采集目标待测的井筒内油水两相流中,不同含水范围所对应的声波数据,构建样本数据库;

3-2将油水两相流中的含水范围分为Y组,并分别标注为1到Y;

3-3利用小波时间散射变换提取DAS声波数据集的低方差散射特征集a;其中,所述低方差散射特征集a的维度为 $(w*k) \times p$,k为DAS声波数据集的个数,p为信号经散射变换后得到的散射路径的个数,w为每条散射路径对应的时间窗口的个数,p和w与DAS系统的采样频率有关;

同时,利用短时傅里叶变换对DAS声波数据集进行处理,得到DAS的时频数据集,将时频数据集输入到主成分分析算法中进行处理,提取DAS声波数据集的短时时频特征集b;其中,短时时频特征集b的维度为 $k \times r$,r为短时傅里叶变换处理声波数据时采用的窗口重叠宽度加1,所述窗口重叠宽度为窗口宽度的一半,所述短时傅里叶变换是关于时间和频率的二维函数:

$$STFT(k', t) = \sum_{m=1}^N x(t)w(t - m/fs)e^{-2\pi k' j m/N} \quad (2)$$

在公式(2)中,N表示DAS声波数据时间序列维数;t为时间参数;k'为频率参数;fs为DAS系统的采样频率; $m=1, 2, \dots, N$;j为虚数单位, $j = \sqrt{-1}$;x(t)为需要处理的时域DAS声波数据; $w(t - m/fs)$ 代表中心位于m/fs时刻的窗口函数;

3-4将低方差散射特征集a与短时时频特征集b融合形成融合特征集c:

低方差散射特征集a的数据维度为 $(w*k) \times p$,短时时频特征集b的数据维度为 $k \times r$,重复短时时频特征集b的数据,将其维度扩展到 $(w*k) \times r$;利用顺序排列的方式得到融合特征集c,融合特征集c的维度为 $(w*k) \times (p+r)$;

3-5利用分类算法训练形成油水两相流中含水范围的识别模块:所述融合特征集c作为输入,将融合特征集c对应的油水两相流中含水范围作为输出;所述分类算法包括BP神经网络、决策树和随机森林;

3-6对BP神经网络、决策树和随机森林分别进行训练并分别形成BP神经网络训练模型、决策树训练模型和随机森林训练模型。

5.根据权利要求4所述的一种基于分布式光纤声波监测数据识别井筒内油水两相流中含水范围的方法,其特征在于,所述步骤一中所述预处理方法,包括:

1-1采用滤波器对井筒流体流动过程中声波监测数据进行处理,得到频率范围在[200Hz, 2000Hz]的声波幅值;

1-2将经步骤1-1得到的声波幅值,进行Z-score归一化处理,所述的Z-score归一化公式表示为:

$$x' = \frac{x - \mu}{\sigma} \quad (1)$$

其中,x为声波幅值;x'为归一化后的结果,即DAS声波数据集; μ 为x的平均值, σ 为x的标准差。

6.根据权利要求4所述的一种基于分布式光纤声波监测数据识别井筒内油水两相流中含水范围的方法,其特征在于,BP神经网络训练模型为三层网络结构,在前向传播的过程中,输入数据从输入层经隐含层处理,直至输出层;如果输出层得不到期望输出,则转入反

向传播,根据预测误差调整网络权值和阈值,从而使BP神经网络预测输出不断逼近期望输出,BP神经网络选择适用于模式识别的比例共轭梯度(SCG)算法,选择交叉熵为损失函数,设置BP神经网络最大训练次数范围为5000-20000,学习速率范围为0.01-0.05;

决策树训练模型是一个树形结构,由节点和有向边组成;所述节点包括内部节点和叶节点,内部节点表示一个特征或一个属性,叶节点表示一个类;采用自顶向下的递归方式,从树的根节点开始,在它的内部节点上进行属性值的测试比较,然后按照实例的属性值确定对应的分支,最后在决策树的叶节点得出分类结论,决策树模型选择的节点分裂特征是信息增益,模型中叶节点含有的最少样本数默认为1;

随机森林训练模型基本单元是决策树,通过自助法重采样:随机森林从原始训练样本集中有放回地重复随机抽取 n' 个样本生成新的训练样本集来训练决策树,按以上步骤生成 m' 棵决策树组成随机森林,随机森林集成了所有的分类投票结果,将投票次数最多的类别指定为最终输出,设置随机森林中决策树棵树范围为50-500棵,不限制决策树的最大深度。

7.一种利用如权利要求1所述识别方法进行井筒流体类型识别的系统,其特征在于,包括:数据预处理模块、声波特征参数提取模块和井筒流体类型识别模块;

所述数据预处理模块,用于得到与井筒流体类型相关的滤波和归一化处理之后的声波数据;

所述声波特征参数提取模块,用于进行声波特征参数提取,得到与井筒流体类型相关的声波特征;所述与井筒流体类型相关的声波特征包括:低方差散射特征集a和短时时频特征集b融合形成的融合特征集c;

所述井筒流体类型识别模块,用于将声波特征输入至分类算法中进行训练,得到井筒流体类型识别模型;

最终将实时DAS系统声波监测数据输入至所述井筒流体类型识别模型中,输出结果即为对应的井筒流体类型。

8.一种利用如权利要求4所述识别井筒内油水两相流中含水范围的方法进行井筒内油水两相流中含水范围识别的系统,其特征在于,包括:数据预处理模块、声波特征参数提取模块和井筒内油水两相流中含水范围识别模块;

所述数据预处理模块,用于得到与井筒内油水两相流中不同含水范围相关的滤波和归一化处理之后的声波数据;

所述声波特征参数提取模块,用于进行声波特征参数提取,得到与井筒内油水两相流中不同含水范围相关的声波特征;所述与井筒内油水两相流中不同含水范围相关的声波特征包括:低方差散射特征集a和短时时频特征集b融合形成的融合特征集c;

所述井筒内油水两相流中含水范围识别模块,用于将声波特征输入至分类算法中进行训练,得到井筒内油水两相流中含水范围识别模型;

最终将实时DAS系统声波监测数据输入至所述井筒内油水两相流中含水范围识别模型中,输出结果即为对应的油水两相流中含水范围。

基于分布式光纤声波监测数据的井筒流体类型识别方法、系统

技术领域

[0001] 本发明公开一种基于分布式光纤声波监测数据的井筒流体类型识别方法、系统，属于油气田开发的技术领域。

背景技术

[0002] 油气生产过程中，井筒中多相流体流动的实时监测是观测油气井生产状况、评价油气井产能和分析储层动态变化的重要依据，对保障油气田安全和高效生产具有重要意义。目前，国内外采用层析成像技术和超声检测技术以及高速摄像机、差压传感器、电导率传感器、射线衰减、粒子成像测速等技术对井筒多相流体的流型进行识别，确定井筒中流动流体的分布状态，如纯液流、泡流、段塞流、环状流、雾流。

[0003] 近年来，分布式光纤声波监测 (DAS) 技术快速发展，为井筒多相流体流动状态的连续、长距离实时监测提供了一种新的手段。DAS技术利用相干光时域反射测量的原理，通过检测井下事件前后的瑞利散射光信号的强度变化，探测并精确定位正在发生的井下流体流动事件，从而实现井下生产动态的实时监测。光纤传感技术具有的抗电磁干扰能力强、耐腐蚀、耐高温、空间分辨率高和实时性好等优点，使得其在井下多相流体生产动态实时监测方面具有更大的优越性和广阔的发展前景，但与此同时产生的巨大数据量也为DAS技术的应用带来了难题。

[0004] 中国专利文献CN 112985574公开基于模型融合的光纤分布式声波传感信号高精度分类识别方法，该文献在DAS信号识别中引入stacking策略将机器学习中决策树模型、随机森林模型、支持向量机模型和极值梯度提升算法模型进行集成，对DAS系统获取的原始数据进行预处理再提取多分析域的特征，并利用人工神经网络对特征进行进一步的提取和分类，使用逻辑回归对上述模型的预测结果进行再学习，得到当前输入信号所处的环境状态的最终预测。该专利文献中提取了DAS信号的时域、频域和变化域特征，但没有提取DAS信号的时频域特征，无法反映信号的频率变化随时间变化的关系，由于DAS信号通常是时变且非稳态的，信号的时频变化信息对于后续井筒流体类型识别具有重要作用。

[0005] 综上所述，所述机器学习方法对DAS监测数据处理具有巨大优势，怎样利用机器学习技术对井筒中流动流体的类型进行识别分类，确定出流动流体为单相油、单相水、单相气、油水两相、油气两相、气水两相还是油气水三相，并为井下多相流体流动监测和水气突破识别提供技术支撑，是本技术领域一直重点关注的技术问题。

[0006] 除此之外，怎样利用机器学习技术对井筒中流动流体含水变化分析也是跟踪油藏动态、优化油井生产、制定井下措施的重要依据，同时对于识别出水位置也具有重要意义。目前含水测量方法主要分为离线测量法和在线测量法。典型的离线测量方法有蒸馏法、电脱法、卡尔-费休法。离线测量法测量精度相对较高，但测量结果具有随机性，且取样和测量过程费时费力，存在一定的人工误差，不能满足油田生产在线测量需求。近年来，在线测量已成为一种发展趋势，在线测量方法主要有射线法、电容法、电导法、微波法、射频法、同轴

相位法等,这些方法可以实现动态实时在线监测,但以地面单点测量为主,无法满足监测井下各生产层段含水变化的需求。由于DAS技术的快速发展为油井含水变化的连续、长距离实时监测提供了一种新的手段,因此利用机器学习方法对DAS监测数据处理具有巨大优势,即利用机器学习算法建立含水范围分类识别方法,确定出油井含水率的大致范围,为油藏动态分析、油井生产优化、出水位置识别提供技术支撑,是本技术领域一直重点关注的技术问题。

发明内容

[0007] 针对现有技术的不足,本发明公开一种基于分布式光纤声波监测数据的井筒流体类型识别方法。

[0008] 本发明还公开了一种利用上述识别方法进行井筒流体类型识别的系统。

[0009] 本发明还公开了一种通过所述识别方法输出井筒流体类型结果后,进行后续应用的方法。

[0010] 本发明详细的技术方案如下:

[0011] 一种基于分布式光纤声波监测数据的井筒流体类型识别方法,其特征在于,

[0012] 步骤一:对DAS系统采集的声波监测数据进行预处理,用于得到与井筒流体类型相关的滤波和归一化处理之后的声波数据;

[0013] 步骤二:对步骤一预处理后的数据进行声波特征参数提取,得到与井筒流体类型相关的声波特征;

[0014] 所述与井筒流体类型相关的声波特征包括:低方差散射特征集a和短时时频特征集b融合形成的融合特征集c;

[0015] 步骤三:将步骤二得到的声波特征输入至分类算法中进行训练,得到井筒流体类型识别模型;

[0016] 步骤四:将实时DAS系统声波监测数据输入至所述步骤三所述井筒流体类型识别模型中,输出结果即为对应的井筒流体类型。

[0017] 根据本发明优选的,所述步骤一中所述预处理方法,包括:

[0018] 1-1采用滤波器对井筒流体流动过程中声波监测数据进行处理,得到频率范围在[200Hz,2000Hz]的声波幅值;

[0019] 1-2将经步骤1-1得到的声波幅值,进行Z-score归一化处理,所述的Z-score归一化公式表示为:

$$[0020] \quad x' = \frac{x - \mu}{\sigma} \quad (1)$$

[0021] 其中,x为声波幅值;x'为归一化后的结果,即DAS声波数据集; μ 为x的平均值, σ 为x的标准差。

[0022] 根据本发明优选的,所述步骤二中,进行声波特征参数提取,得到与井筒流体类型相关的声波特征的方法,包括:

[0023] 2-1利用小波时间散射变换提取DAS声波数据集的低方差散射特征集a;其中,所述低方差散射特征集a的维度为 $(w*k) \times p$,k为DAS声波数据集的个数,p为信号经散射变换后得到的散射路径的个数,w为每条散射路径对应的时间窗口的个数,p和w与DAS系统的采样

频率有关;其中,利用小波时间散射变换是指利用软件Matlab中的小波工具箱,通过构建了用于特征提取的带有两个滤波器组的小波时间散射网络而实现的,此步骤中利用软件Matlab求取低方差散射特征集a是现有技术,不属于本发明所保护的内容;

[0024] 同时,利用短时傅里叶变换(STFT)对DAS声波数据集进行处理,得到DAS的时频数据集,将时频数据集输入到主成分分析算法(PCA)中进行处理,提取DAS声波数据集的短时频特征集b;其中,短时时频特征集b的维度为 $k \times r$, r 为短时傅里叶变换(STFT)处理声波数据时采用的窗口重叠宽度加1,所述窗口重叠宽度为窗口宽度的一半,所述短时傅里叶变换(STFT)是关于时间和频率的二维函数:

$$[0025] \quad STFT(k', t) = \sum_{m=1}^N x(t)w(t - m/fs)e^{-2\pi k' jm/N} \quad (2)$$

[0026] 在公式(2)中, N 表示DAS声波数据时间序列维数; t 为时间参数; k' 为频率参数; fs 为DAS系统的采样频率; $m=1, 2, \dots, N$; j 为虚数单位, $j = \sqrt{-1}$; $x(t)$ 为需要处理的时域DAS声波数据; $w(t-m/fs)$ 代表中心位于 m/fs 时刻的窗口函数;优选的,为减少频谱泄漏,所述窗口选择汉明窗;

[0027] 所述主成分分析算法(PCA)是一种常用的降维统计技术,本发明利用PCA算法计算时频数据集协方差矩阵的特征向量,第一主成分的特征值最大,对应特征向量上包含的信息量最多,可利用第一主成分特征向量得到与井筒流体类型最相关的短时时频特征集b;

[0028] 2-2将低方差散射特征集a与短时时频特征集b融合形成融合特征集c:

[0029] 低方差散射特征集a的数据维度为 $(w \times k) \times p$,短时时频特征集b的数据维度为 $k \times r$,重复短时时频特征集b的数据,将其维度扩展到 $(w \times k) \times r$;利用顺序排列的方式得到融合特征集c,融合特征集c的维度为 $(w \times k) \times (p+r)$;

[0030] 2-3利用分类算法训练形成井筒流体类型识别模块:所述融合特征集c作为输入,将融合特征集c对应的已知流体类型作为输出;所述分类算法包括BP神经网络、决策树和随机森林;

[0031] 2-4对BP神经网络、决策树和随机森林分别进行训练并分别形成BP神经网络训练模型、决策树训练模型和随机森林训练模型;将测试集分别代入BP神经网络训练模型、决策树训练模型和随机森林训练模型中,通过均方误差验证预测的效果:当预测精度满足要求时,进入后续的利用现场实际监测数据进行流体类型识别的环节;当不满足预测精度要求时,重新调节分类算法的训练参数,重新开始训练过程,直到满足精度要求为止。此处可以按现有技术确定训练精度,这三种训练模型都是比较经典的分类方法,所述按照训练精度停止训练的技术手段属于现有技术;将DAS原始声波数据集随机打乱之后按照8:2的比例划分为训练集和测试集。

[0032] 一种识别井筒内油水两相流中含水范围的方法,其特征在于,所述步骤二中,进行声波特征参数提取,得到与油水两相流中不同含水范围相关的声波特征的方法,包括:

[0033] 3-1利用DAS系统实时采集目标待测的井筒内油水两相流中不同含水范围所对应的声波数据,构建样本数据库;其中,所使用的DAS系统空间采样间隔为0.25m,采样频率为4096Hz;将所述样本数据随机打乱之后按照8:2的比例划分为训练集和测试集;

[0034] 3-2将油水两相流中的含水范围分为Y组,并分别标注为1到Y;

[0035] 3-3利用小波时间散射变换提取DAS声波数据集的低方差散射特征集a;其中,所述低方差散射特征集a的维度为 $(w \times k) \times p$,k为DAS声波数据集的个数,p为信号经散射变换后得到的散射路径的个数,w为每条散射路径对应的时间窗口的个数,p和w与DAS系统的采样频率有关;

[0036] 同时,利用短时傅里叶变换对DAS声波数据集进行处理,得到DAS的时频数据集,将时频数据集输入到主成分分析算法中进行处理,提取DAS声波数据集的短时时频特征集b;其中,短时时频特征集b的维度为 $k \times r$,r为短时傅里叶变换处理声波数据时采用的窗口重叠宽度加1,所述窗口重叠宽度为窗口宽度的一半,所述短时傅里叶变换是关于时间和频率的二维函数:

$$[0037] \quad STFT(k', t) = \sum_{m=1}^N x(t)w(t - m/fs)e^{-2\pi k' j m/N} \quad (2)$$

[0038] 在公式(2)中,N表示DAS声波数据时间序列维数;t为时间参数;k'为频率参数;fs为DAS系统的采样频率; $m=1, 2, \dots, N$;j为虚数单位, $j = \sqrt{-1}$;x(t)为需要处理的时域DAS声波数据; $w(t-m/fs)$ 代表中心位于m/fs时刻的窗口函数;

[0039] 3-4将低方差散射特征集a与短时时频特征集b融合形成融合特征集c;

[0040] 低方差散射特征集a的数据维度为 $(w \times k) \times p$,短时时频特征集b的数据维度为 $k \times r$,重复短时时频特征集b的数据,将其维度扩展到 $(w \times k) \times r$;利用顺序排列的方式得到融合特征集c,融合特征集c的维度为 $(w \times k) \times (p+r)$;

[0041] 3-5利用分类算法训练形成油水两相流中含水范围的识别模块:所述融合特征集c作为输入,将融合特征集c对应的油水两相流中含水范围作为输出;所述分类算法包括BP神经网络、决策树和随机森林;

[0042] 3-6对BP神经网络、决策树和随机森林分别进行训练并分别形成BP神经网络训练模型、决策树训练模型和随机森林训练模型。

[0043] 根据本发明优选的,BP神经网络训练模型为三层网络结构,在前向传播的过程中,输入数据从输入层经隐含层处理,直至输出层;如果输出层得不到期望输出,则转入反向传播,根据预测误差调整网络权值和阈值,从而使BP神经网络预测输出不断逼近期望输出,BP神经网络选择适用于模式识别的比例共轭梯度(SCG)算法,选择交叉熵为损失函数,避免过拟合,设置BP神经网络最大训练次数范围为5000-20000,学习速率范围为0.01-0.05。

[0044] 根据本发明优选的,决策树训练模型是一个类似流程图的树形结构,由节点和有向边组成;所述节点包括内部节点和叶节点,内部节点表示一个特征或一个属性,叶节点表示一个类;采用自顶向下的递归方式,从树的根节点开始,在它的内部节点上进行属性值的测试比较,然后按照实例的属性值确定对应的分支,最后在决策树的叶节点得出分类结论,决策树模型选择的节点分裂特征是信息增益,模型中叶节点含有的最少样本数默认为1。

[0045] 根据本发明优选的,随机森林训练模型基本单元是决策树,通过自助法重采样:随机森林从原始训练样本集中有放回地重复随机抽取 n' 个样本生成新的训练样本集来训练决策树,按以上步骤生成 m' 棵决策树组成随机森林,随机森林集成了所有的分类投票结果,将投票次数最多的类别指定为最终输出,设置随机森林中决策树棵树范围为50-500棵,不限制决策树的最大深度。

[0046] 一种利用上述识别方法进行井筒流体类型识别的系统,其特征在于,包括:数据预处理模块、声波特征参数提取模块和井筒流体类型识别模块;

[0047] 所述数据预处理模块,用于得到与井筒流体类型相关的滤波和归一化处理之后的声波数据;

[0048] 所述声波特征参数提取模块,用于进行声波特征参数提取,得到与井筒流体类型相关的声波特征;所述与井筒流体类型相关的声波特征包括:低方差散射特征集a和短时时频特征集b融合形成的融合特征集c;

[0049] 所述井筒流体类型识别模块,用于将声波特征输入至分类算法中进行训练,得到井筒流体类型识别模型;

[0050] 最终将实时DAS系统声波监测数据输入至所述井筒流体类型识别模型中,输出结果即为对应的井筒流体类型。

[0051] 一种描绘目标待测的井筒内不同流体分布的方法,其特征在于,包括:

[0052] (1) 利用DAS系统实时采集目标待测的井筒各位置分布的声波数据;

[0053] (2) 将步骤(1)的声波数据输入至所述步骤三所述井筒流体类型识别模型中,输出结果:井筒流体类型;

[0054] (3) 将与声波数据对应的井筒流体位置信息与对应输出的井筒流体类型进行关联。

[0055] 本发明所述应用方法可以便于后续根据实时分布采集并识别出的井筒流体类型,数字化描绘井筒内不同类型流体的动态分布,该应用方法具有重要意义。

[0056] 一种描绘目标待测的井筒内油水两相流中含水范围的方法,其特征在于,包括:

[0057] (4) 利用DAS系统实时采集目标待测的井筒内油水两相流中不同含水范围的声波数据;

[0058] (5) 将步骤(4)的声波数据输入至所述井筒内油水两相流中含水范围的识别模块中,输出结果:油水两相流中含水范围。

[0059] 本发明是技术优势在于:

[0060] (1) 本发明将低方差散射特征与短时时频特征相结合形成融合特征用于流体类型识别,融合特征属于多源特征,综合了低方差散射特征与短时时频特征中包含的信息,为井筒流体类型的准确识别提供了更多数据源,有效解决单一特征识别流体类型准确率低的问题,极大地提高了识别精度。

[0061] (2) 本发明所述方法可以准确识别井筒流体类型,可用于现场监测井下多相流体流动和识别水气突破位置。

[0062] (3) 由于井下各种流体的性质差异,在井下流动过程中产生的声波数据不同,利用声波数据中所携带的流体类型信息,结合机器学习算法可以实现井下流体类型识别,本发明利用的分类算法分别为BP神经网络、决策树和随机森林,这三种方法是机器学习算法中具有代表性的分类算法,将三种分类算法分别得到的流体类型、油水两相中含水范围的分类结果进行对比,可以提高流体类型识别和油水两相中含水范围识别的最终准确率。

附图说明

[0063] 图1为本发明所述基于分布式光纤声波监测数据的井筒流体类型识别方法流程示

意图;

[0064] 图2为本发明实施例1的声波数据的原始数据示意图;

[0065] 图3A为本发明实施例1所提取的声波数据的低方差散射特征集a的第一滤波器组散射特征图;

[0066] 图3B为本发明实施例1所提取的声波数据的低方差散射特征集a的第二滤波器组散射特征图;

[0067] 图4为本发明实施例1所提取的声波数据的短时时频特征集b;

[0068] 图5A为本发明实施例1所使用的随机森林算法对低方差散射特征集a的识别训练集结果的混淆矩阵图;

[0069] 图5B为本发明实施例1所使用的随机森林算法对低方差散射特征集a的识别测试集结果的混淆矩阵图;

[0070] 图6A为本发明实施例1所使用的随机森林算法对短时时频特征集b的识别训练集结果的混淆矩阵图;

[0071] 图6B为本发明实施例1所使用的随机森林算法对短时时频特征集b的识别测试集结果的混淆矩阵图;

[0072] 图7A为本发明实施例1所使用的随机森林算法对融合特征集c的识别训练集结果的混淆矩阵图;

[0073] 图7B为本发明实施例1所使用的随机森林算法对融合特征集c的识别测试集结果的混淆矩阵图;

[0074] 图8A为本发明实施例1所使用的随机森林算法对低方差散射特征集a的识别训练集结果的ROC曲线图;

[0075] 图8B为本发明实施例1所使用的随机森林算法对低方差散射特征集a的识别测试集结果的ROC曲线图;

[0076] 图9A为本发明实施例1所使用的随机森林算法对短时时频特征集b的识别训练集结果的ROC曲线图;

[0077] 图9B为本发明实施例1所使用的随机森林算法对短时时频特征集b的识别测试集结果的ROC曲线图;

[0078] 图10A为本发明实施例1所使用的随机森林算法对融合特征集c的识别训练集结果的ROC曲线图;

[0079] 图10B为本发明实施例1所使用的随机森林算法对融合特征集c的识别测试集结果的ROC曲线图。

具体实施方式

[0080] 下面结合实施例和说明书附图对本发明做详细的说明,但不限于此。

[0081] 实施例1、

[0082] 利用井筒多相流物理模拟实验装置,开展不同流体类型和不同流量情况下的分布式光纤声波监测实验,获取相应的声波数据,构建样本数据库。使用的分布式光纤声波监测系统的空间采样间隔为0.25m,采样频率为4096Hz。

[0083] 流体类型分别为:单相气、单相水、单相油、油水两相、油气两相、水气两相和油气

水三相共7种类型,分别标注为1到7。通过井筒多相流实验得到原始声波数据集样本共5286个,每个样本提取流体进入点下游1米的声波数据,即每个流体进入点附近提取4组数据,原始数据集样本共提取21144组数据。

[0084] 图2所示为 $0.2\text{m}^3\cdot\text{h}^{-1}$ 流量下单相水的声波监测结果。将原始数据集随机打乱之后按照8:2的比例划分为训练集和测试集,如表1所示:

[0085] 表1声波数据集

	井筒流体类型	流量范围/ $(\text{m}^3\cdot\text{h}^{-1})$	训练/测试集数据	标签
[0086]	单相气	气量 1.0-10.0	6048/1512	1
	单相水	水量 0.1-4	5536/1384	2
	单相油	油量 0.1-4	2285/571	3
	油水两相	油量 0.1-4	365/91	4
		水量 0.1-4		
	油气两相	油量 0.1-4	362/90	5
		气量 1.0-10.0		
	水气两相	水量 0.1-4	1040/260	6
		气量 1.0-10.0		
	油气水三相	油量 0.1-4	1280/320	7
[0087]		水量 0.1-4		
		气量 1.0-10.0		

[0088] 利用数据预处理模块、声波特征参数提取模块和井筒流体类型识别模块对构建的样本库进行处理,建立井筒流体类型识别方法,即如图1所示,一种基于分布式光纤声波监测数据的井筒流体类型识别方法,包括,

[0089] 步骤一:对DAS系统采集的声波监测数据进行预处理,用于得到与井筒流体类型相关的滤波和归一化处理之后的声波数据;

[0090] 步骤二:对步骤一预处理后的数据进行声波特征参数提取,得到与井筒流体类型相关的声波特征;

[0091] 所述与井筒流体类型相关的声波特征包括:低方差散射特征集a和短时时频特征集b融合形成的融合特征集c;

[0092] 步骤三:将步骤二得到的声波特征输入至分类算法中进行训练,得到井筒流体类型识别模型;

[0093] 步骤四:将实时DAS系统声波监测数据输入至所述步骤三所述井筒流体类型识别模型中,输出结果即为对应的井筒流体类型。

[0094] 所述步骤一中所述预处理方法,包括:

[0095] 1-1采用滤波器对井筒流体流动过程中声波监测数据进行处理,得到频率范围在

[200Hz, 2000Hz]的声波幅值;

[0096] 1-2将经步骤1-1得到的声波幅值,进行Z-score归一化处理,所述的Z-score归一化公式表示为:

$$[0097] \quad x' = \frac{x - \mu}{\sigma} \quad (1)$$

[0098] 其中,x为声波幅值;x'为归一化后的结果,即DAS声波数据集; μ 为x的平均值, σ 为x的标准差。

[0099] 所述步骤二中,进行声波特征参数提取,得到与井筒流体类型相关的声波特征的方法,包括:

[0100] 2-1利用小波时间散射变换提取DAS声波数据集的低方差散射特征集a;其中,所述低方差散射特征集a的维度为 $(w*k) \times p$,即 $8k \times 268$,k为DAS声波数据集的个数, $p=268$ 为信号经散射变换后得到的散射路径的个数, $w=8$ 为每条散射路径对应的时间窗口的个数, p 和 w 与DAS系统的采样频率有关;其中,利用小波时间散射变换是指利用软件Matlab中的小波工具箱,通过构建了用于特征提取的带有两个滤波器组的小波时间散射网络而实现的,此步骤中利用软件Matlab求取低方差散射特征集a是现有技术,不属于本发明所保护的内容;

[0101] 同时,利用短时傅里叶变换(STFT)对DAS声波数据集进行处理,得到DAS的时频数据集,将时频数据集输入到主成分分析算法(PCA)中进行处理,提取DAS声波数据集的短时时频特征集b;其中,短时时频特征集b的维度为 $k \times r$, $r=257$ 为短时傅里叶变换(STFT)处理声波数据时采用的窗口重叠宽度加1,所述窗口重叠宽度为窗口宽度的一半,所述短时傅里叶变换(STFT)是关于时间和频率的二维函数:

$$[0102] \quad STFT(k', t) = \sum_{m=1}^N x(t)w(t - m/fs)e^{-2\pi k' jm/N} \quad (2)$$

[0103] 在公式(2)中,N表示DAS声波数据时间序列维数;t为时间参数; k' 为频率参数; fs 为DAS系统的采样频率; $m=1, 2, \dots, N$;j为虚数单位, $j = \sqrt{-1}$;x(t)为需要处理的时域DAS声波数据; $w(t-m/fs)$ 代表中心位于 m/fs 时刻的窗口函数;优选的,为减少频谱泄漏,所述窗口选择汉明窗;

[0104] 所述主成分分析算法(PCA)是一种常用的降维统计技术,本发明利用PCA算法计算时频数据集协方差矩阵的特征向量,第一主成分的特征值最大,对应特征向量上包含的信息量最多,可利用第一主成分特征向量得到与井筒流体类型最相关的短时时频特征集b;

[0105] 2-2将低方差散射特征集a与短时时频特征集b融合形成融合特征集c:

[0106] 低方差散射特征集a的数据维度为 $(w*k) \times p=8k \times 268$,短时时频特征集b的数据维度为 $k \times r=k \times 257$,重复短时时频特征集b的数据,将其维度扩展到 $(w*k) \times r=8k \times 257$;利用顺序排列的方式得到融合特征集c,融合特征集c的维度为 $(w*k) \times (p+r)=8k \times 525$;

[0107] 以井筒中 $0.2m^3 \cdot h^{-1}$ 流量下单相水流动实验的声波数据为例,提取的低方差散射特征集a如图3A、图3B所示,短时时频特征集b如图4所示;

[0108] 2-3利用分类算法训练形成井筒流体类型识别模块:所述融合特征集c作为输入,将融合特征集c对应的已知流体类型作为输出;所述分类算法包括BP神经网络、决策树和随机森林;

[0109] 2-4对BP神经网络、决策树和随机森林分别进行训练并分别形成BP神经网络训练模型、决策树训练模型和随机森林训练模型;将测试集分别代入BP神经网络训练模型、决策树训练模型和随机森林训练模型中,通过均方误差验证预测的效果:当预测精度满足要求时,进入后续的利用现场实际监测数据进行流体类型识别的环节;当不满足预测精度要求时,重新调节分类算法的训练参数,重新开始训练过程,直到满足精度要求为止。此处可以按照现有技术确定训练精度,这三种训练模型都是比较经典的分类方法,所述按照训练精度停止训练的技术手段属于现有技术;将DAS原始声波数据集随机打乱之后按照8:2的比例划分为训练集和测试集。

[0110] 其中,BP神经网络训练模型为三层网络结构,在前向传播的过程中,输入数据从输入层经隐含层处理,直至输出层;如果输出层得不到期望输出,则转入反向传播,根据预测误差调整网络权值和阈值,从而使BP神经网络预测输出不断逼近期望输出,BP神经网络选择适用于模式识别的比例共轭梯度(SCG)算法,选择交叉熵为损失函数,避免过拟合,设置BP神经网络最大训练次数为10000,学习速率为0.01。

[0111] 其中,决策树训练模型是一个类似流程图的树形结构,由节点和有向边组成;所述节点包括内部节点和叶节点,内部节点表示一个特征或一个属性,叶节点表示一个类;采用自顶向下的递归方式,从树的根节点开始,在它的内部节点上进行属性值的测试比较,然后按照实例的属性值确定对应的分支,最后在决策树的叶节点得出分类结论,决策树模型选择的节点分裂特征是信息增益,模型中叶节点含有的最少样本数默认为1。

[0112] 其中,随机森林训练模型基本单元是决策树,通过自助法重采样:随机森林从原始训练样本集中有放回地重复随机抽取 n' 个样本生成新的训练样本集来训练决策树,按以上步骤生成 m' 棵决策树组成随机森林,随机森林集成了所有的分类投票结果,将投票次数最多的类别指定为最终输出,设置随机森林中决策树棵树为400棵,不限制决策树的最大深度。

[0113] 利用基于分布式光纤声波监测数据的井筒流体类型识别方法对上述训练集和测试集的融合特征集c进行训练和测试,识别结果的混淆矩阵如图7A、7B所示,ROC曲线如图10A、10B所示。

[0114] 混淆矩阵图中,主对角线方块显示流体类型被正确分类的样本数及占总样本数的百分比,主对角线周围方块显示流体类型被错误分类的样本数及占总样本数的百分比,每一行和每一列的正确与错误分类的百分比显示在最下侧一行和最右侧一列方块中,所有流体类型的正确与错误分类的总百分比显示在右下角方块中。

[0115] ROC曲线图通过描述真阳性率和假阳性率之间的变化关系来解释分类识别问题,真阳性率是指把正确样本分对的概率,假阳性率是指把错误样本分为正确样本的概率,在ROC曲线图中,横坐标为假阳性率,纵坐标为真阳性率,结果越靠近正方形格子的左上角,分类识别效果越好。以图7B中测试集混淆矩阵结果第一类为例,第一类总样本数为1512,数据量占测试集总数据量的35.8%,流体类型正确识别个数为1512,错误识别个数为0,正确识别率达100%,七种流体类型平均正确识别率达100%;以图10B中测试集ROC曲线为例,七种流体类型的识别结果均汇集在正方形格子左上角的一个点,正确识别率达100%,验证了所构建的基于融合特征集c的井筒流体类型识别方法具有满意的识别率。

[0116] 在本实施例中,将低方差散射特征集a与短时频谱特征集b分别作为各分类算法的

输入数据进行流体类型识别的结果和本发明中提出的将融合特征集c作为各分类算法的输入数据进行流体类型识别的结果作为对比,以验证本发明提出的将融合特征集进行流体类型识别的优势和有效性,结果如表2所示:

[0117] 表2井筒流体类型识别准确率

声波特征	BP 神经网络		决策树		随机森林	
	训练集	测试集	训练集	测试集	训练集	测试集
低方差散射特征集 a	99.4%	93.1%	100%	95.8%	100%	91.3%
短时时频特征集 b	92.3%	89.4%	98.5%	86.5%	100%	91.0%
融合特征集 c	99.9%	97.3%	100%	99.9%	100%	100%

[0119] 低方差散射特征集a与短时时频特征集b的流体类型识别结果的混淆矩阵如图5A、5B和图6A、6B所示,ROC曲线如图8A、8B和图9A、9B所示。从混淆矩阵图5A、5B和图6A、6B中可以看出,单一声波特征识别分类时单相气(标签1)和单相水(标签2)这两种流体类型分类准确率低,这也与ROC曲线图8A、8B和图9A、9B中标签是1和2的这两类分类效果较差的现象相吻合,从表2中可以明确地看出,相比于单一声波特征,融合特征集c极大地提高了流体类型识别准确率。

[0120] 本发明提出了将低方差散射特征集a与短时时频特征集b进行集合形成融合特征集c的方法,BP神经网络的识别准确率在97%以上,决策树和随机森林算法的识别准确率高达99.9%和100%,这表明本发明提出的融合特征集c对于基于分布式光纤声波监测数据的井筒流体类型识别的有效性,远远超过单一声波特征的识别方法,说明本发明提出的方法在解决井筒流体类型识别问题中的有效性和突出优势,这也为井下多相流体流动监测和水气突破识别提供了一种可靠的手段。

[0121] 实施例2、

[0122] 如实施例1所述的识别方法,一种识别井筒内油水两相流中含水范围的方法,所述步骤二中,进行声波特征参数提取,得到与油水两相流中不同含水范围相关的声波特征的方法,包括:

[0123] 3-1利用DAS系统实时采集目标待测的井筒内油水两相流中,不同含水范围所对应的声波数据,构建样本数据库;

[0124] 3-2将油水两相流中的含水范围分为Y组,并分别标注为1到Y;

[0125] 3-3利用小波时间散射变换提取DAS声波数据集的低方差散射特征集a;其中,所述低方差散射特征集a的维度为 $(w \times k) \times p$,k为DAS声波数据集的个数,p为信号经散射变换后得到的散射路径的个数,w为每条散射路径对应的时间窗口的个数,p和w与DAS系统的采样频率有关;

[0126] 同时,利用短时傅里叶变换对DAS声波数据集进行处理,得到DAS的时频数据集,将时频数据集输入到主成分分析算法中进行处理,提取DAS声波数据集的短时时频特征集b;

其中,短时频特征集b的维度为 $k \times r$, r 为短时傅里叶变换处理声波数据时采用的窗口重叠宽度加1,所述窗口重叠宽度为窗口宽度的一半,所述短时傅里叶变换是关于时间和频率的二维函数:

$$[0127] \quad STFT(k', t) = \sum_{m=1}^N x(t)w(t - m/fs)e^{-2\pi k' jm/N} \quad (2)$$

[0128] 在公式(2)中, N 表示DAS声波数据时间序列维数; t 为时间参数; k' 为频率参数; fs 为DAS系统的采样频率; $m=1,2,\dots,N$; $j=\sqrt{-1}$; $x(t)$ 为需要处理的时域DAS声波数据; $w(t-m/fs)$ 代表中心位于 m/fs 时刻的窗口函数;

[0129] 3-4将低方差散射特征集a与短时频特征集b融合形成融合特征集c:

[0130] 低方差散射特征集a的数据维度为 $(w \times k) \times p$,短时频特征集b的数据维度为 $k \times r$,重复短时频特征集b的数据,将其维度扩展到 $(w \times k) \times r$;利用顺序排列的方式得到融合特征集c,融合特征集c的维度为 $(w \times k) \times (p+r)$;

[0131] 3-5利用分类算法训练形成油水两相流中含水范围的识别模块:所述融合特征集c作为输入,将融合特征集c对应的油水两相流中含水范围作为输出;所述分类算法包括BP神经网络、决策树和随机森林;

[0132] 3-6对BP神经网络、决策树和随机森林分别进行训练并分别形成BP神经网络训练模型、决策树训练模型和随机森林训练模型。

[0133] 具体的,利用井筒多相流物理模拟实验装置,开展大量的不同含水率下油水两相流动模拟光纤监测实验,获取相应的声波数据,构建样本数据库。使用的分布式光纤声波监测系统的空间采样间隔为0.25m,采样频率为4096Hz。

[0134] 含水范围分别为:0-10%、10-20%、20-30%、30-40%、40-50%、50-60%、60-70%、70-80%、80-90%和90-100%共10种类型,分别标注为1到10。通过实验得到原始声波数据集样本共613个,每个样本提取流体进入点下游2米的声波数据,即每个流体进入点附近提取8组数据,模拟实验系统共布置了五根光缆,则每个流体进入点处五根光缆共提取40组数据,原始数据集样本共提取24520组数据。将原始数据集随机打乱之后按照8:2的比例划分为训练集和测试集,如表3所示:

[0135] 表3油水两相流声波数据集

	含水范围	实验组数	训练/测试集数据	标签
[0136]	0-10%	16	512/128	1
	10-20%	29	928/232	2
	20-30%	64	2048/512	3
	30-40%	71	2272/568	4
	40-50%	101	3232/808	5

[0137]	50-60%	105	3360/840	6
	60-70%	67	2144/536	7
	70-80%	63	2016/504	8
	80-90%	55	1760/440	9
	90-100%	42	1344/336	10

[0138] 表4含水范围识别分类准确率

声波特征	BP 神经网络		决策树		随机森林	
	训练集	测试集	训练集	测试集	训练集	测试集
低方差散射特征集 a	70.8%	51.8%	99.9%	53.9%	100%	65.7%
短时频特征集 b	91.7%	41.4%	86.5%	38.1%	100%	63.3%
融合特征集 c	96.4%	83.4%	100%	99.3%	100%	100%

[0140] 利用提出的油水两相流中含水范围的识别方法对声波数据集进行识别分类,结果如表4所示,将低方差散射特征和短时频特征集成多源数据,再结合随机森林机器学习算法,能准确地识别油水两相流中的含水范围。

[0141] 实施例3、

[0142] 一种利用如实施例1所述识别方法进行井筒流体类型识别的系统,包括:数据预处理模块、声波特征参数提取模块和井筒流体类型识别模块;

[0143] 所述数据预处理模块,用于得到与井筒流体类型相关的滤波和归一化处理之后的声波数据;

[0144] 所述声波特征参数提取模块,用于进行声波特征参数提取,得到与井筒流体类型相关的声波特征;所述与井筒流体类型相关的声波特征包括:低方差散射特征集a和短时频特征集b融合形成的融合特征集c;

[0145] 所述井筒流体类型识别模块,用于将声波特征输入至分类算法中进行训练,得到井筒流体类型识别模型;

[0146] 最终将实时DAS系统声波监测数据输入至所述井筒流体类型识别模型中,输出结果即为对应的井筒流体类型。

[0147] 实施例4、

[0148] 一种利用如实施例2所述识别方法进行井筒内油水两相流中含水范围识别系统,包括:数据预处理模块、声波特征参数提取模块和井筒内油水两相流中含水范围识别模块;

[0149] 所述数据预处理模块,用于得到与井筒内油水两相流中不同含水范围相关的滤波和归一化处理之后的声波数据;

[0150] 所述声波特征参数提取模块,用于进行声波特征参数提取,得到与井筒内油水两相流中不同含水范围相关的声波特征;所述与井筒内油水两相流中不同含水范围相关的声波特征包括:低方差散射特征集a和短时频特征集b融合形成的融合特征集c;

[0151] 所述井筒内油水两相流中含水范围识别模块,用于将声波特征输入至分类算法中进行训练,得到井筒内油水两相流中含水范围识别模型;

[0152] 最终将实时DAS系统声波监测数据输入至所述井筒内油水两相流中含水范围识别模型中,输出结果即为对应的油水两相流中含水范围。

[0153] 实施例5、

[0154] 如实施例1、3,一种描绘目标待测的井筒内不同流体分布的方法,包括:

[0155] 1) 利用DAS系统实时采集目标待测的井筒各位置分布的声波数据;

[0156] 2) 将步骤1)的声波数据输入至所述步骤三所述井筒流体类型识别模型中,输出结果:井筒流体类型;

[0157] 3) 将与声波数据对应的井筒流体位置信息与对应输出的井筒流体类型进行关联。

[0158] 本发明所述应用方法可以便于后续根据实时分布采集并识别出的井筒流体类型,数字化描绘井筒内不同类型流体的动态分布,该应用方法具有重要意义。

[0159] 实施例6、

[0160] 如实施例2、4,一种描绘目标待测的井筒内油水两相流中不同含水范围的方法,包括:

[0161] (4) 利用DAS系统实时采集目标待测的井筒内油水两相流中不同含水范围的声波数据;

[0162] (5) 将步骤(4)的声波数据输入至所述井筒内油水两相流中含水范围的识别模块中,输出结果:油水两相流中含水范围。




图1




图2




图3A




图3B




图4




图5A




图5B




图6A




图6B




图7A




图7B




图8A




图8B




图9A




图9B




图10A




图10B